

Proyecto Big Data — ICFES Saber 11

Comparativa v1 (datos.gov.co) vs v2 (DataIcfes)

Pontificia Universidad Javeriana — Ingeniería de Sistemas

Docente: John Corredor, PhD

Equipo: Juan Martin Trejos · Juan Santiago Mendez · Diego Zabala · Juan David Ordoñez
2026

Hipotesis del proyecto

El techo de F1 macro ~0.46 del Proyecto v1 se debia a la limitada informacion disponible en (datos.gov.co), no al algoritmo ni al volumen de datos. Con los microdatos completos de Datalcfes — que incluyen variables de contexto del estudiante, capital cultural del hogar e indice NSE individual— el modelo deberia superar ese techo.

1. Datos, Seleccin del Dataset, Limpiezas y Preparacion

1.1 ¿Que datos nuevos teniamos en la version 2?

La principal diferencia entre ambas versiones fue la fuente de datos. En el Proyecto v1 se uso el dataset publico de datos.gov.co, que ofrecia una version reducida de los resultados Saber 11 con apenas 11 variables disponibles. Para el Proyecto v2 se accedio directamente a **Datalcfes**, el repositorio oficial del ICFES, que provee los microdatos completos por departamento desde el año 2010 en archivos .txt separados por punto y coma.

Se descargaron 64 archivos en total: 32 de Boyaca (municipio de Sogamoso, codigo DANE 15759) y 32 de Huila (municipio de Pitalito, codigo DANE 41551), cubriendo periodos semestrales desde 2010 hasta 2025. Esto permitio contar con 20 variables adicionales respecto al v1:

Variable	Tipo	Que aporta
estu_inse_individual	NSE continuo	Reemplaza el join proxy con SISBEN del v1
estu_nse_establecimiento	NSE colegio	Nivel promedio del establecimiento (1-4)
fami_numlibros	Capital cultural	Proxy del ambiente intelectual del hogar
fami_cuartoshogar	Hacinamiento	Condiciones de estudio en casa
fami_situacioneconomica	Percepcion	Como percibe el hogar su situacion economica
cole_caracter	Tipo colegio	Academico / Tecnico / Mixto
cole_jornada	Tipo colegio	Mañana / Tarde / Completa / Nocturna
estu_dedicacioninternet	Habitos	Horas semanales de uso de internet
estu_dedicacionlecturadiaria	Habitos	Habito de lectura diaria del estudiante
estu_horassemanatrabaja	Contexto	Si el estudiante trabaja y cuantas horas
fami_tienemotocicleta	Bienes hogar	Proxy socioeconomico con alto peso en zonas rurales

1.2 Seleccin del dataset y configuracion del split temporal

Se cargaron unicamente los años necesarios para el experimento: **Train: 2015, 2016, 2017 y 2019** — años limpios con datos completos — y **Test: 2022**, reservado como ventana de prediccion futura. El año 2020 fue excluido por la pandemia COVID-19, que altero los patrones de presentacion de la prueba. Esto resulto en 15.364 registros de entrenamiento y 3.790 de prueba, distribuidos equitativamente entre Sogamoso y Pitalito.

La estructura del split temporal es identica entre v1 y v2, lo que garantiza que cualquier diferencia en los resultados se explica exclusivamente por las variables disponibles, no por el volumen ni el horizonte de prediccion.

1.3 Limpiezas, transformaciones e imputacion de nulos

Encoding de variables categoricas

Todas las variables categoricas fueron transformadas a valores numericos mediante mapeos ordinales y binarios. Los mapeos mas relevantes fueron:

- **Educacion de padres:** escala ordinal 0 (Ninguno) a 7 (Postgrado), capturando la progresion del nivel educativo.
- **Estrato vivienda:** ordinal 1 a 6. Los valores 'Sin estrato' se trataron como nulos y se imputaron.
- **Variables binarias (internet, computador, automovil, etc.):** Si=1, No=0.
- **Numero de libros en el hogar:** escala 0 (ninguno) a 4 (mas de 100 libros).
- **Caracter del colegio:** 0=Academico, 1=Tecnico/Academico, 2=Tecnico.

El problema de la imputacion: variables con hasta 50% de nulos

Factor limitante identificado

Varias de las variables nuevas mas prometedoras presentaron porcentajes de nulos superiores al 40%. Esto significa que casi la mitad de los registros de train no tenian valor real para esas variables: el modelo recibio la mediana imputada en lugar de la informacion real del estudiante. Una variable con 50% de imputacion aporta señal genuina solo en la mitad de los casos.

Los porcentajes de nulos mas relevantes detectados en el dataset v2 fueron:

Variable	% Nulos	Estrategia de imputacion
cole_caracter	100%	
cole_jornada	47.2%	Mediana global
estu_dedicacionlecturadiaria	53.7%	Mediana global
estu_dedicacioninternet	51.3%	Mediana global
estu_horassemanatrabaja	~40%	Mediana global
fami_tienemotocicleta	41.4%	Mediana por año

Variables derivadas por feature engineering

Para aprovechar mejor las variables disponibles, se construyeron cinco variables de interaccion:

- **capital_educativo**: suma del nivel educativo de ambos padres (rango 0-14). Captura el ambiente academico del hogar como unidad.
- **recursos_tech**: internet + computador (0-2). Refleja el acceso tecnologico para estudio.
- **ventaja_hogar**: capital_educativo × recursos_tech. Captura el efecto multiplicador entre educacion de los padres y acceso tecnologico.
- **bienes_hogar**: automovil + lavadora + television por cable (0-3). Proxy de bienestar material.
- **densidad_hogar**: personas / cuartos. Indicador de hacinamiento y condiciones de estudio.

1.4 Preparacion final para los modelos

Tras eliminar variables redundantes por multicolinealidad ($r > 0.85$ con variables derivadas), el dataset final quedo con 24 features activas. La normalizacion se aplico con StandardScaler ajustado exclusivamente sobre el conjunto de train, garantizando que ningun dato del año de prueba (2022) influyera en la escala del modelo.

La distribucion de clases resulto bien balanceada: Bajo 34.8%, Medio 33.6%, Alto 31.5% en train, y Bajo 31.6%, Medio 31.3%, Alto 37.1% en test 2022.

2. Modelos y Resultados

2.1 Algoritmos evaluados

Se mantuvieron exactamente los mismos algoritmos del Proyecto v1 para garantizar que la comparacion fuera justa y atribuible unicamente a las variables: Random Forest (base y tuning), XGBoost (base y tuning), LightGBM (base y tuning) y una Red Neuronal MLP. Todos fueron evaluados sobre el mismo test 2022 con el mismo split temporal train 2015-2019 / test 2022.

2.2 Resultados — Proyecto v2 (Data1cfes)

Modelo	F1 macro	Accuracy	Acc. Adyacente
LightGBM base	0.5073	0.5153	0.9055
XGBoost tuning	0.5069	0.5150	0.9050
LightGBM tuning	0.5055	0.5169	—
XGBoost base	0.5028	0.5090	0.9050
RF tuning	0.5015	0.5145	—
RF base	0.4949	0.4997	0.8984

Tabla 1. Resultados del Proyecto v2 sobre el conjunto de prueba 2022. El sombreado verde indica el mejor modelo.

2.3 Comportamiento por clase

Un patron consistente en todos los modelos fue la dificultad para predecir la clase Medio. El analisis de los classification reports muestra:

- **Clase Bajo:** F1 entre 0.57 y 0.60 — bien identificada por las variables socioeconomicas.
- **Clase Alto:** F1 entre 0.56 y 0.63 — tambien bien separada del resto.
- **Clase Medio:** F1 entre 0.34 y 0.37 — significativamente mas baja en todos los modelos.

Este patron no es un fallo del modelo sino una limitacion estructural del problema: los estudiantes de nivel medio comparten caracteristicas socioeconomicas con ambos extremos, haciendo que sus fronteras de decision sean inherentemente difusas. Ningun dataset de caracteristicas del hogar puede resolver completamente esta ambigüedad.

2.4 Accuracy adyacente: la metrica ordinal

El accuracy estandar penaliza igual un error de un nivel (Bajo predicho como Medio) que un error grave (Bajo predicho como Alto). Para clases ordinales, el **accuracy adyacente** es mas justo: cuenta como acierto cualquier prediccion a distancia de un nivel. En el Proyecto v2, todos los modelos alcanzaron accuracy adyacente superior al **89%**, lo que significa que cuando el modelo se equivoca casi siempre es por un solo nivel — nunca confunde Bajo con Alto de forma sistematica.

3. Analisis, Conclusiones y Comparativa entre Modelos

3.1 Comparativa directa v1 vs v2

Aspecto	Proyecto v1	Proyecto v2	Diferencia
Fuente de datos	kgxf-xxbe (datos.gov.co)	Datalcfes (.txt por depto)	Fuente completa
Variables activas	~11	24	+13 vars
NSE individual	Join proxy SISBEN	estu_inse_individual	Directo y continuo
Capital cultural	No disponible	fami_numlibros	Nueva en v2
Registros train	~18,800	15,364	Menos (-18%)
Mejor F1 macro	0.4608 (LightGBM)	0.5073 (LightGBM base)	+4.65 pp
Mejor Accuracy	~0.466	0.5153	+4.93 pp
Acc. Adyacente	~0.86	>0.89	+3 pp

Tabla 2. Comparativa directa entre ambas versiones del proyecto.

3.2 Verificación de la hipótesis

hipótesis CONFIRMADA — delta F1 macro: +4.65 puntos porcentuales

Los mismos algoritmos, aplicados sobre datos más ricos, mejoraron el F1 macro de 0.4608 a 0.5073. La diferencia es atribuible exclusivamente a las variables adicionales de Datalcfes, ya que el Split temporal, los municipios y los algoritmos fueron idénticos.

3.3 Porque no mejoro más: el efecto de la imputación masiva

Aunque la hipótesis se confirma, la mejora es moderada (+4.65 pp) en lugar de dramática. La razón principal es la imputación de variables con altos porcentajes de nulos, que redujo el poder informativo real del dataset v2:

- **cole_caracter (100% nulos)**: fue la pérdida más significativa. Esta variable —carácter académico o técnico del colegio— es uno de los predictores más fuertes del rendimiento ICFES según la literatura educativa, pero el ICFES no la registraba de forma consistente en los años de train (2015-2019). Al imputar con la mediana, la variable se convirtió en una constante sin señal.
- **estu_dedicacioninternet y estu_dedicacionlecturadiaria (>50% nulos)**: estas variables de hábitos del estudiante fueron prometedoras teóricamente —el tiempo dedicado a internet y a la lectura captura rutinas de estudio— pero con más de la mitad de los valores imputados, su contribución al modelo fue mínima.
- **estu_horassemanatrabaja (~40% nulos)**: saber si un estudiante trabaja es uno de los predictores más fuertes del rendimiento académico. Con un 40% de imputación, el modelo vio la señal de trabajo solo en 6 de cada 10 estudiantes.

En términos prácticos: el dataset v2 prometía ~30 variables nuevas, pero efectivamente aportó señal real en aproximadamente 15 de ellas. El resto fue ruido imputado que no perjudicó al modelo pero tampoco lo ayudó.

3.4 Variables más importantes en el modelo v2

El análisis de feature importance del mejor Random Forest sobre Datalcfes mostró el siguiente orden de relevancia:

- **estu_inse_individual**: el predictor más fuerte del modelo. El índice NSE continuo provisto por Datalcfes reemplazó con ventaja el join proxy que el v1 hacía contra el SISBEN.
- **estu_nse_establecimiento**: segundo predictor. El nivel socioeconómico promedio del colegio captura el efecto de pares —los estudiantes se ven influenciados por el entorno académico de sus compañeros.
- **ventaja_hogar y capital_educativo**: la interacción entre educación de los padres y acceso tecnológico fue el tercer grupo de variables más informativo.

- **fami_numlibros:** el capital cultural del hogar, ausente en el v1, entro entre las cinco variables mas importantes.
- **cole_area_ubicacion:** la diferencia urbano/rural mantiene alta importancia, consistente con los resultados del v1.

3.5 Conclusiones finales

El Proyecto v2 permite extraer tres conclusiones de distinto alcance:

Conclusion 1: el techo era de informacion, no de algoritmo

La mejora de +4.65 pp en F1 macro usando los mismos modelos confirma que el limite del v1 estaba en la calidad y riqueza de los datos, no en la capacidad del algoritmo. Cambiar a Datalcfes fue la intervencion correcta.

Conclusion 2: hay un nuevo techo, ahora estructural

Todos los modelos del v2 convergen entre 0.49 y 0.52 de F1 macro. Esta convergencia señala que el nuevo limite no es de datos sino del problema mismo: predecir rendimiento ICFES a partir de variables socioeconomicas observables tiene un techo natural. Las variables que faltarian para superarlo —calidad docente especifica, salud mental del estudiante, capacidad cognitiva individual— no existen en ningun dataset publico.

Conclusion 3: la calidad de la imputacion es tan importante como las variables nuevas

Tener acceso a 20 variables nuevas no fue suficiente cuando varias de ellas llegaron con 40-100% de nulos. En proyectos futuros, antes de incorporar una variable nueva, se debe verificar su tasa de completitud en los años de train. Una variable con mas del 30% de imputacion aporta ruido mas que señal.

Resumen ejecutivo

El Proyecto v1 alcanzo F1 macro 0.46 usando datos reducidos de datos.gov.co. El Proyecto v2, con los mismos algoritmos pero microdatos completos de Datalcfes, alcanzo 0.507 — una mejora de 4.65 puntos porcentuales que confirma la hipotesis del techo de informacion. La mejora fue moderada porque varias variables nuevas (cole_caracter, dedicacion internet, horas de trabajo) llegaron con 40-100% de nulos y tuvieron que imputarse, reduciendo su señal real. El nuevo techo (~0.51 F1 macro) es estructural: las variables socioeconomicas observables explican aproximadamente el 50% de la varianza clasificable del puntaje global.