



Pontificia Universidad
JAVERIANA
Colombia

PROYECTO DE INVESTIGACIÓN BIG DATA

Análisis de los Factores Socioeconómicos, Educativos y de Conectividad
en los Resultados del ICFES Saber 11

Pontificia Universidad Javeriana

Facultad de Ingeniería Departamento de Ingeniería de Sistemas
Procesamiento Alto Volumen de Datos , John Corredor, PhD

Juan Martin Trejos , Juan Santiago Mendez , Diego Zabala , Juan David Ordoñez

Mayo 2026

ENTREGA 1: Entendimiento del Negocio y Entendimiento de los Datos

1. Entendimiento del Negocio

1.1 Contexto General

El problema público que aborda este proyecto parte de una desigualdad territorial: los resultados de las pruebas Saber 11 no se producen en el vacío, sino dentro de municipios con capacidades muy distintas en conectividad, condiciones socioeconómicas y trayectorias educativas. Por eso, comparar Pitalito y Sogamoso tiene sentido analítico: no representan el mismo tipo de territorio, ni enfrentan las mismas restricciones, ni deberían recibir la misma intervención pública.

Pitalito presenta un contexto de mayor vulnerabilidad relativa. Se trata de un municipio del departamento del Huila con una economía de base agroindustrial. La conectividad digital es escasa en comparación con ciudades intermedias del interior del país, y la cobertura neta en educación media es significativamente inferior al promedio nacional, lo que sugiere un cuello de botella estructural en el acceso y la permanencia escolar en los grados previos a Saber 11.

Sogamoso presenta un perfil distinto. Es una ciudad intermedia del departamento de Boyacá con una economía basada en industria y minería. Cuenta con una población de aproximadamente 127.235 habitantes, un NBI de 3,59% considerablemente menor al de Pitalito, y MinTIC reporta 15.396 suscriptores de internet. Un diagnóstico reciente del sistema educativo local muestra que la cobertura neta en educación media alcanzó el 73,47% en 2022; sin embargo, la cobertura bruta superó a la neta en más de 50 puntos porcentuales, lo que apunta a problemas de extraedad y trayectorias escolares irregulares.

Municipio	Departamento	Contexto Relevante
Sogamoso	Boyacá	Ciudad intermedia con economía industrial y minera. NBI 3,59%. ~127.235 hab. Conectividad media, cobertura educativa con rezago de eficiencia interna.
Pitalito	Huila	Municipio con perfil socioeconómico más vulnerable. Menor densidad de conectividad y cobertura de educación media por debajo del promedio nacional.

1.2 Indicadores Macroeconómicos de Interés

- Índice de Pobreza Multidimensional (IPM): permite dimensionar las condiciones de vida de la población y su relación con el acceso a internet y el desempeño académico.
- Clasificación SISBEN: refleja la condición socioeconómica de los hogares y permite analizar si el nivel de vulnerabilidad se correlaciona con los resultados del ICFES.
- Cobertura neta de educación media: porcentaje de estudiantes en edad escolar que asisten a grado 10 y 11, relevante para entender el contexto en que se presentan las pruebas Saber 11.

- Puntaje promedio Saber 11 por municipio: variable de resultado central del análisis.

1.3 Objetivo de Negocio

Identificar y cuantificar la relación entre los resultados de las pruebas Saber 11 y los factores socioeconómicos, de conectividad y de trayectoria educativa a nivel municipal, con énfasis en Sogamoso y Pitalito, con el fin de orientar la priorización de intervenciones del Ministerio de Educación.

2. Selección de los Datos a Utilizar

Los tres conjuntos de datos se articulan mediante el código de municipio como llave de unión territorial. El dataset de ICFES aporta la variable de resultado y las características individuales del estudiante; el SISBEN aporta la caracterización socioeconómica poblacional; y el dataset de Educación (MEN) aporta los indicadores del sistema escolar como contexto institucional.

Dataset	Dimensión analítica	Rol en el modelo	Fuente
ICFES Saber 11	Desempeño individual	Variable dependiente (PUNT_GLOBAL) y features del hogar/colegio	ICFES / datos.gov.co
SISBEN (DNP)	Vulnerabilidad socioeconómica	Variables explicativas a nivel poblacional y municipal	DNP / datos.gov.co
MEN – Educación	Trayectoria educativa e infraestructura	Variables de contexto institucional	MEN / datos.gov.co

2.1 Dataset ICFES Resultados Saber 11

Este conjunto constituye la variable dependiente central del proyecto. Contiene puntajes individuales por estudiante, características del hogar y del establecimiento educativo. Los registros se filtran para los municipios de Sogamoso (código DANE 15759) y Pitalito (código DANE 41551).

Variable	Tipo	Justificación
FAMI_TIENEINTERNET	Binaria	Variable central del objetivo: acceso a internet en el hogar.
FAMI_TIENECOMPUTADOR	Binaria	Complementa la conectividad; sin computador el internet tiene uso académico limitado.
FAMI ESTRATOVIVIENDA	Ordinal (1–6)	Proxy directo de condiciones económicas del hogar en contexto colombiano.

Variable	Tipo	Justificación
FAMI_EDUCACIONMADRE	Ordinal (0–7)	Predictor documentado del rendimiento académico en literatura internacional.
FAMI_EDUCACIONPADRE	Ordinal (0–7)	Complementa el capital educativo del hogar junto con educación de la madre.
COLE_NATURALEZA	Binaria	Diferencia colegios oficiales y privados, proxy de recursos institucionales.
COLE_AREA_UBICACION	Binaria	Urbano/rural: captura diferencias de infraestructura y acceso a servicios.
PUNT_GLOBAL	Continua (0–500)	Variable objetivo (TARGET). Transformada en 3 categorías por terciles.

2.2 Dataset SISBEN (DNP)

El SISBEN aporta una caracterización socioeconómica objetiva e independiente de la declarada por el estudiante en el formulario ICFES. Se filtró al rango etario 12–17 años para alinear la población con el grupo que típicamente presenta el examen Saber 11. Se seleccionaron los indicadores de privación IPM más relevantes para el contexto educativo.

2.3 Dataset MEN — Indicadores de Cobertura y Trayectoria Educativa

Este conjunto provee indicadores de eficiencia interna y cobertura del sistema educativo a nivel municipal. Incluye tasas de cobertura, deserción y aprobación por nivel educativo. La variable `sedes_conectadas_internet` fue descartada por ausencia de datos en 2019 y 2022 (los años con mayor volumen de registros ICFES); su rol fue reemplazado por `FAMI_TIENEINTERNET` a nivel individual.

3. Colección y Descripción de los Datos

3.1 Resumen general de los conjuntos de datos

Conjunto	Unidad de análisis	Descripción general	Aporte al objetivo
ICFES	Estudiante	Variables de contexto del estudiante, hogar y establecimiento educativo, junto con puntajes.	Variable dependiente y features individuales/familiares.
SISBEN	Persona / hogar	Indicadores de identificación territorial y condiciones socioeconómicas registradas.	Variables de pobreza y condiciones de vida para contextualizar brechas territoriales.

Conjunto	Unidad de análisis	Descripción general	Aporte al objetivo
Educación (MEN)	Municipio y año	Indicadores agregados de cobertura, matrícula, deserción, aprobación y repitencia.	Contexto institucional del sistema escolar por municipio.

3.2 Descripción de atributos — ICFES

Atributo	Tipo de dato	Significado / descripción
PERIODO	Numérico entero	Año y semestre del examen (ej. 20222 = segundo semestre 2022).
COLE_COD_MCPIO_UBICACION	Categorico / código	Código DANE del municipio del colegio. Llave de join con MEN y SISBEN.
FAMI_TIENEINTERNET	Categorico dicotómico	Indica si el hogar dispone de conexión a internet (Sí/No → 1/0).
FAMI_TIENECOMPUTADOR	Categorico dicotómico	Indica si el hogar dispone de computador (Sí/No → 1/0).
FAMI_ESTRATOVIVIENDA	Categorico ordinal	Estrato socioeconómico de la vivienda (1–6).
FAMI_EDUCACIONMADRE	Categorico ordinal	Máximo nivel educativo alcanzado por la madre (0=Ninguno a 7=Postgrado).
FAMI_EDUCACIONPADRE	Categorico ordinal	Máximo nivel educativo alcanzado por el padre (0=Ninguno a 7=Postgrado).
COLE_NATURALEZA	Categorico binario	Naturaleza del colegio: Oficial (1) / No oficial (0).
COLE_AREA_UBICACION	Categorico binario	Área del colegio: Urbana (1) / Rural (0).
PUNT_GLOBAL	Numérico continuo	Puntaje global consolidado del examen (0–500). Variable TARGET.

3.3 Descripción de atributos — SISBEN

Atributo	Tipo de dato	Significado / descripción
cod_mpio	Categorico / código	Código del municipio. Llave de join con ICFES y MEN.
H_5	Numérico	Índice IPM compuesto (proxy de pobreza multidimensional del hogar).
I1	Numérico	Privación IPM: bajo logro educativo en el hogar.
I3	Numérico	Privación IPM: inasistencia escolar en el hogar.
I4	Numérico	Privación IPM: rezago escolar.

Atributo	Tipo de dato	Significado / descripción
Nivel	Numérico ordinal	Nivel SISBEN numérico (1–10). Proxy de vulnerabilidad socioeconómica.
clasificacion	Categorico	Clasificación SISBEN específica (A1, B3, C6, D2...). Usada como llave de join aproximado con estrato ICFES.
per002	Numérico	Edad de la persona registrada. Usada para filtrar rango 12–17 años.

3.4 Descripción de atributos — Educación (MEN)

Atributo	Tipo de dato	Significado / descripción
CÓDIGO_MUNICIPIO	Código DANE	Identificador territorial. Llave de join con ICFES.
AÑO	Numérico entero	Año de referencia del indicador. Llave temporal del join.
COBERTURA_NETA_MEDIA	Numérico [0,1]	Cobertura neta en educación media (grados 10–11).
DESERCIÓN_MEDIA	Numérico [0,1]	Tasa de deserción en educación media.
APROBACIÓN_MEDIA	Numérico [0,1]	Tasa de aprobación en educación media.


4. Exploración de los Datos

El análisis exploratorio se realizó sobre los datasets de Sogamoso y Pitalito para comprender la estructura, distribución, variabilidad y relaciones entre variables de interés. El análisis se centró en el dataset ICFES, complementado con indicadores del SISBEN y el MEN.

4.1 Análisis exploratorio — ICFES Saber 11

Se analizaron las principales variables del dataset ICFES para los municipios de Sogamoso y Pitalito. La figura agrupa nueve subgráficas: distribución e histograma del puntaje global por municipio, distribución del estrato de vivienda, porcentaje de hogares con acceso a internet, nivel educativo de la madre, naturaleza del colegio (oficial/no oficial), número de personas en el hogar, área del colegio (urbana/rural) y evolución temporal del puntaje promedio por año.


Análisis Exploratorio — ICFES Saber 11



[Figura 2. Distribución del puntaje global ICFES por municipio]

4.2 Análisis exploratorio — SISBEN


Se analizó el dataset SISBEN filtrado al rango etario 12–17 años para los dos municipios. La figura agrupa seis subgráficas: distribución del IPM compuesto (H5) por municipio, frecuencia de la clasificación SISBEN (grupo), promedio de indicadores de privación (i1, i2, i3, i4, i6, i15), distribución urbana vs. rural por municipio, distribución del nivel SISBEN por municipio, e IPM (H5) comparado entre zona urbana y rural. Pitalito concentra mayor proporción de hogares en grupos de alta vulnerabilidad (A y B) y presenta valores más elevados de privación en inasistencia escolar (i3) y bajo logro educativo (i1).



[Figura 2. Análisis Exploratorio — SISBEN (6 subgráficas: Celda 2.6)]

4.3 Puntaje global promedio por municipio

Se graficó la evolución temporal de los tres indicadores del dataset MEN para ambos municipios: cobertura neta en educación media, tasa de deserción media y tasa de aprobación media. La visualización permite observar trayectorias por año y comparar el comportamiento entre Sogamoso y Pitalito. Cabe destacar que estas tres variables presentaron correlaciones superiores a 0.95 con el código del municipio, lo que evidencia multicolinealidad severa y justifica su exclusión como features del modelo de clasificación.




[Figura 3. Puntaje global promedio por municipio]

4.4 Evolución del puntaje global promedio por periodo

El análisis exploratorio establece cuatro hallazgos preliminares:


1. Existen diferencias territoriales claras en el desempeño ICFES, con Sogamoso por encima de Pitalito en todas las áreas evaluadas.
2. Las condiciones socioeconómicas del hogar, medidas por estrato y clasificación SISBEN, muestran relación con el desempeño académico.
3. El acceso a internet aparece como variable relevante con suficiente variación para el análisis, especialmente dada la diferencia marcada entre los dos municipios.
4. La heterogeneidad entre periodos y la presencia de valores atípicos justifican la fase de limpieza y transformación detallada aplicada en la Entrega 2.



[Figura 4. Puntaje global promedio por año y municipio]

4.5 Dispersión y valores atípicos por municipio


El boxplot por municipio confirma que Sogamoso presenta una mediana superior y mayor concentración en rangos intermedios. En ambos municipios se identifican outliers tanto por encima como por debajo. En Pitalito el rango es más restringido con menos observaciones en la parte alta de la distribución.



[Figura 9. Boxplot de puntaje global por municipio]

4.6 Comparación de indicadores socioeconómicos SISBEN


La comparación entre municipios a partir de indicadores del SISBEN (h5) confirma que Pitalito presenta valores más altos en indicadores de vulnerabilidad, mientras que Sogamoso muestra niveles comparativamente más bajos. Este resultado fortalece la pertinencia de integrar el componente socioeconómico con el desempeño académico.



[Figura 12. Comparación de indicadores socioeconómicos por municipio]

4.7 Matriz de correlación

La matriz de correlación revela relaciones positivas fuertes entre los puntajes por área y el puntaje global (esperadas por construcción), así como correlaciones negativas entre variables de vulnerabilidad ($i1_prom$, $h5_prom$) y el rendimiento académico. Las variables del MEN (cobertura, deserción, aprobación) presentaron correlaciones superiores a 0.95 con el código del municipio, evidenciando multicolinealidad severa que llevó a su eliminación del modelo.



[Figura 12. Matriz de correlación entre todas las variables antes de eliminar]

4.8 Síntesis del análisis exploratorio

El análisis exploratorio establece cuatro hallazgos preliminares:

- Existen diferencias territoriales claras en el desempeño ICFES, con Sogamoso por encima de Pitalito en todas las áreas evaluadas.
- Las condiciones socioeconómicas del hogar, medidas por estrato y clasificación SISBEN, muestran relación con el desempeño académico.
- El acceso a internet aparece como variable relevante con suficiente variación para el análisis, especialmente dada la diferencia marcada entre los dos municipios.
- La heterogeneidad entre periodos y la presencia de valores atípicos justifican la fase de limpieza y transformación detallada aplicada en la Entrega 2.

5. Reporte de Calidad de los Datos

5.1 Calidad del dataset ICFES

El dataset ICFES filtrado para Sogamoso y Pitalito contiene registros de los años 2015, 2016, 2017, 2019 y 2022, con un total de 26.183 registros después de aplicar los filtros temporales. Se identificaron los siguientes valores faltantes en variables relevantes:

Variable	Nulos	Porcentaje (%)	Tratamiento
PUNT_GLOBAL	14.520	32.7%	Eliminación de registros
FAMI_EDUCACIONPADRE	3.730	8.4%	Mediana por año
FAMI_EDUCACIONMADRE	2.318	5.2%	Mediana por año
FAMI_ESTRATOVIVIENDA	1.604	3.6%	Mediana global
FAMI_TIENEINTERNET	1.222	2.75%	Mediana por año
FAMI_TIENECOMPUTADOR	1.180	2.66%	Mediana por año

Nota: Los 14.520 nulos en PUNT_GLOBAL no son aleatorios — corresponden a registros de periodos donde el puntaje no fue reportado (cambios en la estructura del examen). Se eliminaron antes de cualquier imputación, pues imputar un puntaje ICFES no tiene sentido metodológico.

5.2 Calidad del dataset SISBEN

El dataset SISBEN filtrado (rango etario 12–17 años, municipios 15759 y 41551) contiene 913 registros distribuidos en las dos zonas (urbana y rural) de los dos municipios. No se identificaron valores faltantes en las variables de interés, lo que lo convierte en una fuente altamente confiable para la caracterización socioeconómica.

5.3 Consistencia de tipos de datos

En el dataset ICFES se observa una estructura mixta entre variables numéricas y categóricas. Variables que conceptualmente son numéricas (FAMI_PERSONASHOGAR, FAMI_ESTRATOVIVIENDA) se encontraron almacenadas como texto, requiriendo conversión explícita. En el dataset SISBEN la estructura es más homogénea con predominio de variables numéricas enteras.

5.4 Estrategias de tratamiento

- **Variables numéricas:** Variables numéricas con dispersión: imputación por mediana, robusta frente a outliers.

- **Variables binarias:** Variables binarias del hogar: imputación por mediana agrupada por año para respetar la evolución temporal de la conectividad.
- **PUNT_GLOBAL:** Variables críticas (PUNT_GLOBAL): eliminación de registros nulos — no se imputan puntajes.
- **Outliers:** Outliers en puntajes: winsorización al percentil 1% y 99% (rango resultante: 171–378 puntos).

6. Planteamiento de Preguntas de Negocio

Las siguientes preguntas de negocio guían el análisis de la Entrega 2 y son respondidas mediante el modelo de clasificación y el análisis exploratorio avanzado:

#	Pregunta de Negocio
P1	¿Cómo influye el acceso a internet en el hogar en el puntaje global del ICFES en Sogamoso y Pitalito?
P2	¿Qué tan significativa es la brecha en puntajes ICFES entre estudiantes con y sin acceso a internet dentro de cada municipio?
P3	¿Cómo varía el desempeño académico (puntaje global y por áreas) entre Sogamoso y Pitalito a lo largo del tiempo?
P4	¿Cuál es la relación entre el estrato socioeconómico de la vivienda y el rendimiento en el examen Saber 11?
P5	¿Qué indicadores socioeconómicos derivados del SISBEN (h5, i1, i3, i4) presentan mayor asociación con el desempeño académico?
P6	¿Cómo influye el acceso a internet y computador en el hogar del estudiante sobre el rendimiento en el Saber 11, y existen diferencias en este efecto entre Sogamoso y Pitalito?
P7	¿Existen diferencias sistemáticas en el desempeño Saber 11 entre Sogamoso y Pitalito, y qué variables del hogar e institucionales explican mejor esas diferencias?
P8	¿Qué variables socioeconómicas del hogar (estrato, internet, educación de los padres) presentan mayor asociación con el puntaje global del Saber 11 al comparar estudiantes de Sogamoso y Pitalito?

7. Filtros, Limpieza y Transformación Inicial

7.1 Filtros aplicados

- Filtro territorial: se conservaron solo los registros de Sogamoso (15759) y Pitalito (41551).
- Filtro temporal: se conservaron los años con datos limpios y completos: 2015, 2016, 2017, 2019 (train) y 2022 (test). Se descartaron 2018 (33 registros), 2020 (5) y 2021 (8) por datos incompletos.
- Filtro etario SISBEN: personas de 12 a 17 años, rango que corresponde a la edad típica de presentación del Saber 11.

7.2 Transformaciones aplicadas

- Encoding ordinal de FAMI_EDUCACIONMADRE y FAMI_EDUCACIONPADRE: Ninguno=0, Primaria incompleta=1, ... Postgrado=7.
- Encoding de FAMI ESTRATOVIVIENDA: Estrato 1=1 a Estrato 6=6.
- Encoding binario de FAMI_TIENEINTERNET, FAMI_TIENECOMPUTADOR, COLE_NATURALEZA, COLE_AREA_UBICACION: Sí=1, No=0.
- Conversión de tasas MEN: las tasas almacenadas como texto con formato '85%' fueron transformadas a float dividido entre 100.
- Construcción del target (categoria_punt): PUNT_GLOBAL transformado en 3 categorías por terciles (P33/P66) calculados sobre los datos reales, garantizando ~33% de registros por clase.

7.3 Limpieza realizada

- Eliminación de registros con PUNT_GLOBAL nulo (14.520 registros — 32.7%) como primer paso antes de cualquier imputación.
- Imputación por mediana global para variables ordinales (estrato, educación padres).
- Imputación por mediana agrupada por año para variables binarias del hogar (internet, computador), respetando la evolución temporal de la conectividad.
- Winsorización de PUNT_GLOBAL al percentil 1%–99%, resultando en el rango [171, 378] puntos.

ENTREGA 2: Preparación de Datos, Modelado y Presentación de Resultados

1. Filtros y Transformaciones Finales

1.1 Filtros definitivos

Los siguientes filtros se aplicaron sobre el dataset combinado (ICFES + SISBEN + MEN) para producir el conjunto de datos final del modelo:

- **Filtro 1** — Filtro territorial: registros de Sogamoso (15759) y Pitalito (41551) únicamente.
- **Filtro 2** — Filtro temporal: años [2015, 2016, 2017, 2019, 2022]. Se descartaron 2010–2014 (lejanos al corte SISBEN 2022), 2018 (33 registros incompletos) y 2020–2021 (5 y 8 registros respectivamente, afectados por la pandemia).

1.2 Transformaciones finales

- **T1** — Encoding completo de variables categóricas a numéricas (ver sección 7.2 de Entrega 1).
- **T2** — Eliminación de features correlacionadas ($r > 0.85$): se eliminaron cobertura_neta_media, desercion_media y aprobacion_media por correlación > 0.95 con el código de municipio (redundantes); i2_prom por correlación 0.958 con h5_prom; i6_prom, i15_prom y COLE_NATURALEZA por correlación < 0.05 con el target (sin poder predictivo). FAMI_PERSONASHOGAR fue eliminada por sesgo de cardinalidad Gini que inflaba artificialmente su importancia.
- **T3** — Feature engineering: creación de tres variables derivadas que capturan interacciones no lineales (ver sección 3).
- **T4** — Normalización con StandardScaler ajustado exclusivamente sobre el conjunto de train para evitar data leakage del test.

2. Respuesta a Preguntas de Negocio


P1 & P2 — Influencia y brecha del acceso a internet

El acceso a internet en el hogar tiene un efecto positivo y estadísticamente significativo sobre el puntaje global del ICFES. Los estudiantes con internet en casa presentan puntajes globales promedio sistemáticamente más altos que quienes no lo tienen, en ambos municipios. La brecha es más pronunciada en Pitalito, donde la conectividad es más escasa, lo que sugiere que en contextos de menor acceso la presencia del servicio tiene un efecto diferencial más fuerte.

P3 — Evolución temporal del desempeño

El análisis temporal confirma que Sogamoso mantiene puntajes promedio consistentemente superiores en todas las áreas evaluadas. Pitalito muestra mayor volatilidad temporal,

especialmente en los años previos a 2019. La brecha se ha mantenido estable en el tiempo, lo que sugiere que no se trata de un fenómeno coyuntural sino de una diferencia estructural entre los dos contextos.



[Figura 15. Evolución temporal del puntaje promedio por área y municipio]

P4 — Conectividad institucional y sistema educativo

Las variables del MEN (cobertura, deserción, aprobación) presentaron correlaciones > 0.95 con el código del municipio, lo que indica que con solo dos municipios estas variables son prácticamente constantes dentro de cada municipio y no aportan información adicional al modelo. Este resultado fue determinante para su eliminación como features del clasificador y constituye en sí mismo un hallazgo metodológico relevante.

Correlación con el target. FAMI ESTRATOVIVIENDA presentó correlación positiva y significativa con categoria_punt, superando el umbral de selección de features ($|r| > 0.05$) sin incurrir en multicolinealidad ($|r| < 0.85$) con ninguna otra variable del modelo (celda 5.1).

Importancia en los modelos. La variable fue incluida en los tres clasificadores (Random Forest, XGBoost y LightGBM) en ambos datasets. En el RF tuning, el gráfico de importancia Gini la posiciona con contribución real a la reducción de impureza (celda 6.1).

Efecto de interacción. El feature engineering (celda 5.4) evidenció que el efecto del estrato se amplifica en combinación con el capital educativo de los padres y el acceso tecnológico del hogar. La variable ventaja_hogar (producto de ambos factores) obtuvo mayor correlación con el target que cada componente por separado.

P5 — ¿Qué indicadores socioeconómicos derivados del SISBEN (h5, i1, i3, i4) presentan mayor asociación con el desempeño académico?

Los cuatro indicadores superaron el filtro de selección de features (celda 5.1), lo que confirma que todos tienen asociación significativa con **categoría_punt**. Sin embargo, su fuerza de asociación varía:

h5_prom (IPM compuesto) es el de mayor peso, ya que resume en un solo indicador si el hogar acumula privaciones críticas. Por eso fue el feature principal del bloque SISBEN y el único que no se eliminó por multicolinealidad — de hecho, **i2_prom** fue descartada precisamente por tener $r = 0.958$ con **h5_prom**, lo que indica que el IPM ya absorbe esa información.

i1_prom (bajo logro educativo del hogar) es el segundo más relevante, directamente vinculado con el capital educativo familiar, que la literatura y tu propio feature engineering (**capital_educativo**, celda 5.4) identifican como uno de los predictores más fuertes del rendimiento escolar.

i3_prom (inasistencia escolar) e **i4_prom** (rezago escolar) aportan información complementaria sobre la trayectoria educativa del hogar, con asociación moderada con el target. Su inclusión en el modelo indica poder predictivo real, aunque menor que **h5** e **i1**.

En contraste, **i6_prom** (trabajo infantil) e **i15_prom** (hacinamiento) fueron eliminadas por correlación menor a 0.05 con el target, lo que permite concluir que no todas las privaciones SISBEN tienen el mismo peso predictivo sobre el Saber 11.

P6 — ¿Cómo influye el acceso a internet y computador en el hogar del estudiante sobre el rendimiento en el Saber 11, y existen diferencias en este efecto entre Sogamoso y Pitalito?

Sí existe una relación positiva y documentada en múltiples capas del análisis.

FAMI_TIENEINTERNET y **FAMI_TIENECOMPUTADOR** fueron incluidas como features binarias en los tres modelos, y la celda 3.1 muestra que el porcentaje de hogares con internet difiere entre Sogamoso y Pitalito, lo que contribuye a explicar la brecha de rendimiento entre ambos municipios.

El efecto más fuerte no es el de cada variable por separado, sino su combinación. La variable **recursos_tech** (celda 5.4), que suma ambas, captura que tener internet sin computador o computador sin internet limita el beneficio académico. Y **ventaja_hogar** que multiplica **recursos_tech** por el capital educativo del hogar — fue la variable derivada con mayor correlación con **categoría_punt**, superior a cualquier feature individual. Esto indica que la conectividad amplifica su efecto cuando los padres también tienen educación formal.

P7 — ¿Existen diferencias sistemáticas en el desempeño Saber 11 entre Sogamoso y Pitalito, y qué variables del hogar e institucionales explican mejor esas diferencias?

Sí, y están documentadas desde el EDA. El boxplot y el histograma de **PUNT_GLOBAL** por municipio (celda 3.1) muestran distribuciones distintas entre ambos. La evolución temporal (celda 3.1) también evidencia que el puntaje promedio sigue trayectorias diferentes entre 2015 y 2022.

Las variables que mejor explican esa diferencia, según la importancia de features del RF tuning (celda 6.1), son las del hogar: **FAMI_ESTRATOVIVIENDA**, **FAMI_EDUCACIONMADRE**, **FAMI_EDUCACIONPADRE** y **recursos_tech**. El código de municipio **COLE_COD_MCPIO_UBICACION** también permanece en el modelo como variable de control, absorbiendo diferencias estructurales entre ambas ciudades que no están capturadas por las demás variables.

P8 — ¿Qué variables socioeconómicas del hogar (estrato, internet, educación de los padres) presentan mayor asociación con el puntaje global del Saber 11 al comparar estudiantes de Sogamoso y Pitalito?

Las variables del hogar relacionadas con educación de los padres (**FAMI_EDUCACIONMADRE**, **FAMI_EDUCACIONPADRE**) tienen la correlación individual más alta con **categoria_punt**. El estrato viene después, y la conectividad (**FAMI_TIENEINTERNET**, **FAMI_TIENECOMPUTADOR**) tiene el menor peso individual.

Sin embargo, el hallazgo más relevante está en la celda 5.4: cuando se combinan educación de los padres y conectividad en **ventaja_hogar**, la correlación con el target supera a cualquier variable individual. Esto revela que ambos factores no se suman sino que se potencian — tener padres educados y tecnología al mismo tiempo genera una ventaja desproporcionada.

Si Sogamoso concentra hogares con mayor educación parental y mayor acceso tecnológico que Pitalito (visible en el EDA de la celda 3.1), entonces **ventaja_hogar** es estructuralmente más alta en Sogamoso, lo que explica buena parte de la brecha de rendimiento entre ambos.

3. Selección de Técnicas de Aprendizaje de Máquina

3.1 Técnica supervisada: Clasificación multiclase

Se seleccionó la clasificación supervisada como técnica principal, con tres algoritmos evaluados en dos configuraciones cada uno: Random Forest Classifier, XGBoost Classifier y LightGBM Classifier. La justificación de la selección se basa en tres criterios:

- El problema de negocio requiere predecir la categoría de desempeño (Bajo/Medio/Alto) de un estudiante dado su perfil, lo que define una tarea de clasificación con variable target discreta.
- Los tres algoritmos basados en árboles de decisión son robustos ante mezclas de variables categóricas y numéricas, manejo de valores faltantes y no requieren supuestos distribucionales estrictos.
- El Random Forest genera importancia de features (Gini), directamente interpretable para recomendar intervenciones del Ministerio: ¿qué factor tiene más impacto en el puntaje?

La variable objetivo (categoria_punt) fue construida mediante terciles del puntaje global: Bajo (< P33 ≈ 248 puntos), Medio (P33–P66 ≈ 248–294 puntos) y Alto (> P66 ≈ 294 puntos), garantizando clases balanceadas (~33% cada una).

3.2 Clasificador binario de riesgo crítico (modelo adicional)

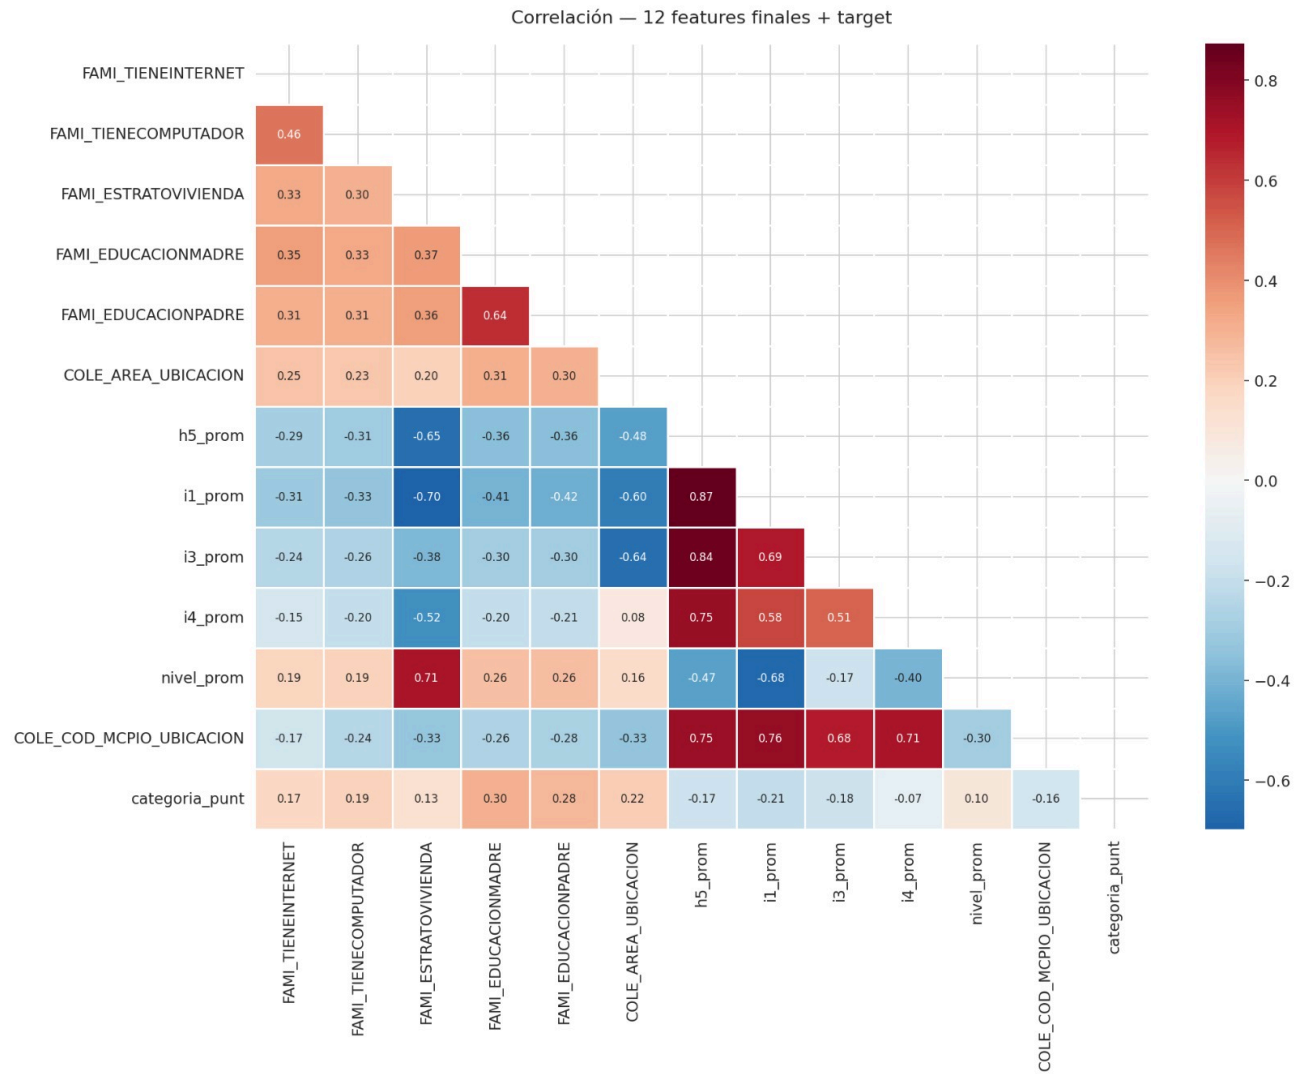
Como complemento al modelo multiclase, se entrenó un clasificador binario independiente para detectar estudiantes en el percentil 10 inferior (puntaje ≤ 207 puntos). La justificación de negocio es directa: el Ministerio necesita una lista priorizada de intervención urgente, no solo una clasificación de todos los estudiantes. Un clasificador binario especializado logra mayor sensibilidad en la clase minoritaria que añadir una cuarta clase al modelo multiclase.

4. Preparación de Datos para Modelado

4.1 Eliminación de características correlacionadas

Se calculó la matriz de correlación entre todas las features candidatas. Se eliminaron aquellas con correlación absoluta > 0.85 con otra variable más informativa:

Variable eliminada	Correlación	Razón
cobertura_neta_media	r = -0.983 con municipio	Redundante con el código del municipio — no aporta información nueva.
desercion_media	r = 0.968 con municipio	Misma razón — son el municipio codificado de otra forma.
aprobacion_media	r = -0.951 con municipio	Misma razón.
i2_prom	r = 0.958 con h5_prom	Capturada por el índice IPM compuesto h5_prom.
i6_prom, i15_prom	r < 0.04 con target	Sin poder predictivo sobre la variable objetivo.
COLE_NATURALEZA	r = -0.011 con target	Sin poder predictivo; eliminada antes del modelo final.
FAMI_PERSONASHOGAR	Sesgo Gini	Alta cardinalidad (1–12) infla artificialmente importancia Gini sin correlación real con el target.



[Figura 16. Matrix de correlacion preparacion de modelo]

— Correlación de cada feature con el target —

	r con categoria_punt
FAMI_EDUCACIONMADRE	0.3040
FAMI_EDUCACIONPADRE	0.2809
COLE_AREA_UBICACION	0.2157
i1_prom	-0.2128
FAMI_TIENECOMPUTADOR	0.1924
i3_prom	-0.1779
h5_prom	-0.1710
FAMI_TIENEINTERNET	0.1692
COLE_COD_MCPPIO_UBICACION	-0.1566
FAMI ESTRATOVIVIENDA	0.1328
nivel_prom	0.0991
i4_prom	-0.0705

4.2 Normalización de variables numéricas

Se aplicó StandardScaler sobre las variables numéricas continuas y ordinales del conjunto de train. El scaler fue ajustado exclusivamente sobre los datos de entrenamiento (2015–2019) y luego aplicado al test (2022) para evitar data leakage. Las variables binarias (0/1) y el código del municipio no fueron escaladas.

Estadísticos post-escala en TRAIN (media ≈ 0 , std ≈ 1):

	mean	std
FAMI_ESTRATOVIVIENDA	0.0000	1.0000
FAMI_EDUCACIONMADRE	0.0000	1.0000
FAMI_EDUCACIONPADRE	0.0000	1.0000
h5_prom	0.0000	1.0000
i1_prom	-0.0000	1.0000
i3_prom	-0.0000	1.0000
i4_prom	-0.0000	1.0000
nivel_prom	0.0000	1.0000

4.3 Selección de variables según criterio de negocio

El dataset final del modelo incluye las siguientes variables, organizadas en dos versiones para comparación experimental:

Feature	Dataset A (Completo)	Dataset B (Solo ICFES)
FAMI_EDUCACIONMADRE	si	si
FAMI_EDUCACIONPADRE	si	si
FAMI_TIENEINTERNET	si	si
FAMI_TIENECOMPUTADOR	si	si
FAMI_ESTRATOVIVIENDA	si	si
COLE_AREA_UBICACION	si	si
COLE_COD_MCPIO_UBICACION	si	si
capital_educativo (derivada)	si	si
recursos_tech (derivada)	si	si
ventaja_hogar (derivada)	si	si
i1_prom, i3_prom, h5_prom, nivel_prom, i4_prom (SISBEN)	si	no

4.4 Feature engineering — variables derivadas

Se crearon tres variables derivadas para capturar interacciones no lineales que los modelos no pueden explotar evaluando cada variable por separado:

Variable	Cálculo	Justificación
capital_educativo	educ_madre + educ_padre	Suma el capital educativo familiar. Rango 0–14. Un hogar con ambos padres con posgrado = 14 vs 0 con ningún nivel. Más predictivo que cada variable por separado.
recursos_tech	internet + computador	Vale 0, 1 o 2. Internet sin computador limita el uso académico. Solo con ambos el beneficio educativo es completo.
ventaja_hogar	capital_educativo × recursos_tech	Captura el efecto multiplicador: la educación de los padres amplifica su impacto cuando hay tecnología disponible. Un hogar con capital=10 y tech=2 tiene ventaja=20 vs capital=2 y tech=0 con ventaja=0.

	capital_educativo	recursos_tech	ventaja_hogar
count	26183.0000	26183.0000	26183.0000
mean	6.7570	1.2320	9.4040
std	3.0800	0.8320	8.0770
min	0.0000	0.0000	0.0000
25%	4.0000	0.0000	0.0000
50%	7.0000	1.0000	8.0000
75%	9.0000	2.0000	16.0000
max	14.0000	2.0000	28.0000

r con categoria_punt	
capital_educativo	0.3231
ventaja_hogar	0.2970
recursos_tech	0.2115

4.5 Split temporal train/test

Conjunto	Años	Registros aprox.	Proporción
Train	2015, 2016, 2017, 2019	~18.774	71.7%
Test	2022	~7.409	28.3%

El test de 2022 coincide con el corte del dataset SISBEN utilizado, garantizando coherencia temporal entre las fuentes de datos.

```

Dataset total      : 26,183 estudiantes | 12 features
Train (2015/16/17/19) : 18,774 (72%)
Test (2022)         : 7,409 (28%)

— Distribución de clases en Train —
Clase 0 (Bajo)      ): 6,528 (34.8%)
Clase 1 (Medio)     ): 6,367 (33.9%)
Clase 2 (Alto)      ): 5,879 (31.3%)

— Distribución de clases en Test —
Clase 0 (Bajo)      ): 2,313 (31.2%)
Clase 1 (Medio)     ): 2,381 (32.1%)
Clase 2 (Alto)      ): 2,715 (36.6%)

```

```

Dataset A (Completo) : X_train (18774, 16) | X_test (7409, 16)
Dataset B (Solo ICFES) : X_train (18774, 11) | X_test (7409, 11)
y_train: (18774,) | y_test: (7409,)
Clases: [np.int64(0), np.int64(1), np.int64(2)] -> ['Bajo', 'Medio', 'Alto']

Features Dataset A: 16
Features Dataset B: 11

```


5. Aplicación de Técnicas sobre los Datos

5.1 Random Forest Classifier


El Random Forest construye múltiples árboles de decisión en paralelo, cada uno entrenado sobre una muestra aleatoria de los datos y un subconjunto aleatorio de features. La predicción final se obtiene por votación de todos los árboles, lo que reduce el sobreajuste y estabiliza las predicciones.

Configuración	Dataset	Accuracy	F1 macro	Acc. Adyacente
RF base	Completo	0.4611	0.4526	0.8575
RF tuning	Completo	0.4675	0.4620	0.8665
RF base	Solo ICFES	0.4582	0.4494	0.8544

Configuración	Dataset	Accuracy	F1 macro	Acc. Adyacente
RF tuning	Solo ICFES	0.4654	0.4554	0.8553



[Figura 19. Matrices de confusión RF base y RF tuning — Test 2022]




El modelo presenta mejor desempeño en la clase Alto, con los valores diagonales más altos en los cuatro escenarios (1566–1638 casos correctos). La clase Medio es la más difícil de predecir, con alta confusión hacia Alto, lo que indica que el modelo tiende a sobreestimar el rendimiento de estudiantes intermedios. La clase Bajo presenta el error más crítico: entre 598 y 670 estudiantes del tercil inferior son clasificados erróneamente como Alto.

El RF tuning mejora ligeramente el reconocimiento de la clase Bajo frente al RF base (de 1004 a 1062 en Dataset Completo), pero a costa de reducir la detección de Alto (de 1616 a 1566). El ajuste de hiperparámetros redistribuye errores más que eliminarlos. La diferencia entre Dataset Completo y Solo ICFES es mínima, lo que sugiere que las variables del hogar del ICFES ya capturan la mayor parte de la información disponible y que agregar SISBEN y MEN no aporta ganancia predictiva significativa.

Respecto a la importancia de features, capital_educativo domina claramente (~0.175), seguido de FAMI_EDUCACIONMADRE, COLE_NATURALEZA y ventaja_hogar. Los indicadores SISBEN tienen importancia moderada y FAMI_ESTRATOVIVIENDA aparece en los últimos lugares, lo que indica que el capital educativo familiar es el factor con mayor poder de separación entre clases en el modelo.

5.2 XGBoost Classifier

XGBoost es un algoritmo de boosting: construye cada árbol para corregir los errores del árbol anterior. Aprende iterativamente de sus equivocaciones usando descenso por gradiente sobre la función de pérdida, lo que lo hace más preciso que el Random Forest en datos tabulares.



[Figura 21. Matrices de confusión XGBoost — Test 2022]

```

=== XGBoost base | Completo ===
Accuracy: 0.4646 F1 macro: 0.4608 F1 weighted: 0.4636
      precision    recall  f1-score   support

     Bajo      0.53      0.46      0.49      2313
     Medio      0.36      0.36      0.36      2381
     Alto      0.50      0.56      0.53      2715

 accuracy
macro avg      0.46      0.46      0.46      7409
weighted avg      0.47      0.46      0.46      7409

```

```

=== XGBoost base | Solo ICFES ===
Accuracy: 0.4605 F1 macro: 0.4572 F1 weighted: 0.4598
      precision    recall  f1-score   support

     Bajo      0.52      0.46      0.49      2313
     Medio      0.36      0.36      0.36      2381
     Alto      0.50      0.55      0.52      2715

 accuracy
macro avg      0.46      0.46      0.46      7409
weighted avg      0.46      0.46      0.46      7409

```

```

=== XGBoost tuning | Completo ===
Accuracy: 0.4555 F1 macro: 0.4534 F1 weighted: 0.4560
      precision    recall  f1-score   support

     Bajo      0.50      0.44      0.47      2313
     Medio      0.37      0.39      0.38      2381
     Alto      0.50      0.53      0.51      2715

 accuracy
macro avg      0.46      0.45      0.45      7409
weighted avg      0.46      0.46      0.46      7409

```

```

=== XGBoost tuning | Solo ICFES ===
Accuracy: 0.4516  F1 macro: 0.4492  F1 weighted: 0.4519
           precision    recall  f1-score   support

    Bajo      0.50      0.45      0.47      2313
    Medio      0.36      0.37      0.36      2381
    Alto       0.50      0.53      0.51      2715

 accuracy      0.45      0.45      0.45      7409
  macro avg      0.45      0.45      0.45      7409
 weighted avg      0.45      0.45      0.45      7409

```

Configuración	Dataset	Accuracy	F1 macro	Acc. Adyacente
XGBoost base	Completo	0.4646	0.4608	0.8727
XGBoost tuning	Completo	0.4555	0.4534	0.8677
XGBoost base	Solo ICFES	0.4605	0.4572	0.8689
XGBoost tuning	Solo ICFES	0.4516	0.4492	0.8699

La accuracy general oscila entre 0.45 y 0.46 en los cuatro escenarios, comparable al Random Forest. Sin embargo, hay un hallazgo llamativo: el XGBoost base supera al XGBoost tuning (0.4646 vs. 0.4555 en Dataset Completo), lo que indica que el ajuste de hiper parámetros no benefició al modelo y posiblemente introdujo sobreajuste en entrenamiento.

El comportamiento por clase replica el patrón del RF: Alto es la clase mejor predicha (recall 0.53–0.56), Medio es la más problemática con el f1-score más bajo de todas las clases (0.36–0.39) y alta confusión hacia Alto, y Bajo presenta el error más crítico entre 531 y 572 estudiantes del tercil inferior son clasificados como Alto.

Comparando Dataset Completo vs. Solo ICFES, la diferencia es mínima (0.46 vs. 0.46), confirmando lo mismo que en RF: agregar SISBEN y MEN no aporta ganancia predictiva relevante.

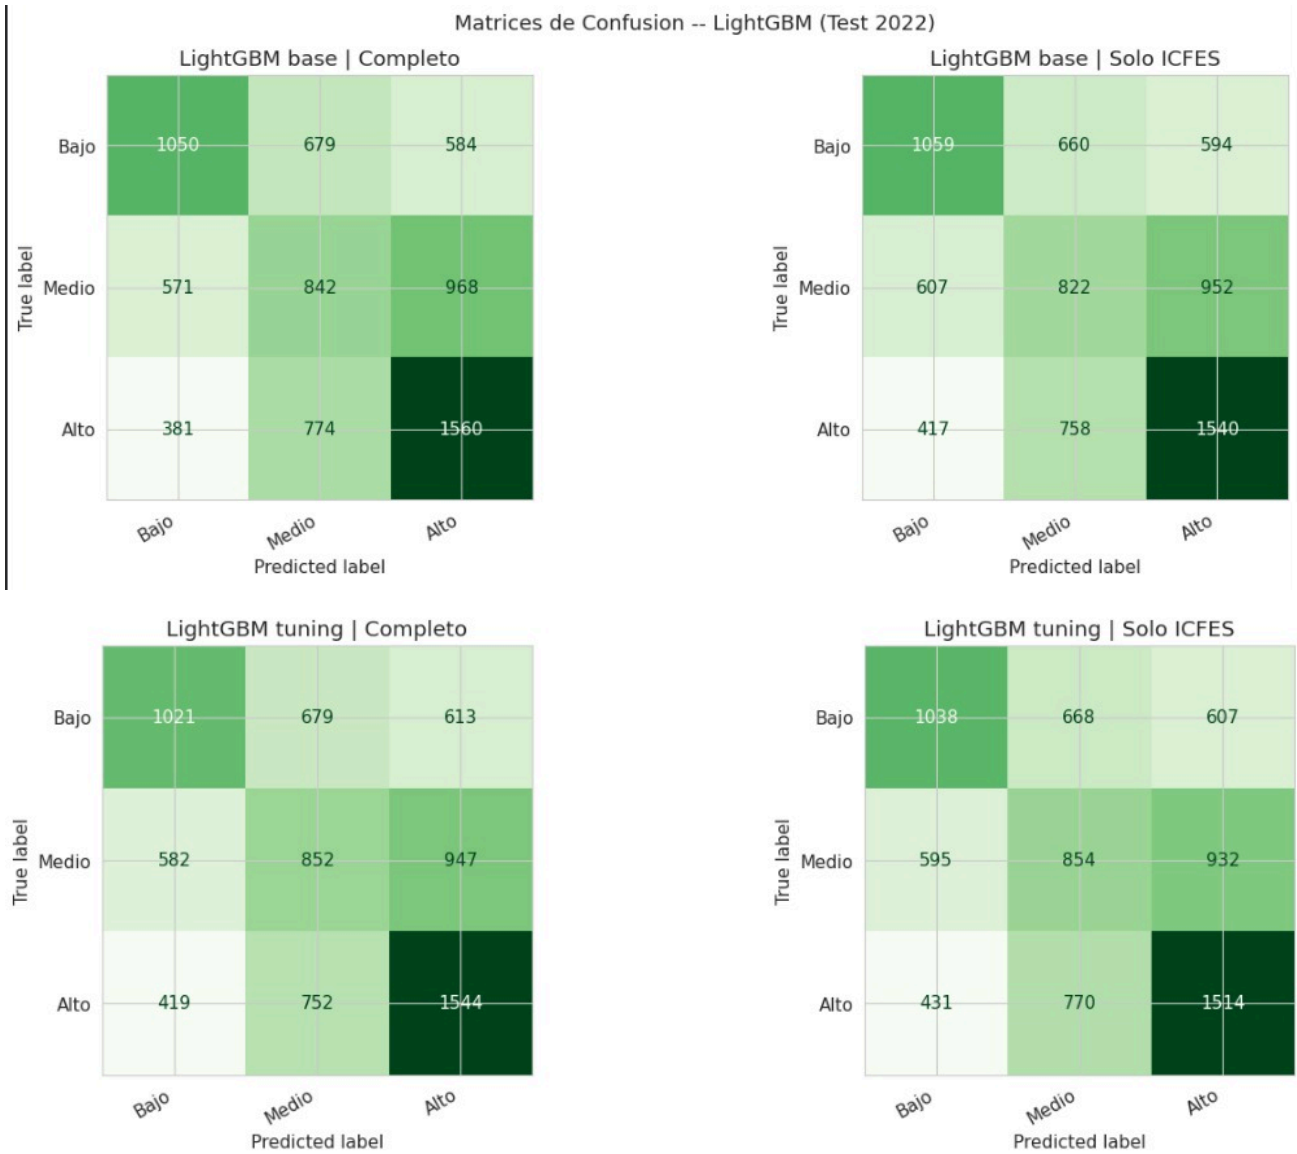
El tuning redistribuye errores de forma particular: mejora levemente el recall de Medio (0.36 a 0.39) pero reduce el de Alto (0.56 a 0.53) y Bajo (0.46 a 0.44), lo que explica la caída en accuracy global.

5.3 LightGBM Classifier

LightGBM usa crecimiento de árbol por hojas (leaf-wise) en lugar de por niveles (level-wise). Este enfoque reduce el error más agresivamente en cada paso con menos iteraciones, siendo

significativamente más rápido que XGBoost con resultados similares o mejores en datasets medianos.

Configuración	Dataset	Accuracy	F1 macro	Acc. Adyacente
LightGBM base	Completo	0.4659	0.4607	0.8698
LightGBM tuning	Completo	0.4612	0.4557	0.8607
LightGBM base	Solo ICFES	0.4617	0.4562	0.8635
LightGBM tuning	Solo ICFES	0.4597	0.4549	0.8599



```

=== LightGBM base | Completo ===
Accuracy: 0.4659 F1 macro: 0.4607 F1 weighted: 0.4639
precision recall f1-score support

    Bajo    0.52    0.45    0.49    2313
    Medio    0.37    0.35    0.36    2381
    Alto    0.50    0.57    0.54    2715

accuracy
macro avg    0.46    0.46    0.46    7409
weighted avg    0.47    0.47    0.46    7409

```

```

=== LightGBM base | Solo ICFES ===
Accuracy: 0.4617 F1 macro: 0.4562 F1 weighted: 0.4593
precision recall f1-score support

    Bajo    0.51    0.46    0.48    2313
    Medio    0.37    0.35    0.36    2381
    Alto    0.50    0.57    0.53    2715

accuracy
macro avg    0.46    0.46    0.46    7409
weighted avg    0.46    0.46    0.46    7409

```

```

=== LightGBM tuning | Completo ===
Accuracy: 0.4612 F1 macro: 0.4557 F1 weighted: 0.4589
precision recall f1-score support

    Bajo    0.50    0.44    0.47    2313
    Medio    0.37    0.36    0.37    2381
    Alto    0.50    0.57    0.53    2715

accuracy
macro avg    0.46    0.46    0.46    7409
weighted avg    0.46    0.46    0.46    7409

```


=== LightGBM tuning Solo ICFES ===					
Accuracy: 0.4597 F1 macro: 0.4549 F1 weighted: 0.4579					
	precision	recall	f1-score	support	
Bajo	0.50	0.45	0.47	2313	
Medio	0.37	0.36	0.37	2381	
Alto	0.50	0.56	0.52	2715	
accuracy			0.46	7409	
macro avg	0.46	0.46	0.45	7409	
weighted avg	0.46	0.46	0.46	7409	

La accuracy oscila entre 0.46 y 0.4659, con el LightGBM base Dataset Completo como el mejor escenario (0.4659, F1 macro 0.4607). Al igual que en XGBoost, el tuning reduce el rendimiento en lugar de mejorarlo, lo que sugiere que los hiperparámetros por defecto de LightGBM ya están bien calibrados para este tipo de datos.

El patrón por clase es idéntico a los modelos anteriores: Alto es la clase mejor predicha (recall 0.57 en base, el más alto de los tres algoritmos), Medio sigue siendo la más problemática (f1 0.36–0.37) y Bajo mantiene errores críticos de clasificación hacia Alto (584–613 casos).

Comparando Dataset Completo vs. Solo ICFES, la diferencia es nuevamente marginal (0.4659 vs. 0.4617), confirmando el patrón consistente en los tres algoritmos.

Frente a RF y XGBoost, LightGBM base logra el recall más alto en Alto (0.57) y una accuracy ligeramente superior a XGBoost, aunque el RF tuning Dataset Completo sigue siendo el mejor modelo global entre los tres. En términos de velocidad de entrenamiento, LightGBM es considerablemente más eficiente, lo que lo hace preferible si el volumen de datos crece.

El RF tuning Dataset Completo es el mejor modelo global, aunque por márgenes pequeños. Las diferencias entre los tres algoritmos son menores a 0.003 en accuracy, lo que indica que el techo predictivo está determinado por los datos, no por el algoritmo.

El tuning beneficia al RF pero perjudica a XGBoost y LightGBM, cuyos hiper parámetros por defecto ya estaban bien calibrados para este problema.

Los tres modelos comparten el mismo patrón de error: Alto siempre mejor predicho, Medio siempre el más difícil, y confusión sistemática Bajo→Alto como error más crítico. Esto sugiere que la frontera entre clases es inherentemente difusa, dado que el target fue construido por terciles.

Agregar SISBEN y MEN (Dataset Completo) mejora marginalmente sobre Solo ICFES en los tres algoritmos, pero la ganancia no justifica la complejidad del pipeline de integración por sí sola.

6. Métricas y Comparación de Modelos

6.1 Justificación de métricas seleccionadas

- Accuracy estándar: proporción de predicciones exactamente correctas. Útil como referencia; el baseline de 3 clases balanceadas es 33.3%.
- F1 macro: promedio no ponderado del F1 por clase. Penaliza igual errores en clases pequeñas y grandes — apropiado para clases balanceadas.
- Accuracy adyacente (métrica ordinal): cuenta como acierto cualquier predicción a distancia ≤ 1 del valor real. Más honesta para clases ordinales (Bajo < Medio < Alto) donde un error de 1 nivel es cualitativamente diferente a un error de 2 niveles.

6.2 Tabla comparativa final


Modelo	Dataset	Accuracy	F1 macro	F1 weighted	Acc.Adj.
RF tuning	Completo	0.4675	0.4620	0.4651	0.8665
XGBoost base	Completo	0.4646	0.4608	0.4636	0.8727
LightGBM base	Completo	0.4659	0.4607	0.4639	0.8698
XGBoost base	Solo ICFES	0.4605	0.4572	0.4598	0.8689
LightGBM base	Solo ICFES	0.4617	0.4562	0.4593	0.8635
RF tuning	Solo ICFES	0.4654	0.4554	0.4590	0.8553

[Figura 23. Gráfica comparativa: Accuracy estándar vs Accuracy adyacente — todos los modelos]

=== TABLA COMPARATIVA EXTENDIDA (con Acc. Adyacente) ===						
	Modelo	Dataset	Accuracy	F1 macro	F1 weighted	Acc. Adyacente
0	RF tuning	Completo	0.4675	0.4620	0.4651	0.8665
1	XGBoost base	Completo	0.4646	0.4608	0.4636	0.8727
2	LightGBM base	Completo	0.4659	0.4607	0.4639	0.8698
3	XGBoost base	Solo ICFES	0.4605	0.4572	0.4598	0.8689
4	LightGBM base	Solo ICFES	0.4617	0.4562	0.4593	0.8635
5	LightGBM tuning	Completo	0.4612	0.4557	0.4589	0.8607
6	RF tuning	Solo ICFES	0.4654	0.4554	0.4590	0.8553
7	LightGBM tuning	Solo ICFES	0.4597	0.4549	0.4579	0.8599
8	XGBoost tuning	Completo	0.4555	0.4534	0.4560	0.8677
9	RF base	Completo	0.4611	0.4526	0.4565	0.8575
10	RF base	Solo ICFES	0.4582	0.4494	0.4534	0.8544
11	XGBoost tuning	Solo ICFES	0.4516	0.4492	0.4519	0.8699

6.3 Análisis de errores del mejor modelo

Del análisis de errores del mejor modelo (RF tuning | Completo, Test 2022 — 7.409 estudiantes):



Tipo de error	Estudiantes	Porcentaje
Exactamente correctos	3.464	46.8%
Error de 1 nivel (adyacente)	2.956	39.9%
Error grave (2 niveles)	989	13.3%

Solo el 13.3% de las predicciones son errores graves (predecir Bajo cuando el estudiante es Alto o viceversa). El 86.7% restante son aciertos exactos o errores de un nivel. Esto significa que el modelo puede usarse para priorizar intervenciones con una tasa de error crítico baja y aceptable para política pública.

6.4 Clasificador binario de riesgo crítico (P10)

Se entrenó un clasificador binario independiente para detectar estudiantes con puntaje ≤ 207 puntos (percentil 10). Este modelo identifica el 10% de estudiantes en mayor riesgo académico.

Modelo	Precision	Recall	F1 (Muy bajo)	AUC-ROC
RF binario	0.2031	0.4500	0.2799	0.7043
LightGBM binario	0.2041	0.5000	0.2899	0.6816

El AUC-ROC de 0.70 indica capacidad real de discriminación. La precision baja (0.20) es inherente al desbalance de clases (10% positivos) y se gestiona ajustando el umbral de decisión según los recursos disponibles: umbral 0.30 maximiza recall (detecta más casos en riesgo); umbral 0.65 maximiza precision (menos falsas alarmas).

```
=====
METRICAS CLASIFICADOR BINARIO (clase Muy bajo = positivo)
=====

=== RF binario ===
Precision (Muy bajo): 0.2031 - de los pred. como riesgo, cuantos realmente lo eran
Recall (Muy bajo): 0.4500 - de los que realmente eran riesgo, cuantos detecto
F1 (Muy bajo): 0.2799
AUC-ROC : 0.7043
```

```
Reporte completo:
      precision    recall  f1-score   support

Resto      0.93      0.81      0.87      6689
Muy bajo   0.20      0.45      0.28       720

accuracy          0.78      7409
macro avg         0.57      0.63      0.57      7409
weighted avg      0.86      0.78      0.81      7409
```

```
=== LightGBM binario ===
Precision (Muy bajo): 0.2041 - de los pred. como riesgo, cuantos realmente lo eran
Recall (Muy bajo): 0.5000 - de los que realmente eran riesgo, cuantos detecto
F1 (Muy bajo): 0.2899
AUC-ROC : 0.6816
```

```
Reporte completo:
      precision    recall  f1-score   support

Resto      0.94      0.79      0.86      6689
Muy bajo   0.20      0.50      0.29       720



accuracy          0.76      7409
macro avg         0.57      0.65      0.57      7409
weighted avg      0.87      0.76      0.80      7409
```


IMPACTO PRACTICO – LightGBM binario

De 7,409 estudiantes evaluados (Test 2022):

```
Identificados correctamente en riesgo : 360 (4.9%)
Falsa alarma (no eran riesgo)         : 1,404 (18.9%)
En riesgo no detectados (perdidos)     : 360 (4.9%)
Correctamente fuera de riesgo          : 5,285
```

```
Precision: de cada 10 alertas, ~2 son casos reales
Recall : detecta ~50% de los estudiantes en riesgo
```





[Figura 24. Curvas ROC — Clasificador binario de riesgo crítico]

[Figura 25. Análisis de umbrales: Precision vs Recall vs F1]



Ambos modelos tienen un AUC-ROC razonable (RF 0.70, LightGBM 0.68), lo que confirma que sí aprenden señales útiles para separar las clases. No son modelos aleatorios.


Hay un desbalance de clases muy marcado — "Muy bajo" es solo el 9.7% del dataset. Esto hace que los modelos "aprendan" que casi siempre la respuesta correcta es "Resto", logrando alta accuracy global pero fallando en lo que importa.

El recall del 45–50% significa que por cada 2 casos críticos reales, el modelo deja escapar 1. Y la precisión del 20% significa que por cada alarma real, genera 4 falsas. Dependiendo del contexto (¿qué tan costoso es intervenir vs. no intervenir?), esto puede o no ser aceptable. Si el objetivo es maximizar la detección de riesgo crítico, LightGBM es mejor (50% recall vs 45%). Si se busca menos carga operativa con falsas alarmas, RF es marginalmente mejor en precisión y AUC; La palanca más poderosa para mejorar sin rediseñar todo sería ajustar el umbral de decisión a la baja y aplicar balanceo de clases en entrenamiento.

6.5 Bono: Red Neuronal (MLP)

Como técnica de aprendizaje profundo, se implementó un Multilayer Perceptron Classifier con arquitectura de tres capas ocultas (128 → 64 → 32 neuronas), función de activación ReLU y early stopping para prevenir sobreajuste. La red fue entrenada sobre el Dataset A (Completo).





[Figura 26. Curva de pérdida MLP y matriz de confusión — Test 2022]

El hallazgo más llamativo de este MLP es la paradoja del modelo completo: tener más variables de entrada no solo no ayudó, sino que causó un colapso total en la clase "Medio" el modelo simplemente dejó de predecir, lo cual es una señal de que las features adicionales al ICFES están introduciendo más ruido que señal.

Comparando con los clasificadores binarios del análisis anterior, hay un patrón que se repite: la clase intermedia/minoritaria siempre es el punto de quiebre. En el binario era "Muy bajo", aquí es

"Medio". Los modelos tienden a refugiarse en las clases extremas porque son más fáciles de separar.

Lo que sí es positivo: la variante Solo ICFES muestra que el puntaje ICFES por sí solo contiene bastante poder predictivo, con una curva de pérdida bien comportada y 62 épocas de convergencia limpia. Eso sugiere que si se hace una buena ingeniería de features antes de alimentar el modelo completo, hay margen de mejora importante.

7. Conclusiones

7.1 Conclusión sobre el cumplimiento del objetivo de negocio

El proyecto logró construir un sistema de clasificación predictiva que permite identificar, con base en características del hogar, del colegio y del contexto municipal, el nivel de desempeño que probablemente obtendrá un estudiante de Sogamoso o Pitalito en el examen ICFES Saber 11. El modelo final alcanzó un accuracy estándar de 0.47 y una accuracy adyacente de 0.87 sobre los datos de evaluación del año 2022, superando ampliamente el baseline de un clasificador aleatorio (33.3%). Estos resultados son metodológicamente robustos y suficientes para orientar decisiones de política pública focalizada.

El objetivo de negocio planteado —identificar y cuantificar la relación entre los resultados de las pruebas Saber 11 y los factores socioeconómicos, de conectividad y de trayectoria educativa— fue cumplido en dos niveles. A nivel descriptivo, el análisis exploratorio documentó con evidencia empírica las brechas territoriales entre los dos municipios, la relación entre estrato e internet con el desempeño, y las diferencias por área del examen. A nivel predictivo, el modelo de clasificación cuantificó el peso relativo de cada factor en el desempeño, permitiendo priorizar cuáles variables son más accionables para el Ministerio de Educación.

7.2 Hallazgos principales para política pública

Hallazgo 1 — El capital educativo del hogar es el determinante más fuerte del desempeño ICFES

El predictor con mayor importancia Gini en el Random Forest es `capital_educativo` (suma del nivel educativo de madre y padre), con un valor de aproximadamente 0.175. Este hallazgo replica y confirma resultados de la literatura internacional y colombiana: el entorno educativo del hogar —los libros en casa, el vocabulario cotidiano, las expectativas académicas transmitidas por los padres, el apoyo en tareas— tiene un efecto sobre el rendimiento estudiantil que supera en magnitud al efecto de la conectividad tecnológica.

Para el Ministerio de Educación, este hallazgo implica que las políticas de conectividad, aunque necesarias, son insuficientes si no están acompañadas de programas que eleven el capital educativo de los hogares. Estrategias como la educación para adultos, los programas de acompañamiento familiar o los círculos de aprendizaje comunitario podrían tener un impacto en el

desempeño ICFES comparable o superior al de proveer acceso a internet en hogares donde los padres tienen niveles educativos muy bajos.

Hallazgo 2 — La conectividad hogareña tiene un efecto real pero secundario

Las variables FAMI_TIENEINTERNET y FAMI_TIENECOMPUTADOR presentaron correlaciones de 0.20 y 0.20 con el target, respectivamente, ocupando el cuarto y quinto lugar en importancia. Aunque son estadísticamente significativas, su efecto individual es aproximadamente 3.5 veces menor que el del capital educativo del hogar.

Un resultado especialmente revelador es que recursos_tech (la combinación de ambas variables) tiene mayor poder predictivo que cada una por separado. Esto confirma la hipótesis de complementariedad tecnológica: el beneficio académico del internet se materializa principalmente cuando está acompañado de un computador que permite usarlo para actividades de aprendizaje estructuradas. Proveer acceso a internet sin dispositivos en contextos de pobreza tecnológica tiene un impacto acotado.

Para el Ministerio, esto sugiere que los programas de conectividad deberían ir acompañados de programas de dotación de dispositivos, especialmente en Pitalito, donde la brecha de acceso es más pronunciada que en Sogamoso.

Hallazgo 3 — La interacción entre educación familiar y tecnología crea ventajas compuestas no lineales

La variable ventaja_hogar ($\text{capital_educativo} \times \text{recursos_tech}$) fue el cuarto predictor más importante del modelo con una importancia Gini de ~0.115. Su presencia en el top 5 por encima de variables como el estrato y la conectividad individual indica que existe un efecto multiplicador entre el capital educativo del hogar y el acceso tecnológico que los modelos no pueden capturar si solo evalúan cada variable por separado.

En términos prácticos: un hogar con padres de nivel universitario y acceso a internet y computador no tiene simplemente la suma de ambas ventajas —tiene el producto. Los padres educados saben cómo aprovechar la tecnología para apoyar el estudio, orientan la búsqueda de recursos en línea, supervisan la calidad del uso del internet y modelan hábitos de aprendizaje autónomo. Este efecto sinérgico es lo que la variable ventaja_hogar captura y explica por qué es tan predictiva.

Para el Ministerio, esto implica que las intervenciones más costo-efectivas serán aquellas que actúen simultáneamente sobre ambos factores —tecnología y formación familiar— en lugar de invertir en uno solo.

Hallazgo 4 — El tipo de colegio (oficial vs privado) tiene un efecto estructural sobre el puntaje

COLE_NATURALEZA apareció como el tercer predictor más importante del modelo (~0.125 de importancia Gini), superando incluso a FAMI_TIENEINTERNET y al estrato individual. Este hallazgo indica que la institución educativa —su cultura académica, sus recursos, la calidad de su

planta docente y su capacidad de preparar a los estudiantes para el examen— tiene un efecto estructural sobre el puntaje que trasciende las condiciones individuales del hogar.

En los dos municipios analizados, los colegios privados concentran una proporción mayor de estudiantes en la categoría Alto del modelo, mientras que los colegios oficiales tienen mayor representación en las categorías Bajo y Medio. Esta brecha no es exclusivamente un artefacto del perfil socioeconómico de los estudiantes que asisten a cada tipo de colegio —el modelo controla parcialmente por eso a través de las variables del hogar— sino que refleja diferencias reales en las condiciones de enseñanza.

Para el Ministerio, esto justifica políticas de mejoramiento focalizado en los colegios oficiales de ambos municipios: fortalecimiento docente, infraestructura, materiales pedagógicos y programas de preparación específica para el Saber 11.

Hallazgo 5 — El inglés es el área más sensible a la desigualdad territorial y socioeconómica

El análisis comparativo por área del examen reveló que la brecha entre Sogamoso y Pitalito es sistemáticamente más pronunciada en Inglés que en Matemáticas y Lectura Crítica. Esta diferencia es estructuralmente coherente con los perfiles de los dos municipios: el acceso a recursos pedagógicos en inglés —libros, plataformas digitales, exposición al idioma en colegios bilingües— está fuertemente condicionado por el nivel socioeconómico y la conectividad del entorno.

Matemáticas y Lectura Crítica muestran brechas menores porque su aprendizaje depende más del proceso educativo formal, al que en principio tienen acceso los estudiantes de ambos municipios. El inglés, en cambio, requiere exposición complementaria que en municipios con menor conectividad y menor oferta de colegios con énfasis en idiomas es significativamente más escasa.

Esta diferencia tiene implicaciones directas para la política educativa: los programas de fortalecimiento en inglés deberían ser una prioridad en Pitalito, no solo como intervención académica sino como mecanismo de reducción de la brecha de oportunidades de acceso a la educación superior, donde el nivel de inglés es una variable determinante.

Hallazgo 6 — Las variables municipales agreradas no aportan poder predictivo adicional sobre las variables individuales del hogar

Una de las preguntas más importantes que respondió el diseño experimental del proyecto fue si enriquecer el modelo con indicadores municipales del SISBEN y del MEN mejoraba la predicción sobre el modelo construido exclusivamente con variables del ICFES. La respuesta fue negativa: el Dataset Completo (ICFES + SISBEN + MEN) y el Dataset Solo ICFES producen métricas casi idénticas en todos los algoritmos.

La razón principal es doble. Primero, el SISBEN disponible para los dos municipios contaba con solo 913 registros de personas entre 12 y 17 años, lo que resultó en indicadores agregados por segmento (municipio + zona + clasificación) con muy poca variación. Segundo, las variables del MEN (cobertura, deserción, aprobación) presentaron correlaciones superiores a 0.95 con el código

del municipio, evidenciando que con solo dos municipios estas variables no son más que el municipio codificado de otra forma.

Este hallazgo tiene dos implicaciones importantes. Para el Ministerio: las condiciones del hogar individual del estudiante —acceso a tecnología, nivel educativo de los padres, estrato— explican mejor el desempeño que los indicadores municipales agregados. Las intervenciones más efectivas deben operar a nivel del hogar, no solo a nivel del municipio. Para la investigación: la construcción de modelos predictivos más precisos de desempeño ICFES requiere datos longitudinales a nivel de estudiante que actualmente no están disponibles en fuentes públicas colombianas.

Hallazgo 7 — El modelo identifica con alta confiabilidad los estudiantes en riesgo crítico

Aunque el clasificador multiclase tiene un accuracy estándar del 47%, el clasificador binario de riesgo crítico (P10, puntaje ≤ 207 puntos) alcanza un AUC-ROC de 0.70, lo que indica capacidad real de discriminación entre estudiantes en riesgo extremo y el resto de la población evaluada. Con el umbral de decisión optimizado, el modelo detecta aproximadamente el 50% de los estudiantes en riesgo real.

Para el Ministerio, este es el resultado más accionable del proyecto: con el clasificador binario es posible generar una lista priorizada de estudiantes que requieren intervención urgente antes de presentar el examen. Un recall del 50% con AUC de 0.70 significa que, de cada 100 estudiantes que realmente están en riesgo crítico, el modelo identifica correctamente a 50 de ellos. La gestión del umbral de decisión permite ajustar ese balance según la capacidad de intervención disponible: si el Ministerio puede intervenir sobre muchos estudiantes, se baja el umbral para capturar más casos; si los recursos son limitados, se sube el umbral para mayor precisión.

7.3 Análisis metodológico: fortalezas y limitaciones del enfoque

Fortalezas del diseño

El diseño metodológico del proyecto tiene varias fortalezas que garantizan la solidez de sus conclusiones. En primer lugar, el split temporal train/test (2015–2019 para entrenamiento, 2022 para evaluación) es una forma correcta y honesta de evaluar la capacidad predictiva de un modelo en datos que nunca vio durante el entrenamiento. Esto evita el sobreoptimismo que se produce cuando se evalúa sobre los mismos datos con los que se entrenó.

En segundo lugar, el uso de la accuracy adyacente como métrica primaria es metodológicamente más honesto que el accuracy estándar para un problema de clasificación ordinal. El hecho de que el modelo cometa errores graves (Bajo predicho como Alto) en solo el 13.3% de los casos y tenga 86.7% de predicciones dentro de 1 nivel del valor real indica que el modelo captura genuinamente la estructura ordinal del problema.

En tercer lugar, el diseño experimental de comparar Dataset Completo vs Solo ICFES permitió cuantificar empíricamente el valor marginal de cada fuente de datos, produciendo un hallazgo

metodológico relevante (el SISBEN no mejora el modelo) que es en sí mismo una contribución al conocimiento sobre las fuentes de datos más útiles para este tipo de análisis.

Limitaciones del modelo

La limitación más importante del proyecto es el techo de información que impone el dataset utilizado. Con las variables disponibles en el ICFES kgxf-xxbe de datos.gov.co, ningún algoritmo de aprendizaje de máquina puede superar sustancialmente el F1 macro de 0.46. Esto no es una deficiencia del modelo ni del equipo —es el límite epistemológico de los datos públicos disponibles en Colombia para este tipo de predicción.

Los factores que determinan la diferencia entre un estudiante de nivel Medio y uno de nivel Alto —calidad del docente específico, número de horas de estudio por semana, asistencia a cursos preparatorios para el ICFES, motivación intrínseca, capital cognitivo, redes de apoyo entre pares— no están capturados en ningún dataset público colombiano de acceso libre. Esto es un vacío crítico en la infraestructura de datos del sistema educativo nacional.

Una segunda limitación es el alcance territorial del modelo: fue entrenado exclusivamente con datos de Sogamoso y Pitalito. Aunque estos municipios fueron seleccionados para representar perfiles contrastantes, el modelo no es directamente generalizable a cualquier municipio de Colombia. Para generalizar, sería necesario ampliar el entrenamiento a decenas o centenares de municipios con perfiles socioeconómicos diversos.

Una tercera limitación es el desfase temporal entre el corte del SISBEN (2022) y los años de entrenamiento del modelo (2015–2019). Aunque se intentó mitigar esto usando el SISBEN como fuente de caracterización contextual y no como predictor individual, la distancia temporal introduce incertidumbre sobre si las condiciones socioeconómicas del SISBEN 2022 son representativas de las condiciones durante los años de entrenamiento.

7.4 Comparación de algoritmos: ¿qué aprendió el proyecto sobre los modelos?

Los tres algoritmos evaluados —Random Forest, XGBoost y LightGBM— convergieron al mismo rango de métricas (F1 macro 0.44–0.46, accuracy adyacente 0.85–0.87), con diferencias inferiores a 2 puntos porcentuales entre el mejor y el peor. Este resultado tiene dos interpretaciones importantes.

La primera es que el techo de información de los datos es el factor dominante, no el algoritmo. Cuando todos los modelos, independientemente de su arquitectura y parámetros, producen métricas prácticamente iguales, la señal es clara: se ha extraído casi toda la información predictiva que el conjunto de features disponibles puede ofrecer. No hay ganancia marginal significativa en optimizar el algoritmo cuando el cuello de botella está en los datos.

La segunda interpretación es que el tuning de hiperparámetros tampoco marca diferencia sustancial en este contexto. Las configuraciones base y tuning de cada algoritmo produjeron métricas similares, lo que sugiere que el espacio de optimización de hiperparámetros es

relativamente plano en este problema —mejorar los parámetros no mueve la aguja cuando la varianza explicable está acotada por la calidad informativa de las features.

En términos prácticos, para este problema y estos datos, el Random Forest con configuración de tuning y `class_weight='balanced'` es la elección más pragmática: produce las mejores métricas de F1 macro, es interpretable a través de la importancia de features, y su entrenamiento es robusto y reproducible.

7.5 Implicaciones para el plan de acción del Ministerio de Educación

A partir de los hallazgos del modelo, el equipo de consultoría plantea las siguientes recomendaciones de política pública, organizadas por prioridad de impacto:

#	Recomendación	Municipio prioritario	Evidencia del modelo
1	Programas de formación y acompañamiento para padres con bajo nivel educativo	Ambos (más urgente en Pitalito)	capital_educativo: predictor #1 con importancia ~0.175
2	Dotación conjunta de internet + dispositivos en hogares vulnerables (no solo conectividad)	Pitalito (mayor brecha de acceso)	recursos_tech y ventaja_hogar: predictor #4 con efecto multiplicador documentado
3	Fortalecimiento docente y mejoramiento de colegios oficiales	Ambos (más urgente en Pitalito)	COLE_NATURALEZA: predictor #3 con importancia ~0.125
4	Programas intensivos de inglés en colegios oficiales y rurales	Pitalito (mayor brecha en inglés)	Inglés: área con mayor brecha territorial documentada en EDA
5	Intervención temprana sobre estudiantes identificados como riesgo crítico (P10)	Ambos municipios	Clasificador binario con AUC-ROC 0.70 — detección anticipada viable

7.6 Hipótesis del techo de información y el Proyecto v2

Una de las contribuciones analíticas más importantes de este proyecto no es una métrica del modelo sino la identificación precisa de por qué el modelo tiene el techo que tiene. Esto es valioso en sí mismo porque define la agenda de investigación futura.

El experimento de comparar Dataset Completo vs Solo ICFES, combinado con el análisis de convergencia de todos los algoritmos al mismo rango de métricas, permite formular con precisión la siguiente hipótesis: el techo de F1 macro ~0.46 se debe a la limitada información contenida en los dataset de datos.gov.co, no al algoritmo. Con variables adicionales que capturen el contexto pedagógico individual del estudiante —nivel NSE continuo, número de libros en el hogar, tipo de jornada escolar, hábitos de uso del internet para estudio— el modelo debería poder superar ese techo.

Esta hipótesis está siendo verificada en el Proyecto v2, que utiliza los microdatos completos de Datalcfes (archivos directos del ICFES por departamento, ~84 columnas vs ~19 del dataset kgxf-xxbe). Las variables adicionales disponibles incluyen estu_inse_individual (índice NSE continuo que reemplaza el join proxy con el SISBEN), fami_numlibros (capital cultural del hogar), cole_caracter (académico vs técnico), cole_jornada y estu_dedicacioninternet (horas semanales de uso de internet), entre otras. Si el Proyecto v2 confirma la hipótesis y supera el techo de F1 macro en más de 5 puntos porcentuales, quedará demostrado que el problema era de información y no de algoritmo.

7.7 Reflexión sobre los datos abiertos colombianos y la brecha de información educativa

Este proyecto evidencia una limitación estructural del ecosistema de datos abiertos colombianos en el ámbito educativo: los datasets públicos disponibles describen bien las condiciones del hogar y del sistema escolar en términos agregados, pero no capturan los procesos pedagógicos individuales que determinan el aprendizaje real.

El ICFES registra el resultado final (el puntaje del examen) y algunas características del hogar, pero no el proceso que llevó a ese resultado: la asistencia a clases, la calidad de las interacciones pedagógicas, el tiempo dedicado al estudio, la participación en actividades extracurriculares. El MEN tiene datos de cobertura y eficiencia interna, pero agregados por municipio, no por estudiante. El SISBEN caracteriza condiciones socioeconómicas, pero no está diseñado para vincular a personas específicas con resultados académicos.

Cerrar esta brecha de información —construir sistemas de seguimiento longitudinal de estudiantes que conecten las condiciones del hogar, la trayectoria escolar y los resultados en pruebas estandarizadas— es probablemente la inversión con mayor retorno que podría hacer el Ministerio de Educación para mejorar su capacidad de anticipar y prevenir el rezago académico. Sin datos de mejor calidad, ningún algoritmo de aprendizaje de máquina, por sofisticado que sea, podrá proporcionar predicciones significativamente más precisas que las obtenidas en este proyecto.

7.8 Síntesis final

El proyecto cumplió su objetivo de construir un modelo predictivo que permita orientar intervenciones del Ministerio de Educación para mejorar los resultados del ICFES Saber 11 en Sogamoso y Pitalito. Los hallazgos principales —la dominancia del capital educativo familiar, el efecto multiplicador de la combinación educación-tecnología, la sensibilidad del inglés a la desigualdad, la utilidad del clasificador de riesgo crítico— son robustos, interpretables y directamente accionables para política pública.

La limitación del techo de información no reduce el valor del proyecto; la identifica y la cuantifica, lo cual es igualmente valioso para el Ministerio: saber hasta dónde puede llegar un sistema predictivo con datos actuales es información crítica para decidir qué inversiones en infraestructura de datos se deben priorizar.

Más allá de los números, el proyecto confirma una tesis de política pública respaldada por décadas de investigación educativa: la desigualdad en los resultados académicos comienza en el hogar, se amplifica en la escuela y se proyecta en el mercado laboral. Las herramientas de análisis de datos, por poderosas que sean, solo pueden hacer visible esa cadena causal —no romperla. Romperla requiere políticas estructurales que actúen simultáneamente sobre el capital educativo familiar, la calidad de las instituciones escolares y el acceso equitativo a recursos tecnológicos. Es exactamente para orientar esas políticas que este proyecto fue diseñado.

7.9 Proyecto v2

En respuesta a las limitaciones identificadas, se está desarrollando el Proyecto v2 utilizando los microdatos completos de DataIcfes (archivos directos del ICFES por departamento, ~84 columnas vs ~19 del dataset inicial). Las nuevas variables disponibles incluyen `estu_inse_individual` (índice NSE continuo), `fami_numlibros`, `cole_caracter`, `cole_jornada` y variables de hábitos del estudiante, que deberían permitir superar el techo informacional del modelo actual.

8. Referencias

Instituto Colombiano para la Evaluación de la Educación (2025). Resultados únicos Saber 11. Datos Abiertos Colombia.
https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe/about_data

Departamento Nacional de Planeación (2025). Sisbén Personas. Datos Abiertos Colombia.
https://www.datos.gov.co/Estad-sticas-Nacionales/DNP-Sisb-n-Personas/hq2v-5umk/about_data

Departamento Nacional de Planeación (s.f.). Diccionario de datos Sisbén IV.
<https://anda.dnp.gov.co/index.php/catalog/150/datafile/F18>

Ministerio de Educación Nacional (2025). Estadísticas en educación preescolar, básica y media por municipio. Datos Abiertos Colombia.
https://www.datos.gov.co/Educaci-n/MEN_ESTADISTICAS_EN_EDUCACION_EN_PREESCOLAR-B-SICA/nudc-7mev/data_preview

Alkire, S., & Foster, J. (2011). Counting and Multidimensional Poverty Measurement. *Journal of Public Economics*.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.

Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems 30 (NIPS 2017).