PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ingeniería · Ingeniería de Sistemas

Análisis de los Factores Socioeconómicos, Educativos y de Conectividad en los Resultados del ICFES Saber 11

Juan Santiago Mendez
Juan Martin Trejos
Diego Zabala
Juan Ordoñez

ENTREGA 1

Abril 2026

Proyecto de Investigación Big Data

CRISP-DM · Apache Spark · MLlib

CONTENIDO DE LA ENTREGA 1

01 **Entendimiento del Negocio**
Contexto, indicadores macroeconómicos y objetivo de consultoría

02 **Selección de Datos**
Datasets ICFES, SISBEN y MEN · justificación y criterios de integración

03 **Colección y Descripción**
Tipos de datos, atributos y descripción general de las fuentes

04 **Exploración de Datos**
Estadísticos descriptivos, gráficas y tablas de análisis (≥ 8 elementos)

05 **Calidad de Datos**
Valores faltantes y técnicas de imputación propuestas

06 **Preguntas de Negocio**
8 preguntas que guiarán la Entrega 2

07 **Limpieza y Transformación**
Avance: filtros, normalización e imputación inicial

01 · ENTENDIMIENTO DEL NEGOCIO

Problema central: La brecha en resultados Saber 11 entre municipios refleja desigualdades territoriales en conectividad, condiciones socioeconómicas y trayectorias educativas. El Ministerio de Educación requiere un plan de acción basado en datos.

Bogotá D.C.		Sogamoso		Bugalagrande	
Cundinamarca		Boyacá		Valle del Cauca	
NBI:	3.36%	NBI:	3.59%	NBI:	10.44%
Internet:	29/100 hab.	Internet:	15.396 suscr.	Internet:	4.562 suscr.
Perf. ICFES:	Alto	Perf. ICFES:	Medio	Perf. ICFES:	Bajo-Medio

Objetivo: Identificar y cuantificar la relación entre Saber 11, conectividad y factores socioeconómicos para orientar intervenciones del Ministerio de Educación.

02 · SELECCIÓN DE DATOS

D1 ICFES Saber 11

ICFES — Datos Abiertos Colombia

ROL: Variable dependiente central

Variables clave:

· PUNT_GLOBAL, PUNT_MATEMATICAS, PUNT_LECTURA_CRITICA, PUNT_INGLES

· FAMI_TIENEINTERNET, FAMI_ESTRATOVIVIENDA

· COLE_MCPIO_UBICACION, PERIODO

Contiene puntajes y variables individuales del estudiante y su hogar

D2 SISBEN

DNP — Departamento Nacional de Planeación

ROL: Caracterización socioeconómica

Variables clave:

· Grupo / Nivel / Clasificación (pobreza)

· H_5 (hacinamiento), PER016 (menores)

· I1–I4 (índices multidimensionales)

Proxy objetivo de vulnerabilidad, independiente del reporte ICFES

D3 MEN — Educación

MEN / SIMAT — Datos Abiertos

ROL: Contexto institucional y trayectoria

Variables clave:

· COBERTURA_NETA_MEDIA, DESERCIÓN_MEDIA

· SEDES_CONECTADAS_A_INTERNET

· APROBACIÓN / REPROBACIÓN / REPITENCIA

Mide eficiencia del sistema educativo e infraestructura escolar

03 · COLECCIÓN Y DESCRIPCIÓN DE DATOS

Dataset	Atributo	Tipo esperado	Significado	Nivel análisis
ICFES	PUNT_GLOBAL	Float / Double	Puntaje agregado Saber 11	Individual
ICFES	FAMI_TIENEINTERNET	String → Bool	Acceso a internet en el hogar	Individual
ICFES	FAMI_ESTRATOVIVIENDA	String / Int	Estrato socioeconómico	Individual
ICFES	COLE_MCPIO_UBICACION	String	Municipio del colegio	Institucional
SISBEN	Grupo / Nivel	String (categ.)	Clasificación vulnerabilidad	Poblacional
SISBEN	I1–I4	Float	Índices pobreza multidim.	Poblacional
MEN	COBERTURA_NETA_MEDIA	Float (%)	% estudiantes en edad correcta	Municipal
MEN	SEDES_CONECTADAS_INTERNET	Integer	Sedes con internet por mpio.	Municipal

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

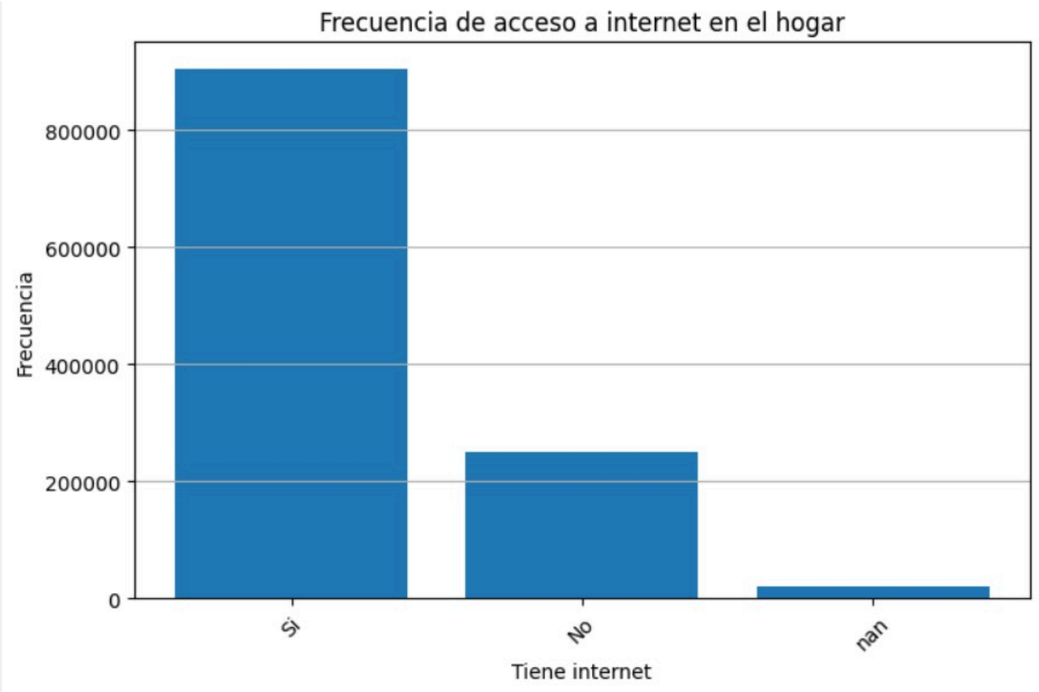

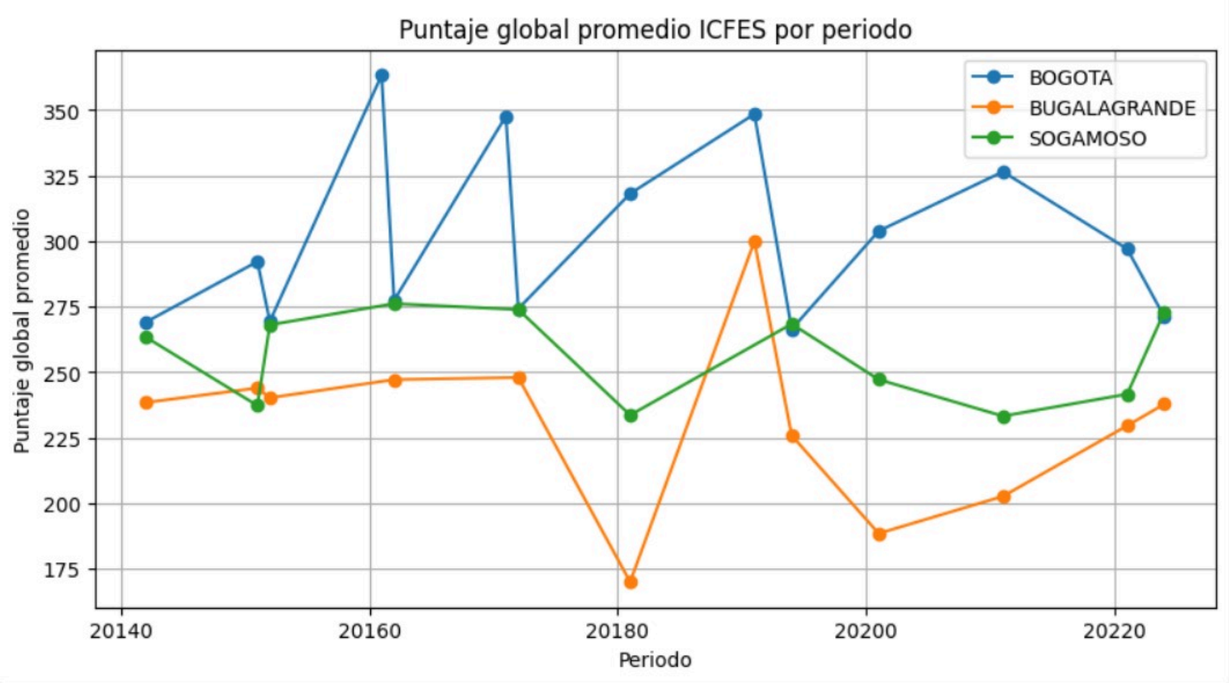

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

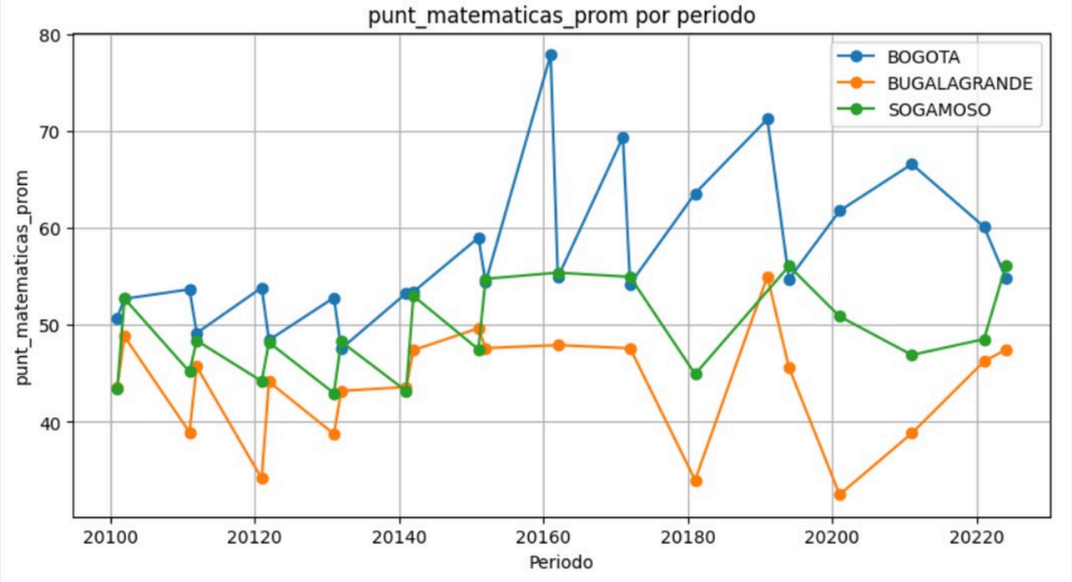

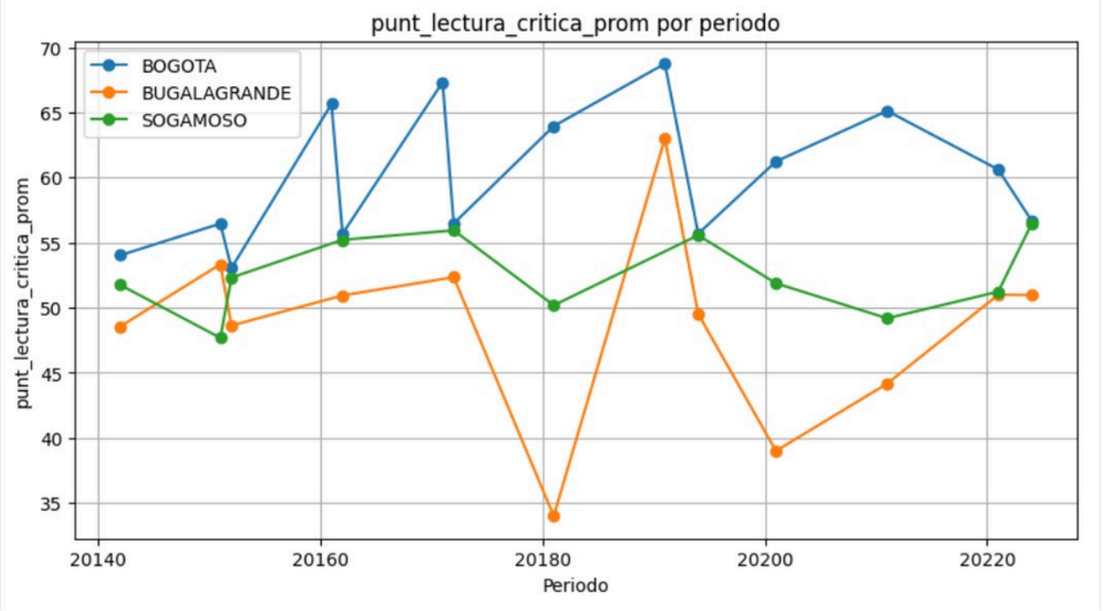

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

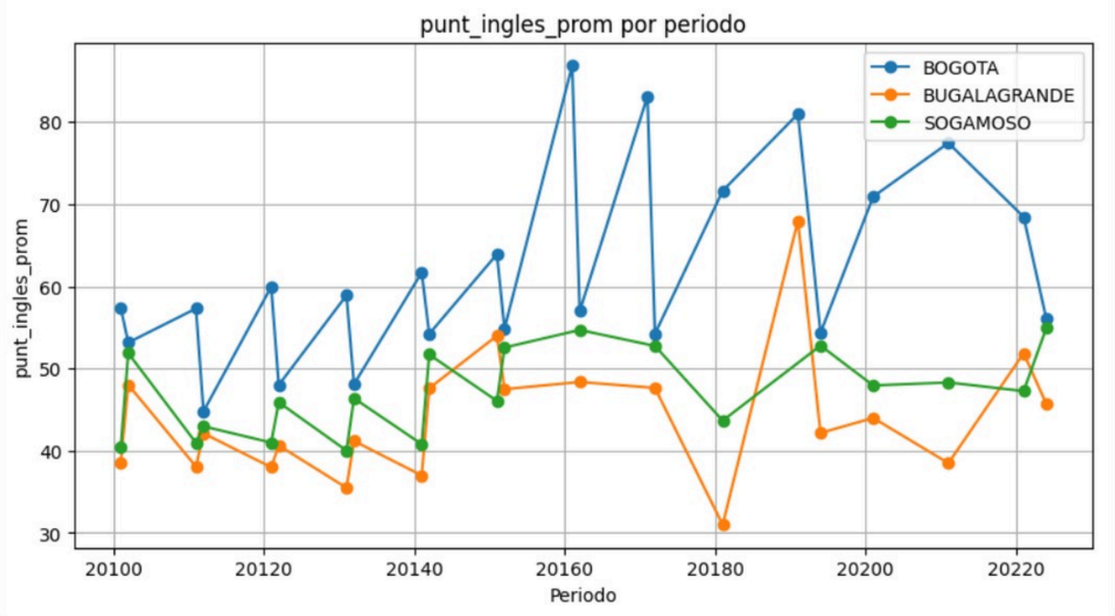

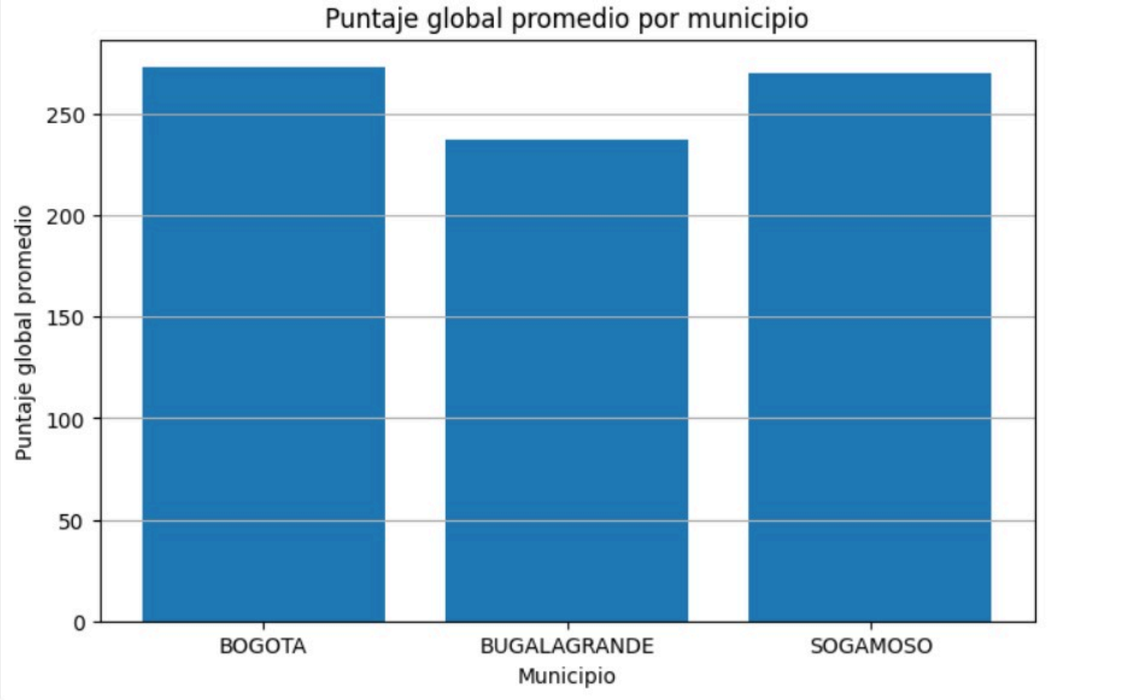

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

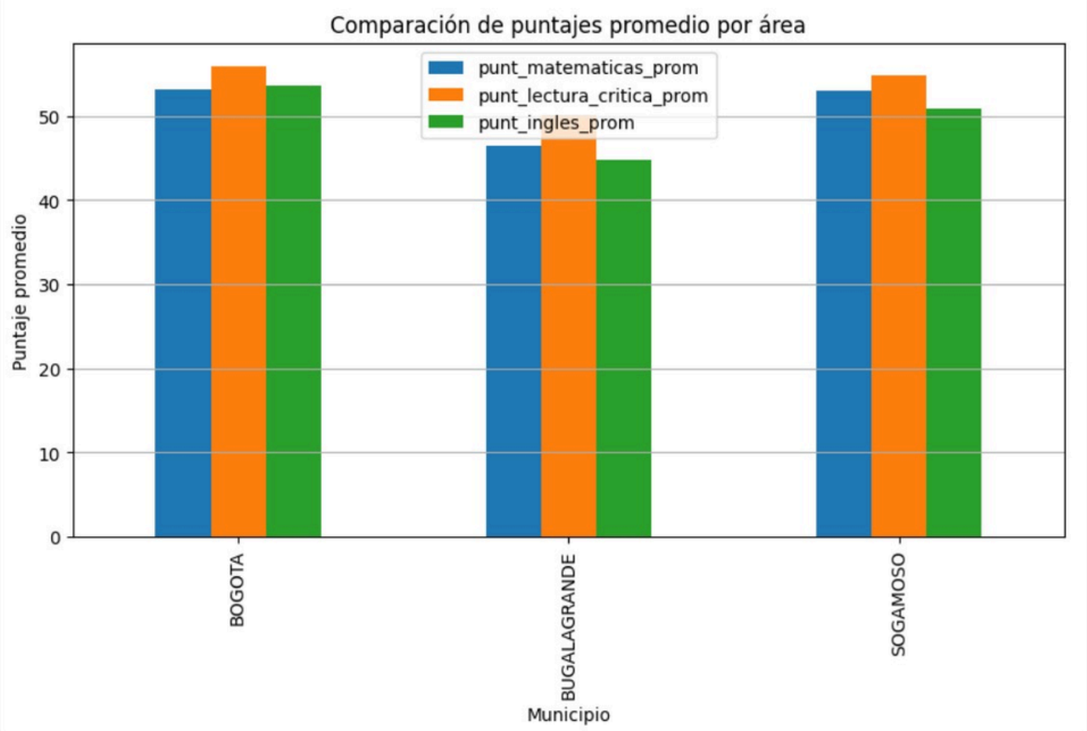

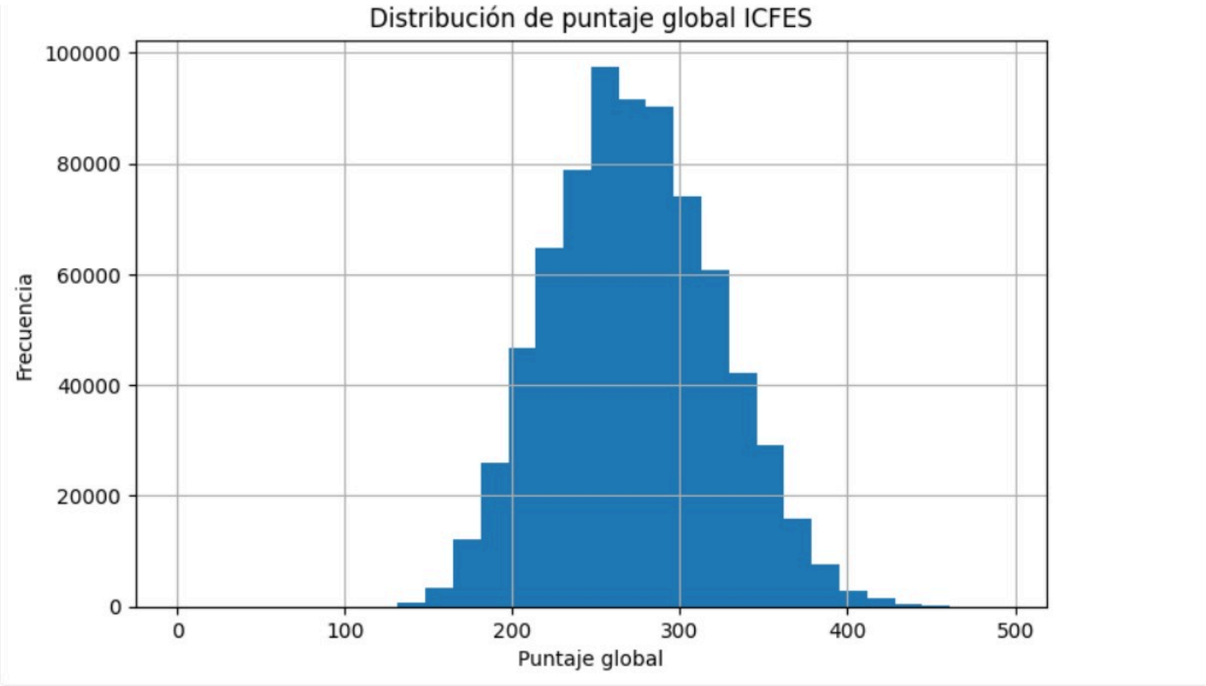

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

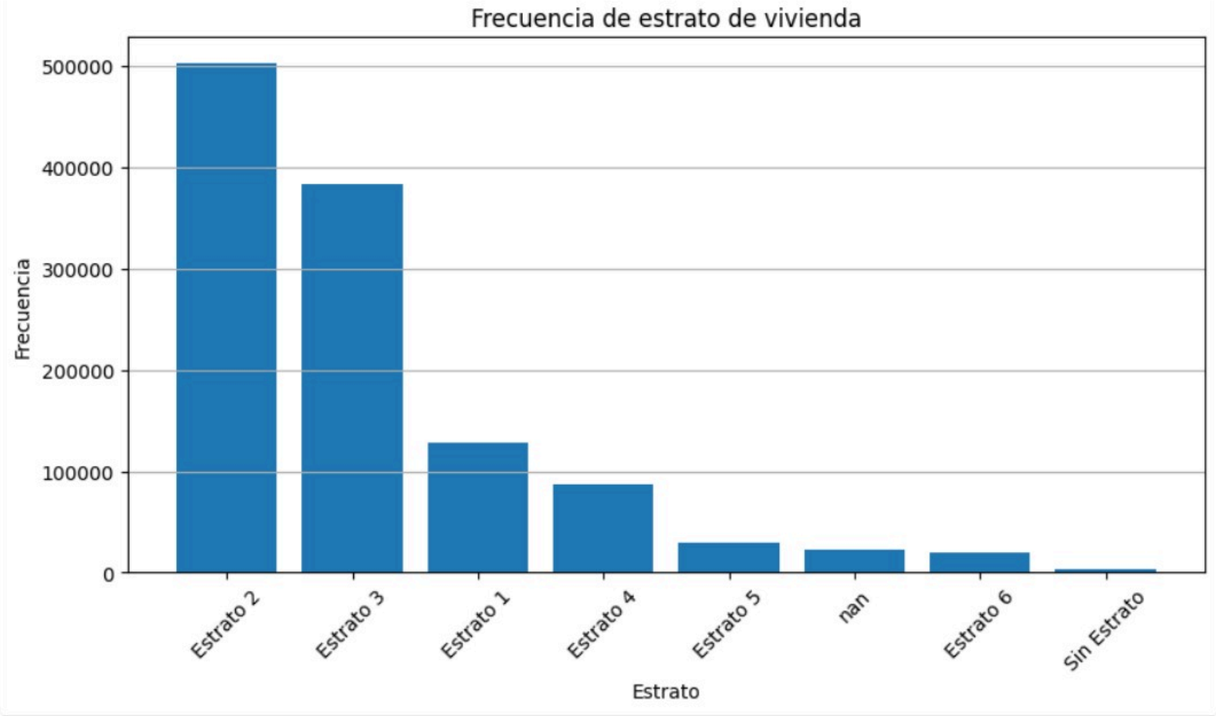

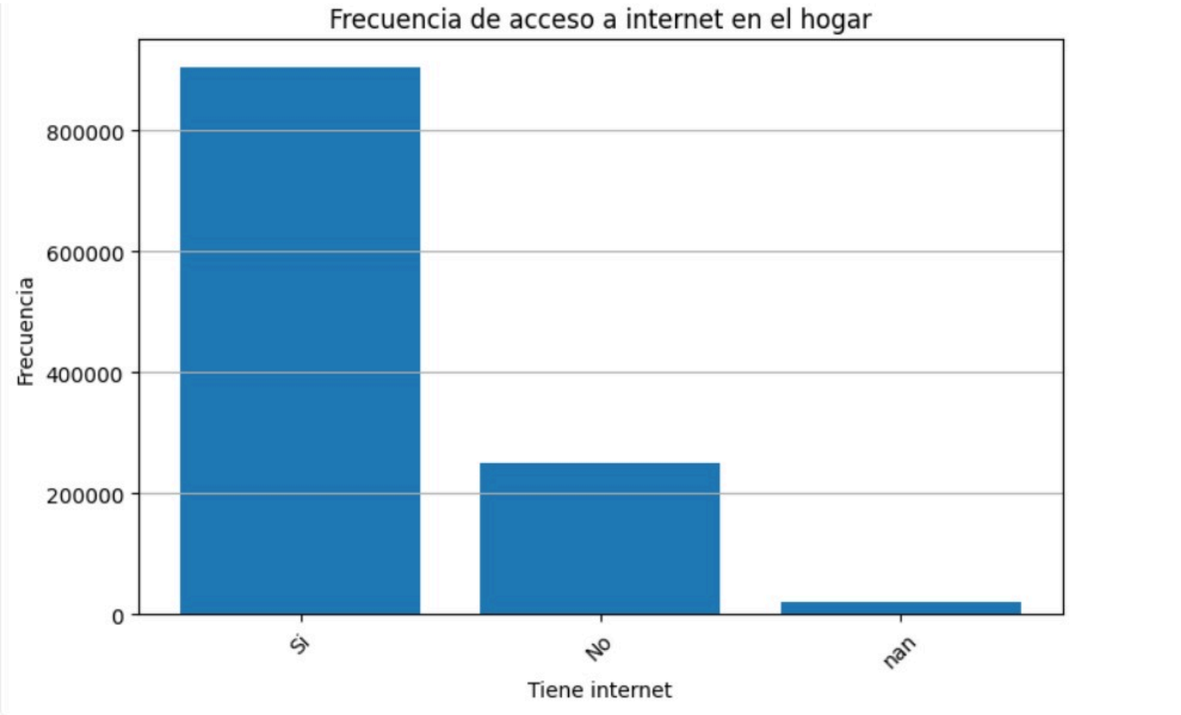

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

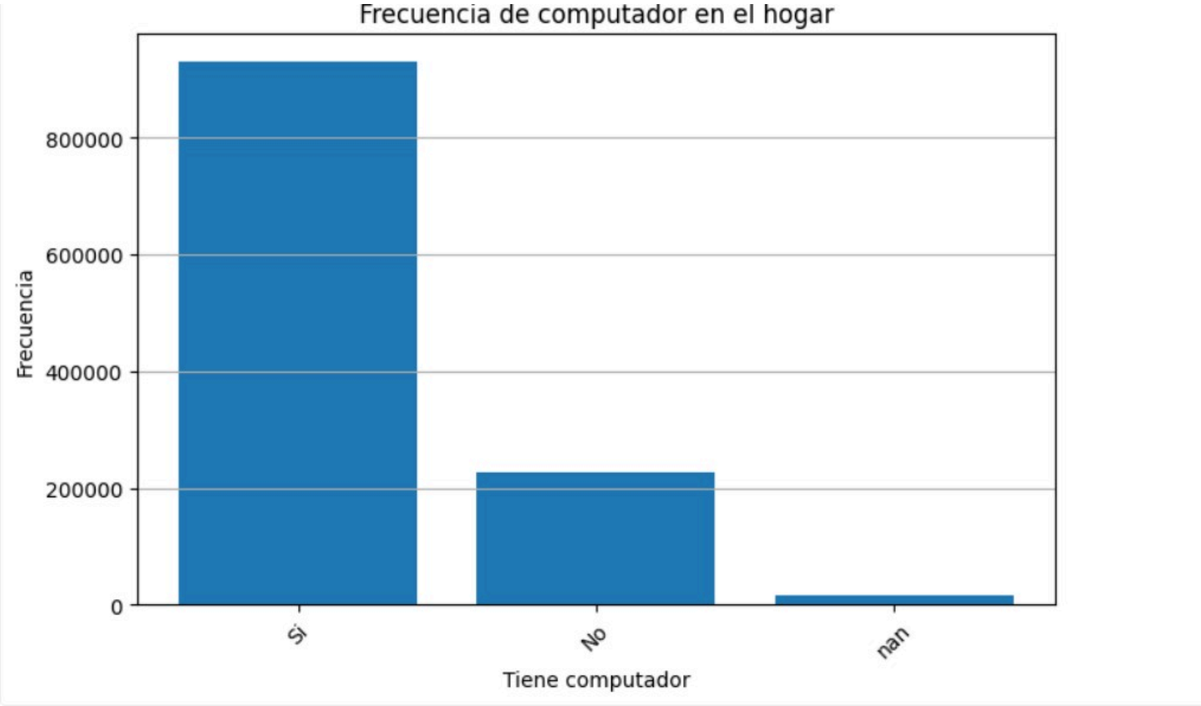

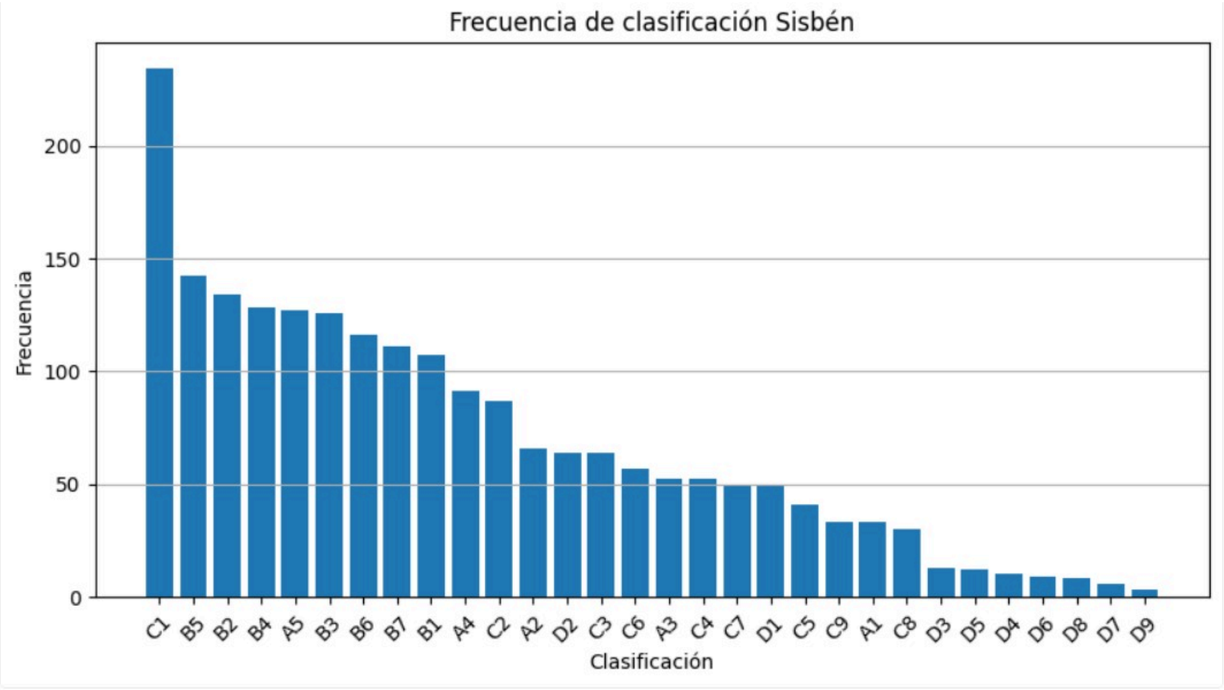

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

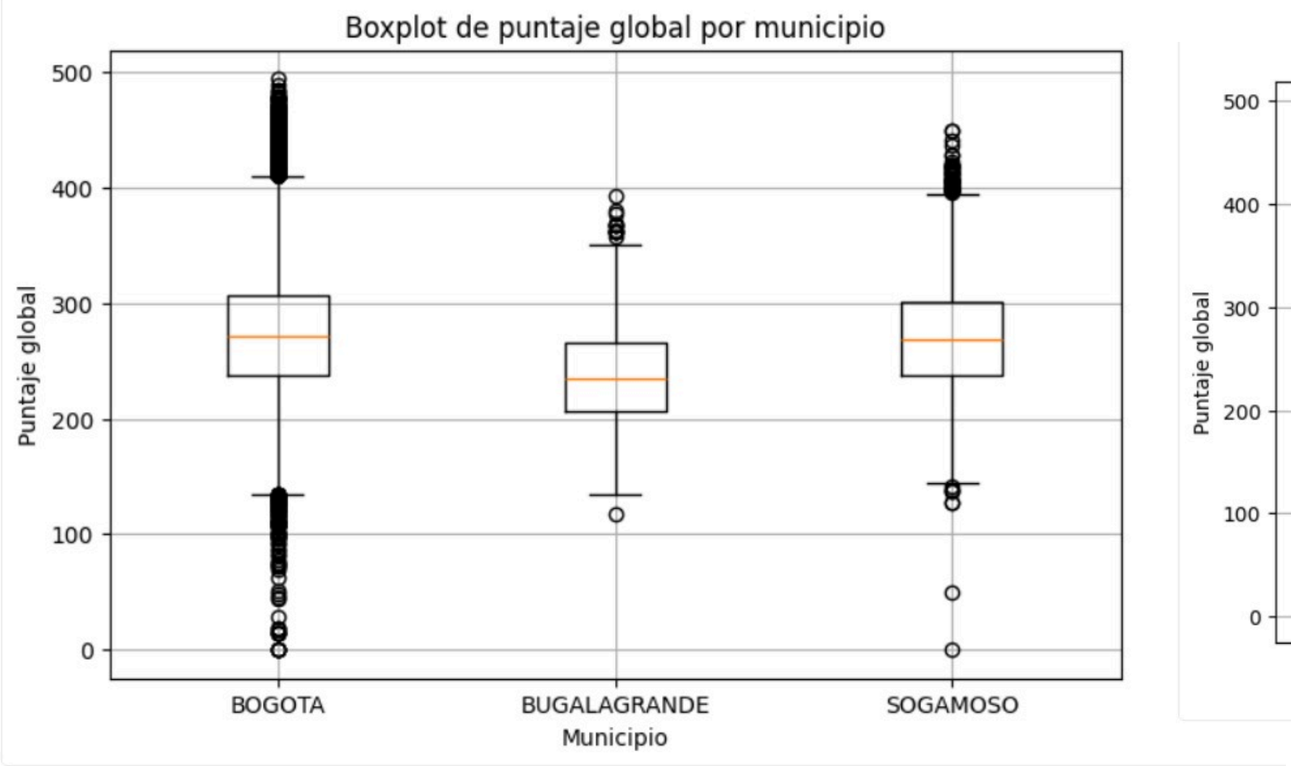

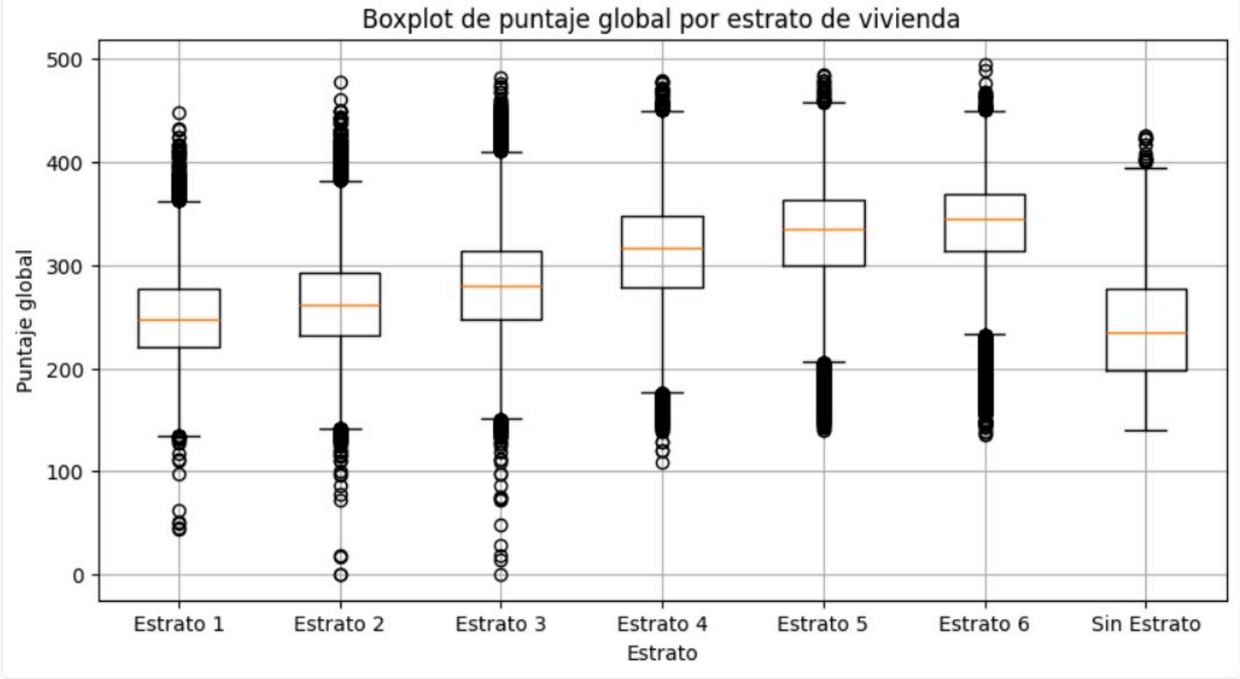

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

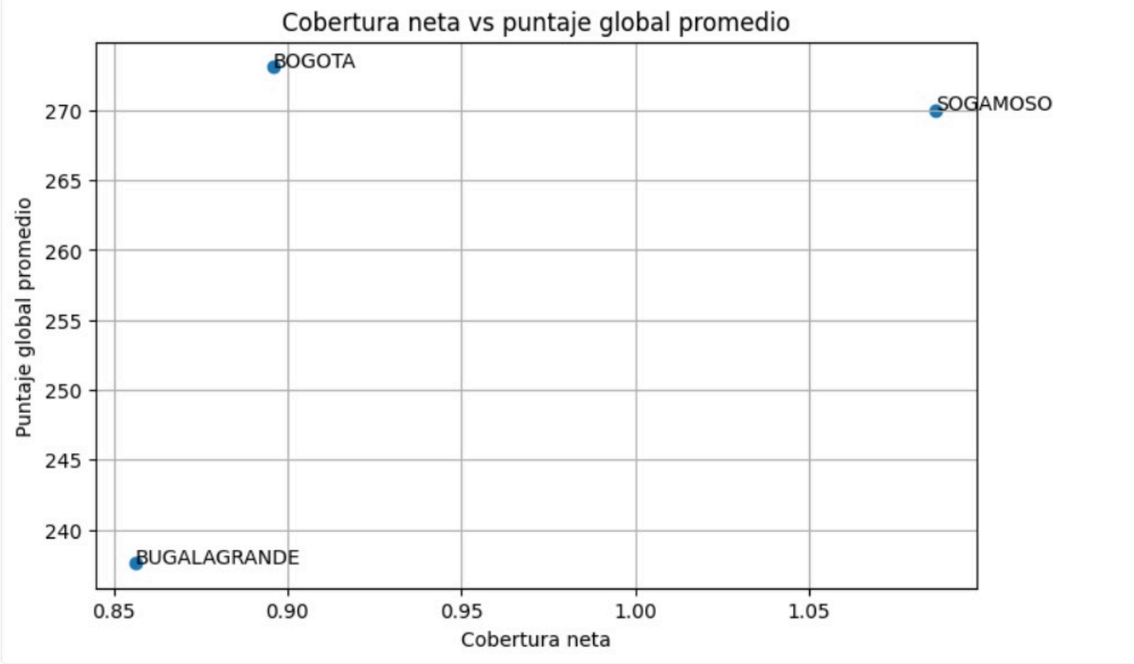

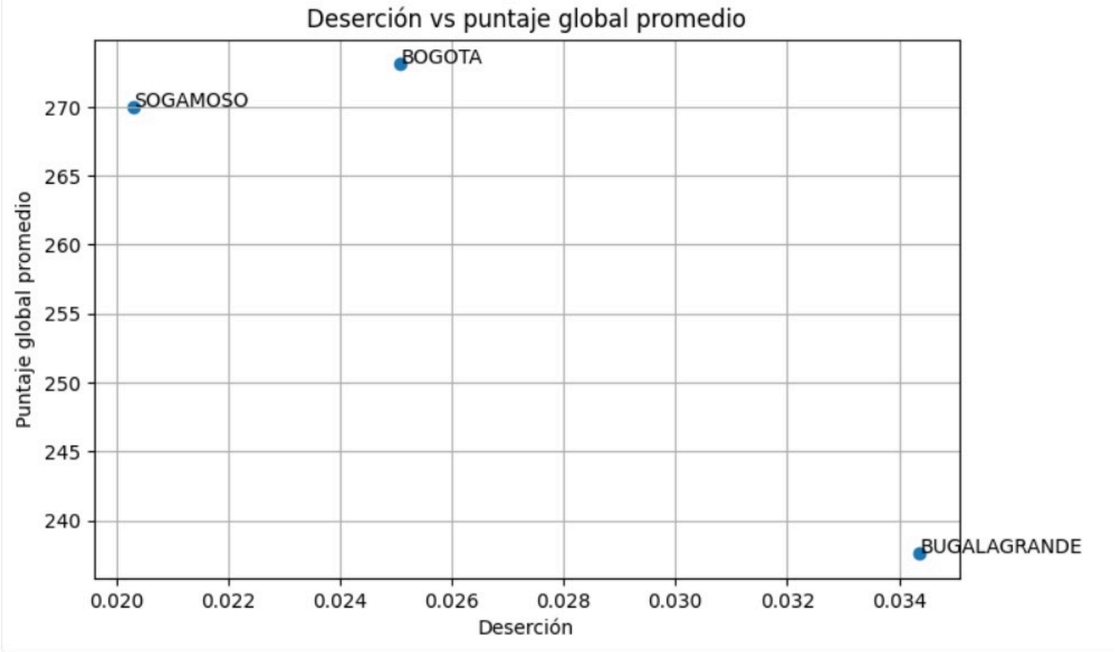

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

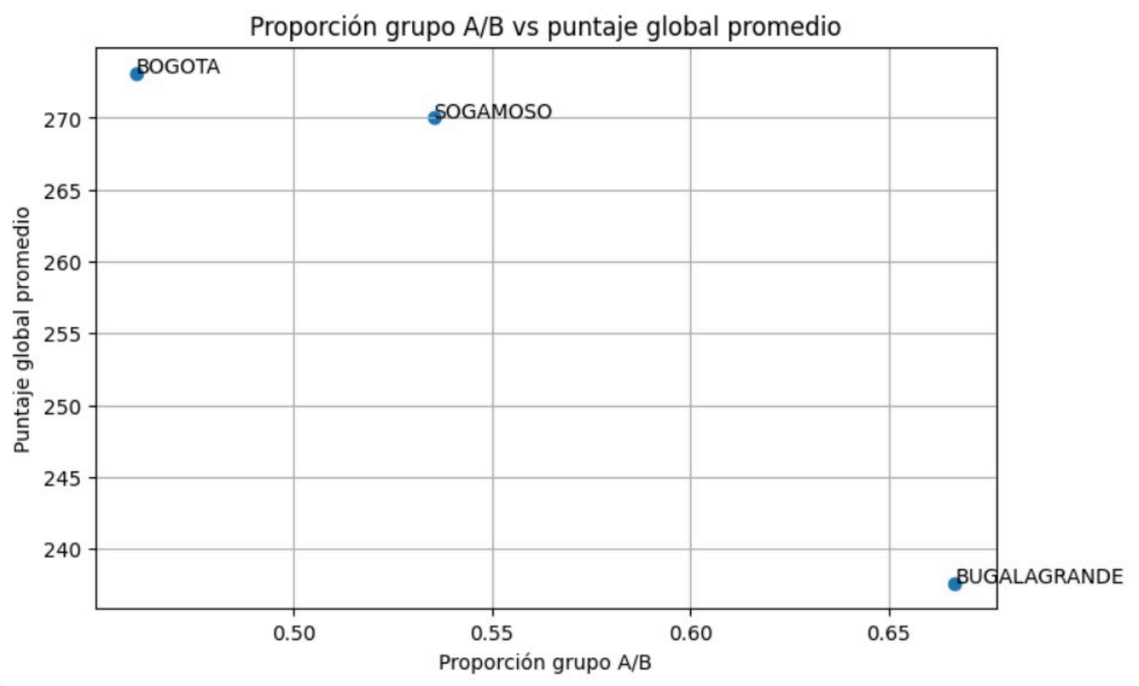

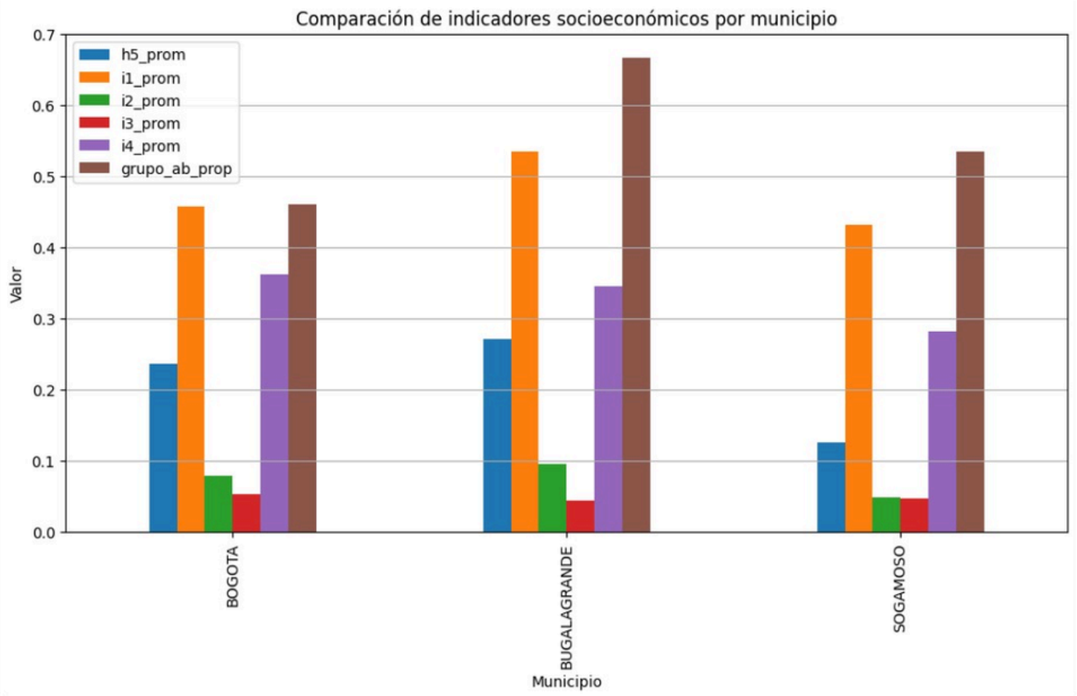

04 · EXPLORACIÓN DE DATOS

Se realizó un análisis exploratorio de los datos para entender su estructura, distribución y relaciones entre variables, enfocándose principalmente en ICFES y Sisbén, con apoyo de indicadores municipales. Se estudiaron Bogotá, Sogamoso y Bugalagrande por sus contextos contrastantes, y a partir de los datos se generaron visualizaciones que permiten identificar patrones iniciales y apoyar las preguntas de negocio.

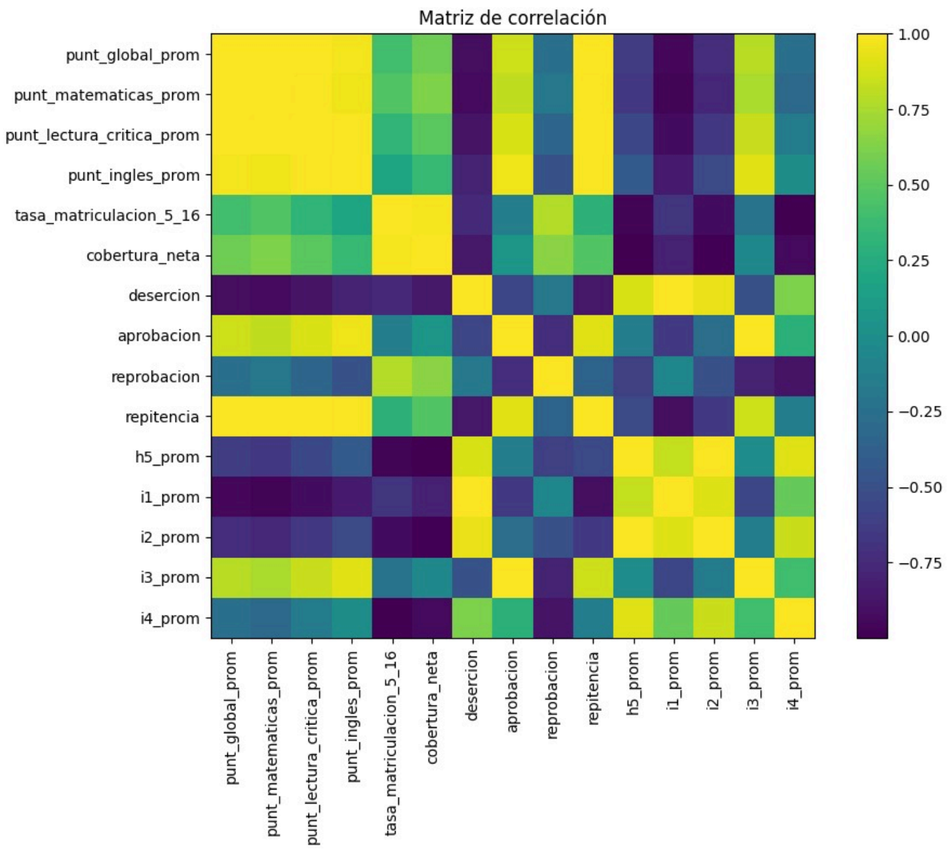

05 · REPORTE DE CALIDAD DE DATOS

Se realizó un análisis de calidad de los datasets ICFES y Sisbén para evaluar su confiabilidad y consistencia, enfocándose en valores faltantes, tipos de datos, estructura y posibles valores atípicos, así como en sus implicaciones para el desarrollo del proyecto.

Dataset ICFES

- 1.17M registros → alta capacidad analítica
- Muchos valores faltantes en puntajes clave (~428K)
- Faltantes también en variables socioeconómicas
- Variables clave (periodo, matemáticas) completas

Dataset SISBÉN

- 715 registros → estructura limpia
- Sin valores faltantes
- Alta confiabilidad para análisis socioeconómico

Problemas Identificados

- Valores faltantes (principalmente en ICFES)
- Tipos de datos inconsistentes
- Presencia de valores atípicos

Estrategias de Tratamiento

- Imputación:
- Numéricas → mediana
- Categóricas → moda / nueva categoría
- Puntaje global → eliminar nulos
- Outliers → winsorización (no eliminar)

Implicaciones

- No todos los datos sirven para todos los análisis
- Se requiere limpieza y transformación
- Datos utilizables con técnicas adecuadas

06 · PREGUNTAS DE NEGOCIO (→ Entrega 2)

P1 ¿Cómo influye el acceso a internet en el hogar en el puntaje global del ICFES en los municipios seleccionados?

P2 ¿Qué tan significativa es la brecha en puntajes ICFES entre estudiantes con y sin acceso a internet?

P3 ¿Cómo varía el desempeño académico (puntaje global y por áreas) entre Bogotá, Sogamoso y Bugalagrande a lo largo del tiempo?

P4 ¿Cuál es la relación entre el estrato socioeconómico de la vivienda y el rendimiento en el examen Saber 11?

P5 ¿Qué indicadores socioeconómicos derivados del Sisbén (h_5, i1, i2, i3, i4) presentan mayor asociación con el desempeño académico?

P6 ¿Existe relación entre la conectividad institucional (sedes conectadas a internet) y los resultados académicos promedio por municipio?

P7 ¿Cómo afectan variables del sistema educativo como cobertura, deserción y aprobación al desempeño en el ICFES?

P8 ¿Qué área del examen (Matemáticas, Lectura Crítica o Inglés) es más sensible a las diferencias socioeconómicas y de conectividad entre municipios?

07 · FILTROS, LIMPIEZA Y TRANSFORMACIÓN INICIAL

FILTROS

Municipios: Bogotá (11001), Sogamoso (15104), Bugalagrande (76113)

Selección de variables relevantes:
- Identificación territorial
- Variables socioeconómicas
- Acceso a tecnología
- Puntajes ICFES

Filtrado en dataset Educación por cod_mpio

LIMPIEZA

Revisión de valores faltantes en ICFES y SISBÉN

Identificación de variables con alta proporción de nulos

- Validación de columnas existentes antes del procesamiento
- Estandarización inicial de nombres de variables

TRANSFORMACIONES

Renombramiento de variables:
- Ej: AÑO → anio, CÓDIGO_MUNICIPIO → cod_mpio

Conversión de tipos de datos (ej: códigos y año a numéricos)

Agregaciones iniciales:
- Puntaje promedio por municipio
- Puntajes por área y periodo

Construcción de variables para análisis exploratorio