PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ingeniería — Departamento de Ingeniería de Sistemas

Proyecto Procesamiento Alto Volumen de Datos

John Corredor, PhD

Proyecto de Investigación Big Data

Análisis de los Factores Socioeconómicos, Educativos y de Conectividad en los Resultados del ICFES Saber 11

en los Municipios de Bogotá, Sogamoso y Bugalagrande

Docente: Jhon Corredor Franco

Juan Martin Trejos

Juan Santiago Mendez

Diego Zabala

Juan David Ordoñez

08/04/2026

ENTREGA 1: Entendimiento del Negocio y Entendimiento de los Datos

1. Entendimiento del Negocio

1.1. Contexto General

El problema público que aborda este proyecto parte de una desigualdad territorial: los resultados de las pruebas Saber 11 no se producen en el vacío, sino dentro de municipios con capacidades muy distintas en conectividad, condiciones socioeconómicas y trayectorias educativas. Por eso, comparar Bugalagrande, Sogamoso y Bogotá D.C. tiene sentido analítico: no representan el mismo tipo de territorio, ni enfrentan las mismas restricciones, ni deberían recibir la misma intervención pública.

Bugalagrande muestra un contexto de mayor vulnerabilidad relativa. Según el CNPV 2018 ajustado, tiene 24.318 habitantes; en el mismo marco censal, su indicador de Necesidades Básicas Insatisfechas fue 10,44%, muy por encima de Sogamoso y Bogotá. En conectividad, MinTIC reporta 4.562 suscriptores de internet para el municipio, y en su planeación local aparece una cobertura neta en educación media de 43,35, lo que sugiere un cuello de botella en el tránsito hacia los grados que preceden directamente a Saber 11. En este municipio, el problema no parece ser solo académico: también hay señales de rezago estructural en acceso y permanencia educativa.

Sogamoso presenta un perfil distinto. Tiene una población de 127.235 habitantes y un NBI de 3,59%, bastante menor que Bugalagrande. MinTIC reporta 15.396 suscriptores de internet, y un diagnóstico reciente del sistema educativo local muestra que la cobertura neta en educación media alcanzó 73,47% en 2022; sin embargo, la cobertura bruta superó a la neta en 50,1 puntos porcentuales, lo que apunta a problemas de extraedad y trayectorias escolares irregulares. Es decir, Sogamoso no enfrenta tanto un déficit básico de acceso como un reto de eficiencia y calidad del recorrido educativo.

Bogotá D.C. representa el caso de mayor escala y mejores condiciones promedio, pero no por eso queda fuera del problema. El CNPV 2018 registró 7.181.469 habitantes y un NBI de 3,36%, y MinTIC reportó 29 accesos fijos a internet por cada 100 habitantes en el primer trimestre de 2025, liderando el indicador nacional. En educación, Bogotá tuvo 74.300 estudiantes evaluados en Saber 11 en 2023 y 84,4% de sus colegios quedaron en categorías

A+, A y B; aun así, la Secretaría de Educación reporta que persiste una brecha entre colegios públicos y privados en los resultados Saber 11. En Bogotá, entonces, la problemática no es tanto de cobertura promedio, sino de desigualdad interna en la calidad y en las oportunidades educativas.

El presente proyecto selecciona tres municipios colombianos que representan realidades contrastantes en términos de tamaño, condición socioeconómica y nivel de conectividad:

Municipio	Departamento	Contexto Relevante
Bogotá D.C.	Cundinamarca	Capital del país y principal centro urbano. Mayor cobertura de internet del país y mejores indicadores educativos a nivel nacional. Sirve como municipio de referencia de alto desempeño.
Sogamoso	Boyacá	Ciudad intermedia con economía basada en industria y minería. Indicadores de conectividad y educación en nivel medio, representativa de los centros urbanos secundarios del país.
Bugalagrande	Valle del Cauca	Municipio pequeño de economía agroindustrial. Menor densidad poblacional y menor cobertura de internet que las ciudades principales. Representa el contexto de municipios rurales intermedios del país.

1.2. Indicadores Macroeconómicos de Interés

Para contextualizar el análisis se consideran los siguientes indicadores, relevantes para los tres municipios seleccionados:

- Índice de Pobreza Multidimensional (IPM): Permite dimensionar las condiciones de vida de la población y su relación con el acceso a internet y el desempeño académico.

- Clasificación SISBEN: Refleja la condición socioeconómica de los hogares y permite analizar si el nivel de vulnerabilidad se correlaciona con los resultados del ICFES.
- Cobertura neta de educación media: Porcentaje de estudiantes en edad escolar que asisten a grado 10 y 11, relevante para entender el contexto en que se presentan las pruebas Saber 11.
- Puntaje promedio Saber 11 por municipio: Variable de resultado central del análisis.

1.3. Objetivo de Negocio

Identificar y cuantificar la relación entre los resultados de las pruebas Saber 11 y los factores socioeconómicos, de conectividad y de trayectoria educativa a nivel municipal, con énfasis en Bugalagrande, Sogamoso y Bogotá D.C., para orientar la priorización de intervenciones del Ministerio de Educación.

2. Selección de los Datos a Utilizar

2.1 Dataset ICFES Resultados Saber 11

Fuente: Instituto Colombiano para la Evaluación de la Educación (ICFES).

Este conjunto de datos constituye la variable dependiente central del proyecto. Contiene los puntajes obtenidos por los estudiantes en las pruebas Saber 11, que son el indicador de desempeño académico de referencia nacional para la educación media. Su inclusión es indispensable para cumplir el objetivo de negocio, pues sin él no sería posible medir ni modelar el rendimiento académico a nivel municipal. Adicionalmente, el dataset incluye variables de caracterización individual del estudiante y su entorno familiar, lo cual permite articular el análisis desde la dimensión socioeconómica del hogar con los resultados obtenidos en las pruebas.

Variable	Justificación
PERIODO	Permite realizar análisis temporales y controlar por año de aplicación, identificando tendencias o cambios en el desempeño a lo largo del tiempo.
COLE_MCPIO_UBICACION	Identifica el municipio donde está ubicado el colegio. Es la clave principal para filtrar los registros de Bugalagrande, Sogamoso y Bogotá D.C., y para realizar agregaciones territoriales.
ESTU_COD_RESIDE_MCPIO / ESTU_MCPIO_RESIDE	Permite distinguir entre el municipio donde estudia y donde reside el estudiante, lo cual es relevante para detectar movilidad educativa intermunicipal y enriquecer el análisis territorial.
ESTU_ESTUDIANTE	Identificador único del estudiante. Necesario para garantizar la unicidad de los registros y evitar duplicados en el procesamiento distribuido.
COLE_BILINGUE	Indicador de si el colegio es bilingüe. Variable de caracterización institucional que puede estar correlacionada con el acceso a recursos y el nivel socioeconómico del entorno escolar.
FAMI_EDUCACIONMADRE / FAMI_EDUCACIONPADRE	El nivel educativo de los padres es uno de los factores más documentados en la literatura como predictor del rendimiento académico. Permite cuantificar el efecto del capital educativo familiar sobre los puntajes.
FAMI_ESTRATOVIVIENDA	El estrato socioeconómico de la vivienda es un proxy directo de las condiciones económicas del hogar en el contexto colombiano. Es una variable explicativa clave del desempeño escolar.

FAMI_PERSONASHOGAR	El número de personas en el hogar refleja condiciones de hacinamiento que pueden afectar el ambiente de estudio y el acceso a recursos educativos dentro del hogar.
FAMI_TIENECOMPUTADOR / FAMI_TIENEINTERNET	Variables centrales para el objetivo del proyecto. Permiten medir directamente el nivel de conectividad y acceso tecnológico del estudiante en su hogar, relacionándolo con sus resultados en las pruebas.
PUNT_INGLES, PUNT_MATEMATICAS, PUNT_SOCIALES_CIUDADANAS, PUNT_C_NATURALES, PUNT_LECTURA_CRITICA	Puntajes por área del conocimiento. Permiten un análisis desagregado del desempeño para identificar en qué componentes son más pronunciadas las brechas asociadas a factores socioeconómicos y de conectividad.
PUNT_GLOBAL	Puntaje agregado que sirve como variable de respuesta principal en los modelos de aprendizaje de máquina y en las agregaciones a nivel municipal.

2.2 Dataset SISBEN Sistema de Identificación de Potenciales Beneficiarios

Fuente: Departamento Nacional de Planeación (DNP).

El SISBEN es el principal instrumento de focalización social del Estado colombiano. Su inclusión aporta una caracterización socioeconómica objetiva e independiente de la declarada por el estudiante en el formulario ICFES, lo que enriquece el análisis al cruzar la situación de vulnerabilidad poblacional con el desempeño académico municipal. Este dataset opera principalmente a nivel de municipio y permite complementar las variables del ICFES con indicadores estructurales de pobreza y condiciones del hogar.

Variable	Justificación

cod_mpio	Código del municipio. Llave de unión con los demás datasets a nivel territorial, esencial para la integración de las tres fuentes de datos.
H_5	Indicador de hacinamiento en el hogar. Complementa la variable FAMI_PERSONASHOGAR del ICFES y permite refinar la medición de las condiciones habitacionales de la población en edad escolar.
I1, I2, I3, I4	Índices componentes del puntaje SISBEN (condiciones de la vivienda, acceso a servicios públicos, capital humano e ingresos). Ofrecen una descomposición estructurada de la pobreza multidimensional, permitiendo identificar qué dimensión tiene mayor impacto sobre el desempeño escolar.
Grupo / Nivel / Clasificacion	Clasificación oficial de vulnerabilidad socioeconómica del hogar. Permite segmentar la población por nivel de pobreza y contrastar el rendimiento entre grupos, lo que es directamente accionable para el Ministerio al priorizar intervenciones.
Edad	Permite caracterizar la distribución etaria de la población registrada en SISBEN dentro del municipio, útil para estimar la proporción en edad escolar y cruzarla con las tasas de matrícula.
PER016	Número de personas entre 0 y 16 años en el hogar. Variable clave para estimar la demanda potencial del sistema educativo en cada municipio y relacionarla con las tasas de cobertura del dataset de Educación.

2.3 Dataset Educación — Indicadores de Cobertura y Trayectoria Educativa por Municipio

Fuente: Ministerio de Educación Nacional (MEN) — Sistema Integrado de Matrícula (SIMAT).

Este conjunto de datos provee los indicadores de eficiencia interna y cobertura del sistema educativo a nivel municipal, representando la trayectoria educativa como dimensión de análisis. Su inclusión permite entender no solo cuántos estudiantes llegan a presentar las pruebas Saber 11, sino también la calidad del proceso educativo que los antecede. Además, incluye una variable de conectividad institucional (sedes conectadas a internet) que complementa la conectividad individual medida en el ICFES.

Variable	Justificación
Año / CÓDIGO_MUNICIPIO	Dimensiones temporales y territoriales. Permiten la unión con los demás datasets y el análisis de tendencias por municipio a lo largo del tiempo.
TASA_MATRICULACIÓN_5_16	Mide el porcentaje de niños en edad escolar que efectivamente están matriculados. Refleja el nivel de acceso al sistema educativo en cada territorio y es un indicador base para contextualizar los resultados de las pruebas.
COBERTURA_NETA / COBERTURA_NETA_PRIMARIA / COBERTURA_NETA_SECUNDARIA / COBERTURA_NETA_MEDIA	Indicadores de cobertura por nivel educativo. Permiten identificar en qué etapa del ciclo escolar se concentran las mayores brechas, informando dónde debe focalizarse la intervención del Ministerio.
SEDES_CONECTADAS_A_INTERNET	Variable de conectividad a nivel institucional. Complementa las variables FAMI_TIENEINTERNET del ICFES al medir el acceso a internet desde el colegio, no solo desde el hogar. Es especialmente relevante para el objetivo central del proyecto.
DESERCIÓN / DESERCIÓN_PRIMARIA / DESERCIÓN_SECUNDARIA / DESERCIÓN_MEDIA	La deserción escolar reduce la cantidad de estudiantes que llegan a presentar Saber 11. En municipios con alta deserción, los puntajes pueden estar sesgados hacia estudiantes con mejores condiciones, lo que exige controlar por esta variable en el análisis.
APROBACIÓN / REPROBACIÓN / REPITENCIA (y desagregaciones por nivel)	Indicadores de eficiencia interna del sistema. Reflejan la calidad del proceso de enseñanza-aprendizaje y la acumulación o pérdida de capital humano a lo largo del ciclo educativo. Su relación con

	los puntajes Saber 11 permite diagnosticar si los problemas de desempeño son estructurales o coyunturales.

2.4 Criterio de Integración entre los Tres Datasets

Los tres conjuntos de datos se articulan mediante el código de municipio como llave de unión territorial. El dataset de ICFES aporta la variable de resultado (puntaje) y las características individuales del estudiante; el SISBEN aporta la caracterización socioeconómica poblacional del municipio; y el dataset de Educación aporta los indicadores del sistema escolar como contexto institucional. Esta integración multi-fuente permite construir un modelo explicativo que abarca desde el nivel individual hasta el nivel territorial, alineado con el objetivo de orientar intervenciones del Ministerio de Educación en los municipios priorizados: Bugalagrande, Sogamoso y Bogotá D.C.

Dataset	Dimensión analítica	Rol en el modelo
ICFES Saber 11	Desempeño individual	Variable dependiente (PUNT_GLOBAL) y variables explicativas individuales/familiares.
SISBEN	Vulnerabilidad socioeconómica	Variables explicativas a nivel poblacional y municipal.
MEN – Educación	Trayectoria educativa e infraestructura	Variables de contexto institucional y conectividad escolar.

3. Colección y Descripción de los Datos

En este apartado se presenta la descripción de los conjuntos de datos seleccionados para el proyecto, organizando la información en tablas que cubren: (i) el tipo de dato esperado de cada atributo, (ii) su significado analítico y (iii) una descripción general del contenido de cada fuente. La clasificación de tipos se plantea como tipo esperado de trabajo y debe validarse al momento de la carga real en Apache Spark.

Nota metodológica: las variables codificadas del SISBÉN (por ejemplo H_5, I1, I2, I3, I4 y PER016) se describen de forma conservadora, ya que su interpretación exacta depende del diccionario oficial del conjunto de datos.

3.1 Resumen general de los conjuntos de datos

Conjunto de datos	Unidad de análisis	Descripción general del contenido	Aporte al objetivo del proyecto
ICFES	Estudiante / registro de evaluación	Contiene variables de contexto del estudiante, del hogar y del establecimiento educativo, junto con los puntajes obtenidos en áreas evaluadas y el puntaje global.	Permite analizar la relación entre desempeño académico, acceso a internet, condiciones del hogar y características del entorno educativo.
SISBÉN	Persona / registro socioeconómico	Incluye variables de identificación territorial y condiciones socioeconómicas de la población registradas por el SISBÉN, útiles para caracterizar vulnerabilidad y contexto social.	Aporta variables de pobreza y condiciones de vida que ayudan a contextualizar diferencias territoriales en resultados educativos.
Educación	Municipio y año	Reúne indicadores agregados de cobertura, matrícula, sedes conectadas a internet, deserción, aprobación, reprobación y repitencia por municipio.	Permite estudiar brechas territoriales del sistema educativo y contrastarlas con resultados ICFES e indicadores de conectividad.

3.2 Descripción de atributos del conjunto ICFES

El conjunto ICFES se centra en registros individuales de estudiantes y combina variables de localización, características familiares y puntajes académicos. Es útil para medir el desempeño académico y relacionarlo con factores del hogar y del municipio.

Atributo	Tipo de dato esperado	Significado / descripción
PERIODO	Numérico entero / fecha	Periodo o vigencia en que se reporta el registro del examen.
COLE_MCPIO_UBICACION	Categórico nominal / código	Código o identificador del municipio donde se ubica la institución educativa.
ESTU_COD_RESIDE_MCPIO	Categórico nominal / código	Código del municipio de residencia del estudiante.
ESTU_ESTUDIANTE	Texto	Identificador o descripción del estudiante dentro del registro.
COLE_BILINGUE	Categórico dicotómico	Indica si la institución educativa tiene condición de bilingüe.
ESTU_MCPIO_RESIDE	Texto	Nombre del municipio de residencia del estudiante.
FAMI_EDUCACIONMADRE	Categórico ordinal	Máximo nivel educativo alcanzado por la madre.
FAMI_EDUCACIONPADRE	Categórico ordinal	Máximo nivel educativo alcanzado por el padre.
FAMI_ESTRATOVIVIENDA	Categórico ordinal	Estrato socioeconómico de la vivienda del estudiante.
FAMI_PERSONASHOGAR	Numérico entero	Cantidad de personas que conforman el hogar.

FAMI_TIENECOMPUTADOR	Categórico dicotómico	Indica si el hogar dispone de computador.
FAMI_TIENEINTERNET	Categórico dicotómico	Indica si el hogar dispone de conexión a internet.
PUNT_INGLES	Numérico continuo	Puntaje obtenido en la prueba de inglés.
PUNT_MATEMATICAS	Numérico continuo	Puntaje obtenido en la prueba de matemáticas.
PUNT_SOCIALES_CIUDADANAS	Numérico continuo	Puntaje obtenido en la prueba de sociales y ciudadanas.
PUNT_C_NATURALES	Numérico continuo	Puntaje obtenido en la prueba de ciencias naturales.
PUNT_LECTURA_CRITICA	Numérico continuo	Puntaje obtenido en la prueba de lectura crítica.
PUNT_GLOBAL	Numérico continuo	Puntaje global consolidado del examen ICFES.

3.3 Descripción de atributos del conjunto SISBÉN

El conjunto SISBÉN aporta variables de caracterización socioeconómica y territorial. Su valor principal dentro del proyecto es complementar los resultados educativos con información de vulnerabilidad y contexto social.

Atributo	Tipo de dato esperado	Significado / descripción

cod_mpio	Categórico nominal / código	Código del municipio asociado al registro.
H_5	Variable de encuesta (validar diccionario)	Atributo del formulario SISBÉN cuyo significado exacto debe verificarse en el diccionario oficial de variables.
I1	Variable de encuesta (validar diccionario)	Indicador codificado del formulario SISBÉN; su interpretación puntual requiere contraste con el diccionario de datos.
I2	Variable de encuesta (validar diccionario)	Indicador codificado del formulario SISBÉN; su interpretación puntual requiere contraste con el diccionario de datos.
I3	Variable de encuesta (validar diccionario)	Indicador codificado del formulario SISBÉN; su interpretación puntual requiere contraste con el diccionario de datos.
I4	Variable de encuesta (validar diccionario)	Indicador codificado del formulario SISBÉN; su interpretación puntual requiere contraste con el diccionario de datos.
Grupo	Categórico ordinal	Grupo de clasificación SISBÉN asignado al hogar o a la persona.
Nivel	Categórico ordinal	Nivel interno de clasificación asociado al puntaje o condición socioeconómica.
Clasificacion	Categórico nominal	Categoría de clasificación socioeconómica reportada por el SISBÉN.
Edad	Numérico entero	Edad de la persona registrada.

PER016	Variable de encuesta (validar diccionario)	Variable codificada del formulario SISBÉN; su significado exacto debe validarse con la metadata oficial.

3.4 Descripción de atributos del conjunto Educación

El conjunto de Educación contiene indicadores agregados por municipio y año. Esta fuente permite analizar cobertura, permanencia, conectividad y desempeño del sistema educativo en el territorio.

Atributo	Tipo de dato esperado	Significado / descripción
Año	Numérico entero / fecha	Año de referencia del indicador educativo.
CÓDIGO_MUNICIPIO	Categórico nominal / código	Código DANE del municipio asociado al registro.
TASA_MATRICULACIÓN_5_16	Numérico continuo	Tasa de matriculación de población entre 5 y 16 años.
COBERTURA_NETA	Numérico continuo	Cobertura neta total del sistema educativo.
COBERTURA_NETA_PRIMARIA	Numérico continuo	Cobertura neta en educación primaria.
COBERTURA_NETA_SECUNDARIA	Numérico continuo	Cobertura neta en educación secundaria.
COBERTURA_NETA_MEDIA	Numérico continuo	Cobertura neta en educación media.
SEDES_CONECTADAS_A_INTERNET	Numérico entero / porcentaje	Cantidad o proporción de sedes educativas con acceso a internet,

		según la estructura del archivo fuente.
DESERCIÓN	Numérico continuo	Tasa general de deserción educativa.
DESERCIÓN_PRIMARIA	Numérico continuo	Tasa de deserción en primaria.
DESERCIÓN_SECUNDARIA	Numérico continuo	Tasa de deserción en secundaria.
DESERCIÓN_MEDIA	Numérico continuo	Tasa de deserción en media.
APROBACIÓN	Numérico continuo	Tasa general de aprobación académica.
APROBACIÓN_PRIMARIA	Numérico continuo	Tasa de aprobación en primaria.
APROBACIÓN_SECUNDARIA	Numérico continuo	Tasa de aprobación en secundaria.
APROBACIÓN_MEDIA	Numérico continuo	Tasa de aprobación en media.
REPROBACIÓN	Numérico continuo	Tasa general de reprobación.
REPROBACIÓN_PRIMARIA	Numérico continuo	Tasa de reprobación en primaria.
REPROBACIÓN_SECUNDARIA	Numérico continuo	Tasa de reprobación en secundaria.
REPROBACIÓN_MEDIA	Numérico continuo	Tasa de reprobación en media.
REPITENCIA	Numérico continuo	Tasa general de repitencia.
REPITENCIA_PRIMARIA	Numérico continuo	Tasa de repitencia en primaria.

REPITENCIA_SECUNDARIA	Numérico continuo	Tasa de repitencia en secundaria.
REPITENCIA_MEDIA	Numérico continuo	Tasa de repitencia en media.

4. Exploración de los Datos

En esta etapa se realizó un análisis exploratorio sobre los conjuntos de datos seleccionados, con el fin de comprender su estructura, distribución, variabilidad y posibles relaciones entre variables de interés. La exploración se centró principalmente en el dataset de resultados ICFES y en el dataset Sisbén, complementando el análisis con indicadores agregados a nivel municipal.

Los municipios seleccionados para el estudio fueron Bogotá D.C., Sogamoso y Bugalagrande, debido a que representan contextos territoriales contrastantes en términos de conectividad, condiciones socioeconómicas y desempeño educativo. A partir de los datos filtrados se construyeron visualizaciones que permiten identificar patrones iniciales y sustentar las preguntas de negocio planteadas para la segunda entrega.

4.1 Frecuencia de acceso a internet en el hogar

La primera exploración se realizó sobre la variable FAMI_TIENEINTERNET del dataset ICFES. La gráfica de frecuencias muestra una clara predominancia de estudiantes que reportan sí tener acceso a internet en el hogar, mientras que un grupo considerable reporta no tenerlo y una proporción menor corresponde a valores faltantes.

Este resultado es relevante para el objetivo del proyecto, ya que confirma que la conectividad en el hogar es una variable con suficiente presencia y variabilidad como para ser analizada en relación con los resultados académicos. Al mismo tiempo, la existencia de un grupo importante sin acceso a internet permite estudiar brechas en desempeño entre estudiantes con distintas condiciones tecnológicas.

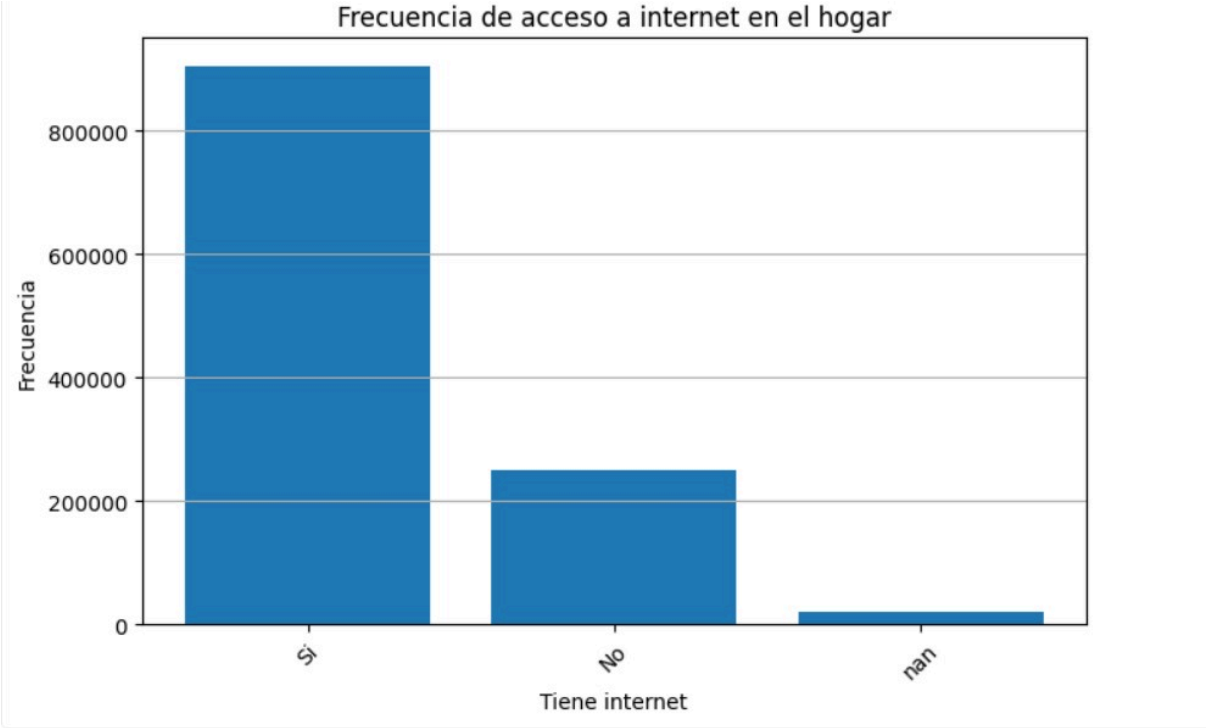

[Insertar Figura 1. Frecuencia de acceso a internet en el hogar]

4.2 Distribución del puntaje global ICFES

Se analizó la distribución del puntaje global del examen Saber 11. La gráfica tipo histograma muestra una concentración importante de observaciones en valores intermedios, con una forma aproximadamente unimodal, centrada alrededor de puntajes medios. También se observan valores extremos hacia ambos lados de la distribución, aunque en menor frecuencia.

Esta distribución sugiere que el rendimiento académico no se comporta de manera uniforme, sino que presenta dispersión suficiente para realizar comparaciones entre municipios, estratos y condiciones socioeconómicas. Además, la presencia de observaciones extremas hace pertinente un análisis posterior de valores atípicos.

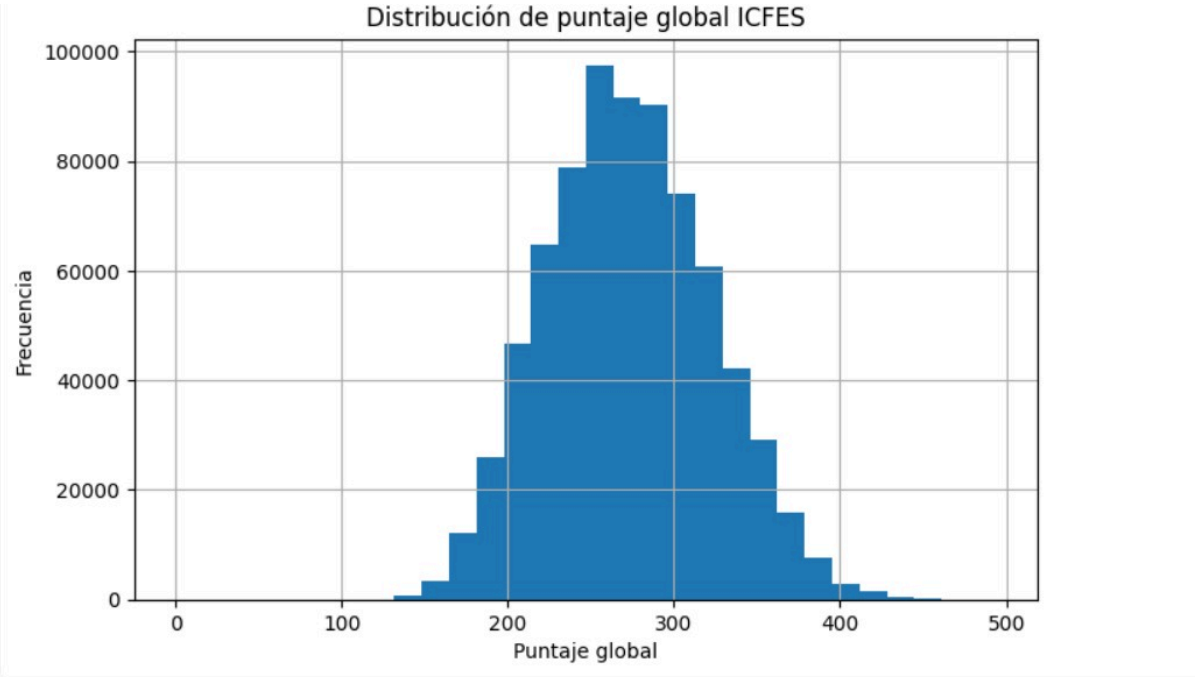

[Insertar Figura 2. Distribución de puntaje global ICFES]

4.3 Puntaje global promedio por municipio

Al comparar el puntaje global promedio entre municipios, se observa que Bogotá presenta el promedio más alto, seguido muy de cerca por Sogamoso, mientras que Bugalagrande registra el promedio más bajo de los tres territorios analizados.

Este resultado es consistente con el contexto planteado en el entendimiento del negocio: Bogotá, al contar con mejores condiciones de conectividad y mayores oportunidades educativas, tiende a mostrar un mejor desempeño agregado. Sogamoso presenta un comportamiento intermedio-alto, mientras que Bugalagrande refleja mayores rezagos relativos.

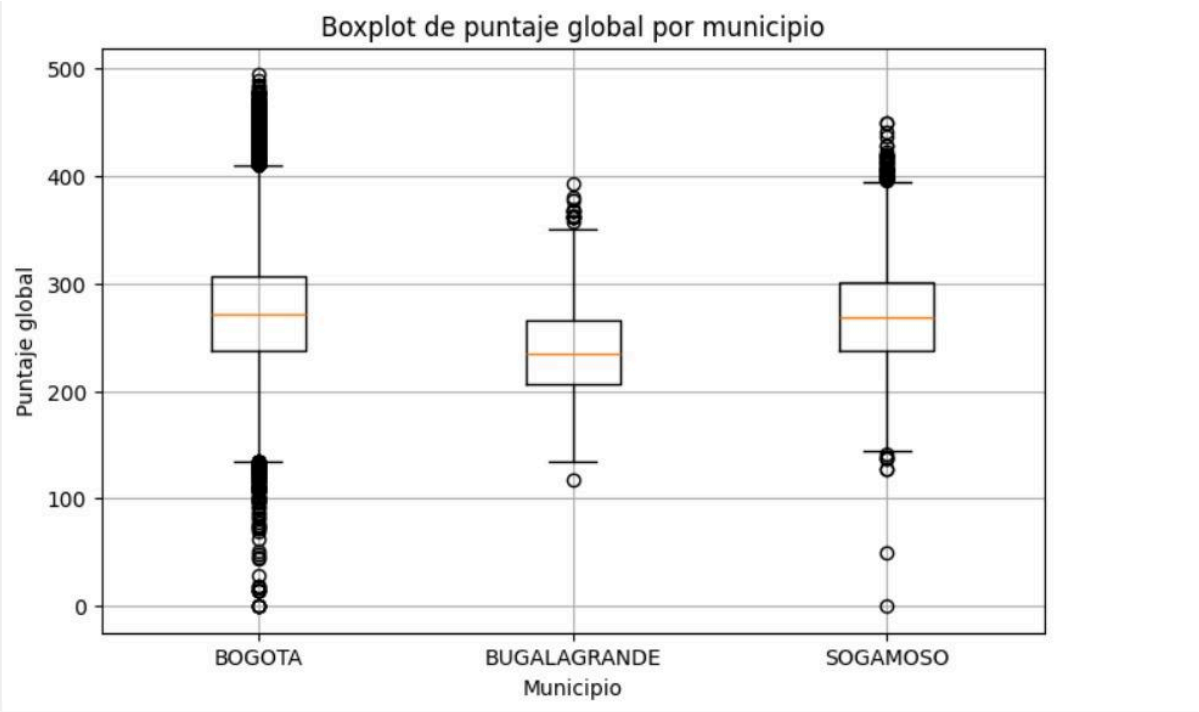

[Insertar Figura 3. Puntaje global promedio por municipio]

4.4 Evolución del puntaje global promedio por periodo

También se analizó el comportamiento del puntaje global promedio a través del tiempo para cada municipio. La serie temporal muestra que Bogotá mantiene, en la mayoría de los períodos, los niveles más altos de puntaje promedio, aunque con fluctuaciones entre años. Sogamoso presenta un comportamiento relativamente más estable, mientras que Bugalagrande evidencia mayor volatilidad y niveles promedio más bajos.

Este patrón sugiere que, además de las diferencias territoriales estructurales, existen variaciones temporales en el desempeño académico que pueden estar relacionadas con cambios en condiciones educativas, cobertura, composición de la población evaluada o incluso ajustes metodológicos entre periodos.

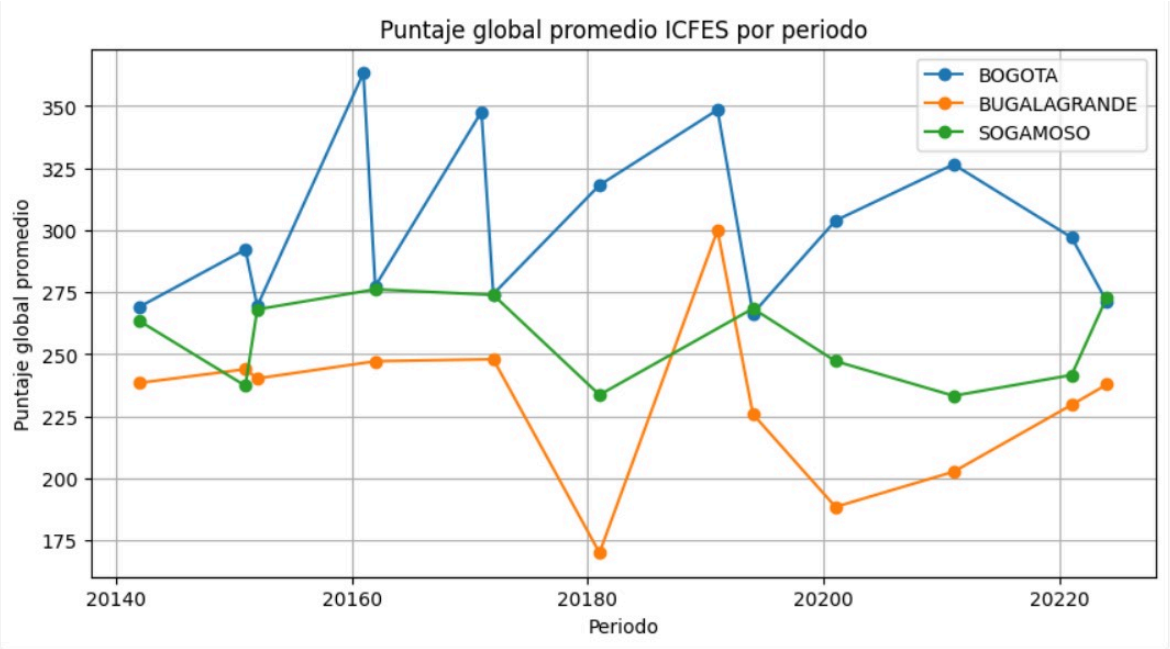

[Insertar Figura 4. Puntaje global promedio ICFES por periodo]

4.5 Comparación de puntajes promedio por área

Se compararon los puntajes promedio en Matemáticas**,** Lectura Crítica **e** Inglés para los tres municipios. En términos generales, Bogotá **y** Sogamoso presentan resultados relativamente cercanos entre sí, mientras que Bugalagrande tiende a ubicarse por debajo en las tres áreas.

Además, se aprecia que Lectura Crítica presenta promedios ligeramente superiores frente a Matemáticas e Inglés en los tres municipios, mientras que Inglés muestra mayor dispersión temporal. Este hallazgo sugiere que las brechas territoriales no afectan por igual todas las competencias evaluadas, lo cual puede ser relevante al diseñar intervenciones focalizadas.

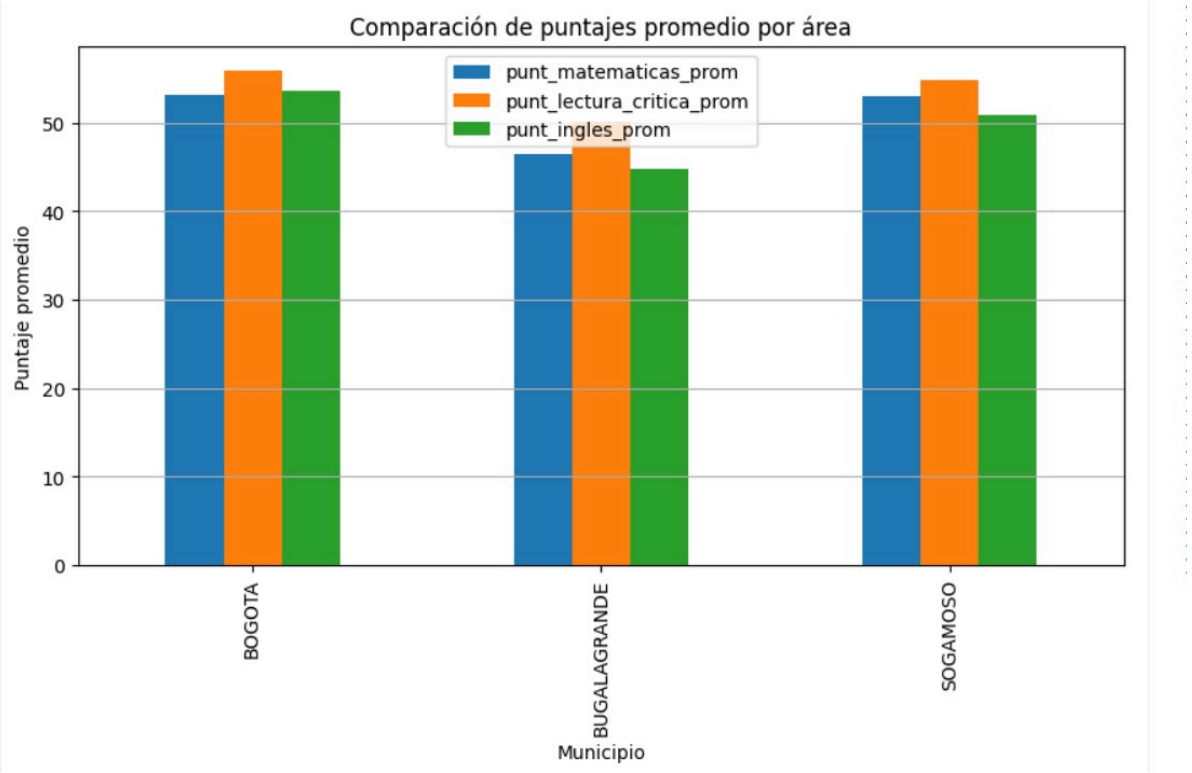

[Insertar Figura 5. Comparación de puntajes promedio por área]

4.6 Evolución temporal de Matemáticas, Lectura Crítica e Inglés

El análisis temporal por área permite observar con mayor detalle las diferencias entre municipios. En Matemáticas, Bogotá se ubica generalmente por encima de los otros municipios, aunque con oscilaciones importantes. En Lectura Crítica, la separación entre Bogotá y Bugalagrande es notoria en varios periodos, mientras que Sogamoso conserva una posición intermedia. En Inglés, la distancia entre Bogotá y los otros dos municipios es especialmente visible, lo que podría estar reflejando desigualdades en exposición al idioma, recursos escolares o calidad institucional.

Estos resultados refuerzan la idea de que la brecha educativa territorial no es homogénea y que ciertas áreas del examen son más sensibles que otras a las diferencias en contexto social y tecnológico.

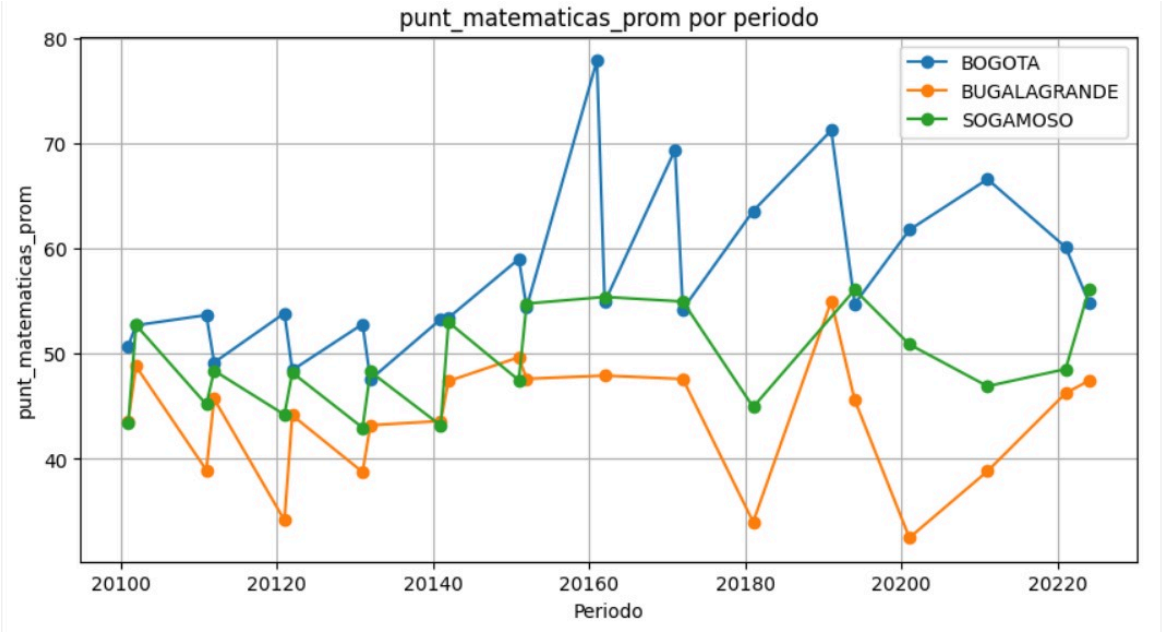

[Insertar Figura 6. Puntaje promedio de Matemáticas por periodo]

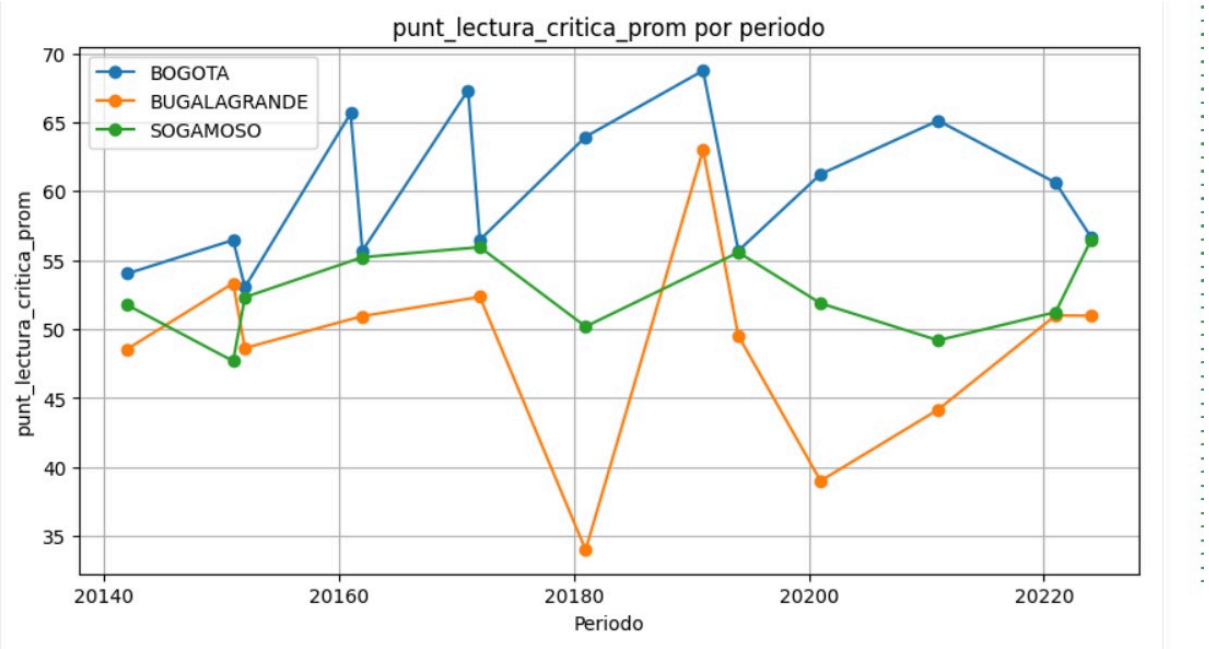

[Insertar Figura 7. Puntaje promedio de Lectura Crítica por periodo]

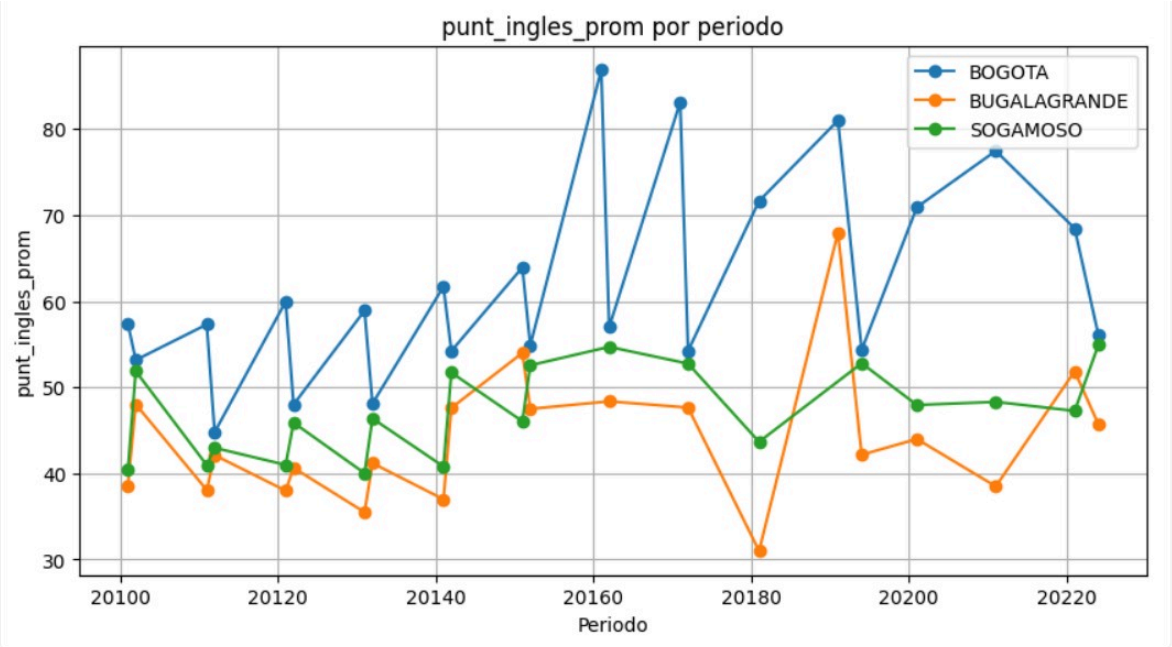

[Insertar Figura 8. Puntaje promedio de Inglés por periodo]

4.7 Puntaje global por municipio: dispersión y valores atípicos

El boxplot por municipio permite comparar no solo los promedios, sino también la dispersión de los puntajes globales. Se observa que Bogotá y Sogamoso presentan medianas superiores a la de Bugalagrande, y que en los tres municipios existen valores atípicos tanto bajos como altos.

La presencia de outliers indica que dentro de cada municipio hay heterogeneidad importante en el desempeño estudiantil. Esto es especialmente relevante en Bogotá, donde aunque el promedio es alto, también persisten estudiantes con resultados considerablemente bajos. En Bugalagrande, por su parte, el menor nivel central se acompaña de un rango más restringido y menos observaciones en la parte alta de la distribución.

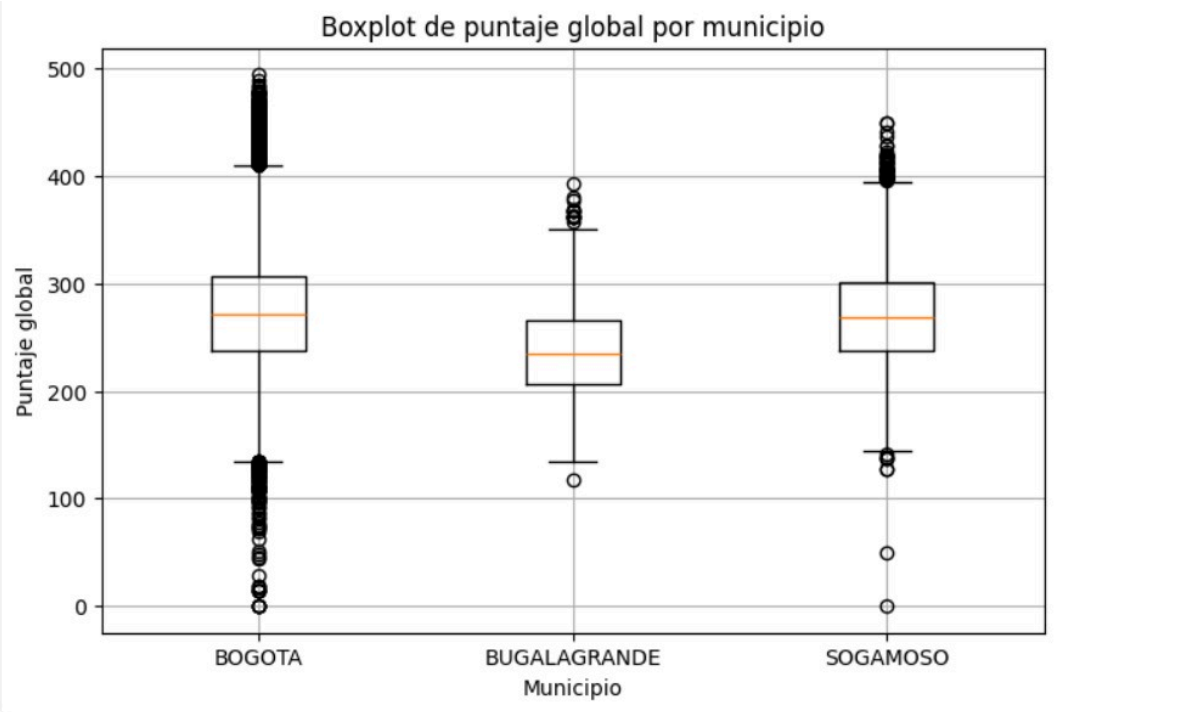

[Insertar Figura 9. Boxplot de puntaje global por municipio]

4.8 Puntaje global por estrato de vivienda

Se exploró la relación entre el puntaje global y el estrato socioeconómico de la vivienda. El boxplot muestra una tendencia ascendente clara: a medida que aumenta el estrato, también aumenta la mediana del puntaje global. Los estratos más bajos concentran resultados más modestos, mientras que los estratos 5 y 6 presentan los puntajes centrales más altos.

Este comportamiento constituye una primera evidencia descriptiva de asociación entre condiciones socioeconómicas y desempeño académico, alineándose con la hipótesis de que el contexto del hogar influye de forma importante en los resultados del examen Saber 11.

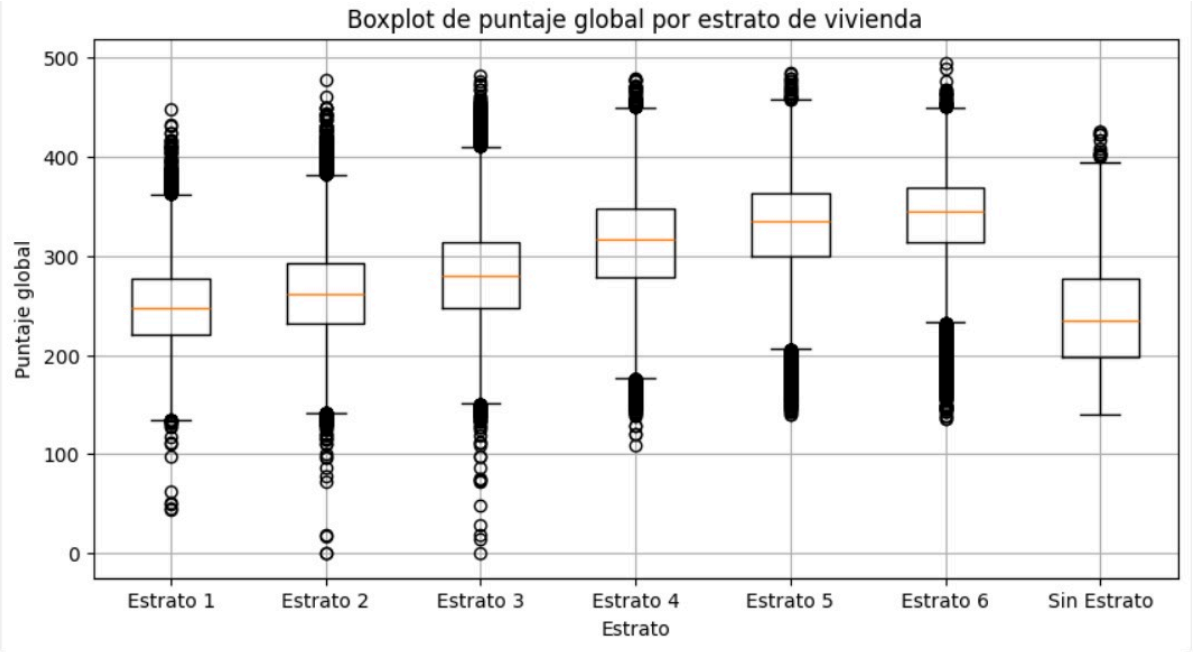

[Insertar Figura 10. Boxplot de puntaje global por estrato de vivienda]

4.9 Distribución de la clasificación Sisbén

En el dataset Sisbén se analizó la frecuencia de la variable clasificación. La gráfica evidencia una mayor concentración en algunas categorías específicas, especialmente en grupos intermedios y vulnerables, mientras que las categorías más extremas tienen menor frecuencia.

Esto sugiere que la población observada en los municipios seleccionados no se distribuye de forma homogénea en la clasificación socioeconómica, sino que tiende a agruparse en determinados niveles de vulnerabilidad. Esta información es importante porque aporta contexto territorial para interpretar diferencias posteriores en el rendimiento educativo.

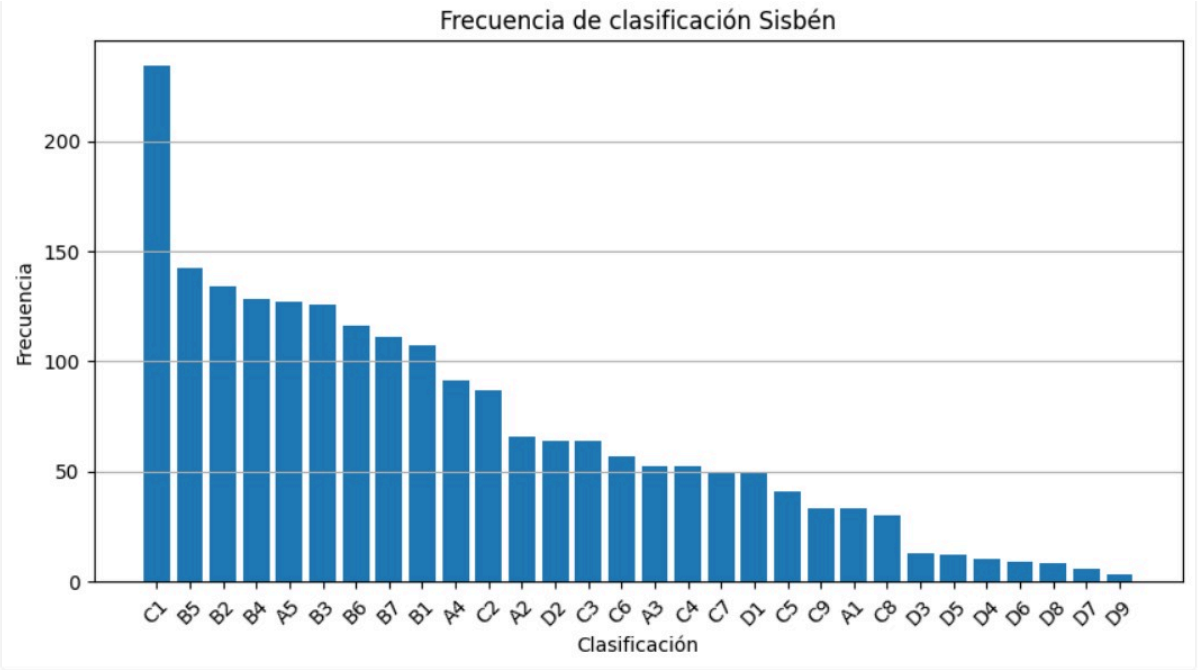

[Insertar Figura 11. Frecuencia de clasificación Sisbén]

4.10 Comparación de indicadores socioeconómicos por municipio

Se construyó una comparación entre municipios a partir de indicadores agregados derivados del Sisbén, como h_5, i1, i2, i3, i4 y la proporción asociada a grupos socioeconómicos más vulnerables. En términos generales, Bugalagrande presenta valores relativamente más altos en varios indicadores de vulnerabilidad, mientras que **S**ogamoso muestra niveles comparativamente más bajos en algunos de ellos. Bogotá aparece en una posición intermedia según el indicador observado.

Este resultado es coherente con la caracterización inicial del problema y fortalece la pertinencia de integrar el componente socioeconómico con el desempeño académico y la conectividad.

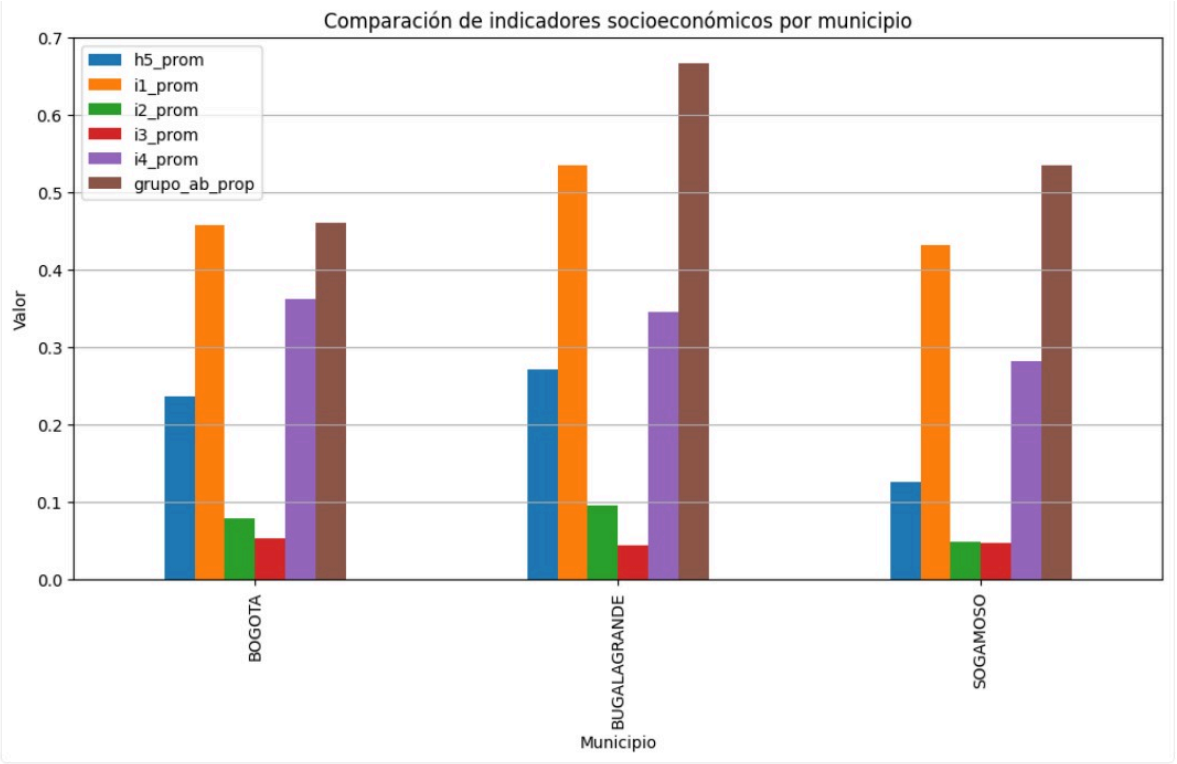

[Insertar Figura 12. Comparación de indicadores socioeconómicos por municipio]

4.11 Matriz de correlación entre variables educativas y socioeconómicas

Finalmente, se elaboró una matriz de correlación con variables agregadas de desempeño académico, cobertura, aprobación, deserción e indicadores socioeconómicos. La visualización permite observar relaciones positivas fuertes entre los puntajes por área y el puntaje global, así como asociaciones negativas entre algunas variables de vulnerabilidad y los indicadores de rendimiento.

También se identifican relaciones inversas entre variables como deserción y desempeño académico, y asociaciones entre aprobación y mejores resultados promedio. Aunque estas correlaciones no implican causalidad, sí permiten identificar variables candidatas para el análisis explicativo y predictivo de la segunda entrega.

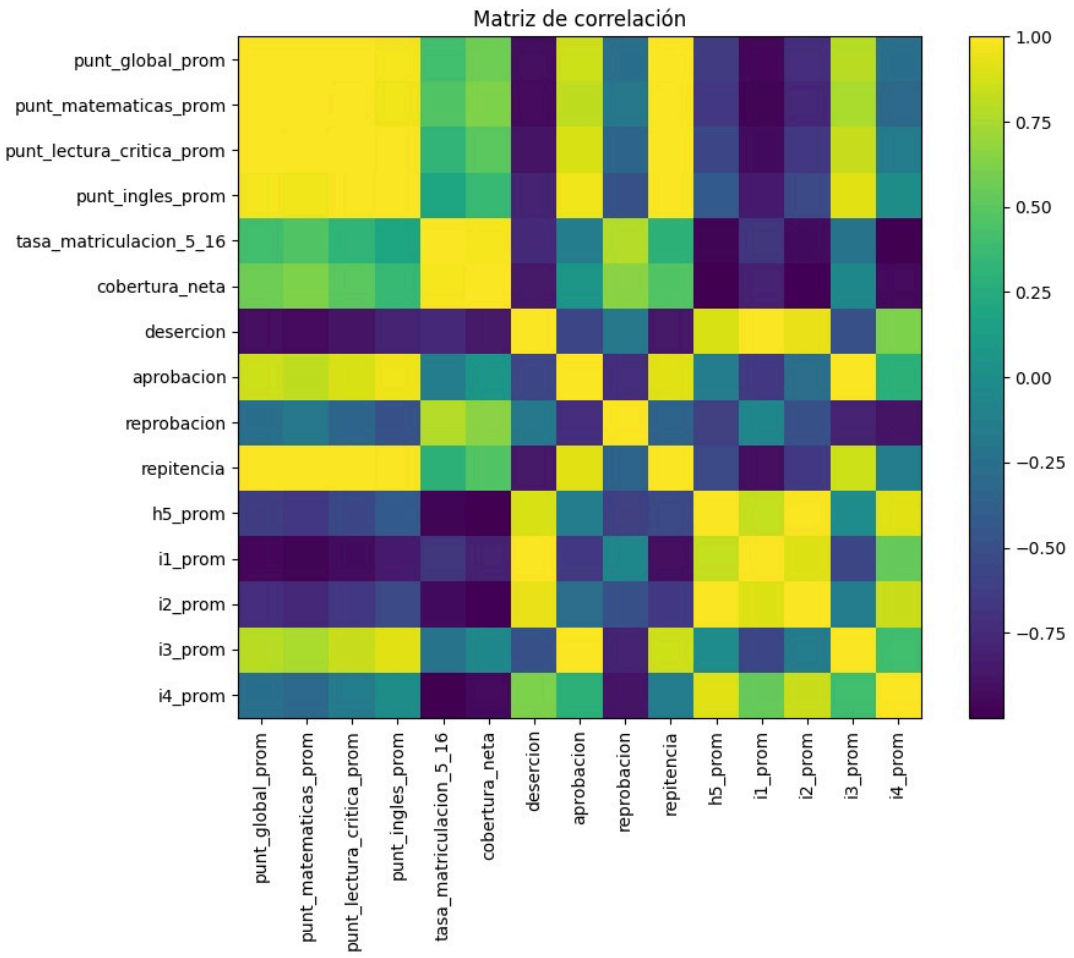

[Insertar Figura 13. Matriz de correlación]

4.12 Síntesis del análisis exploratorio

En conjunto, la exploración de los datos permite establecer cuatro hallazgos preliminares. En primer lugar, existen diferencias territoriales claras en el desempeño ICFES, con Bogotá y Sogamoso por encima de Bugalagrande. En segundo lugar, las condiciones socioeconómicas del hogar, medidas tanto por estrato como por clasificación Sisbén, muestran relación con el desempeño académico. En tercer lugar, el acceso a internet aparece como una variable relevante y con suficiente variación para ser incorporada en el análisis. Finalmente, la existencia de valores atípicos, datos faltantes y heterogeneidad entre periodos justifica una fase posterior de limpieza y transformación más detallada.

5. Reporte de Calidad de los Datos

Con el fin de evaluar la confiabilidad, consistencia y viabilidad analítica de la información utilizada en esta primera entrega, se realizó un análisis de calidad sobre los datasets principales: ICFES y Sisbén. Este análisis se centró en la identificación de valores faltantes, consistencia estructural, tipos de datos y presencia de valores atípicos, así como en sus implicaciones metodológicas para el desarrollo del proyecto.

5.1 Calidad del dataset ICFES

El dataset ICFES, filtrado para los municipios de interés (Bogotá D.C., Sogamoso y Bugalagrande), contiene 1.175.592 registros y 19 columnas, lo que representa una base de datos robusta en términos de volumen y capacidad analítica. Sin embargo, se identificaron valores faltantes en varias variables relevantes, particularmente en aquellas asociadas al desempeño académico.

Las variables con mayor cantidad de valores nulos corresponden a:

- **PUNT_C_NATURALES: 428.627 nulos**
- **PUNT_GLOBAL: 428.627 nulos**
- **PUNT_LECTURA_CRITICA: 428.627 nulos**
- **PUNT_SOCIALES_CIUDADANAS: 428.627 nulos**

El hecho de que estas variables presenten exactamente el mismo número de valores faltantes sugiere que no se trata de ausencia aleatoria, sino de un subconjunto estructurado de registros en los que estas pruebas no fueron reportadas o no aplican bajo ciertas condiciones. Este comportamiento puede estar asociado a cambios en la estructura del examen entre periodos o a diferencias en los esquemas de reporte de información.

Adicionalmente, se identificaron valores faltantes en variables de caracterización del estudiante y su entorno:

- **COLE_BILINGUE: 160.280 nulos**
- **FAMI_EDUCACIONMADRE: 25.207 nulos**
- **FAMI_EDUCACIONPADRE: 25.170 nulos**
- **FAMI_ESTRATOVIVIENDA: 22.240 nulos**
- **FAMI_TIENEINTERNET: 21.389 nulos**
- **FAMI_TIENECOMPUTADOR: 17.304 nulos**
- **FAMI_PERSONASHOGAR: 13.299 nulos**

En menor proporción:

- **ESTU_COD_RESIDE_MCPIO: 249 nulos**
- **ESTU_MCPIO_RESIDE: 249 nulos**
- **PUNT_INGLES: 52 nulos**
- **COLE_MCPIO_UBICACION: 1 nulo**

Por otro lado, variables fundamentales como PERIODO**,** PUNT_MATEMATICAS, ESTU_ESTUDIANTE y municipio_objetivo no presentan valores faltantes, lo cual garantiza una base sólida para la trazabilidad temporal y territorial del análisis.

5.2 Calidad del dataset Sisbén

El dataset Sisbén utilizado contiene 715 registros y 11 columnas, y presenta una estructura considerablemente más limpia en comparación con ICFES. No se identificaron valores faltantes en ninguna de las variables analizadas:

- cod_mpio
- h_5
- i1, i2, i3, i4
- grupo
- nivel
- clasificacion
- per016
- per002

Esta completitud convierte al dataset Sisbén en una fuente altamente confiable para caracterizar condiciones socioeconómicas a nivel territorial y construir indicadores agregados sin necesidad de imputaciones adicionales.

5.3 Consistencia de tipos de datos

En el dataset ICFES se observa una estructura mixta entre variables numéricas y categóricas, lo cual es consistente con la naturaleza del conjunto. No obstante, se identificaron inconsistencias en variables que conceptualmente deberían ser numéricas, como FAMI_PERSONASHOGAR, la cual se encuentra almacenada como tipo object. Esto implica la necesidad de realizar procesos de conversión y validación para garantizar su correcto uso en análisis cuantitativos.

En el dataset Sisbén, la estructura de tipos es más homogénea, predominando variables numéricas enteras, con algunas variables categóricas claramente definidas (como grupo y clasificación), lo que facilita su procesamiento.

5.4 Estrategias de tratamiento de datos

A partir del comportamiento observado en los datos, se definieron estrategias de tratamiento orientadas a preservar la integridad de la información y minimizar sesgos analíticos.

En el caso de los valores faltantes, se propone una estrategia diferenciada según el tipo de variable. Para variables numéricas con dispersión significativa y presencia de valores atípicos, se prioriza el uso de la mediana como método de imputación, dado que esta medida es robusta frente a extremos y representa mejor la tendencia central en distribuciones

asimétricas. En contraste, el uso de la media podría introducir sesgos debido a la influencia de outliers.

Para variables categóricas, se plantea la imputación mediante la categoría más frecuente (moda) o la creación de una categoría adicional que represente la ausencia de información, evitando así la pérdida de registros.

En el caso específico de variables críticas como PUNT_GLOBAL, se propone la eliminación de registros con valores faltantes, dado que imputar estos valores podría distorsionar significativamente los resultados y comprometer la validez del análisis.

Respecto al tratamiento de valores atípicos, se plantea un enfoque técnico basado en la identificación mediante el rango intercuartílico (IQR), definiendo como outliers aquellos valores que se encuentran fuera de los límites:

- $Q1 - 1.5 * IQR$
- $Q3 + 1.5 * IQR$

No obstante, dado que los outliers son abundantes en los datos, se evita su eliminación directa. En su lugar, se propone el uso de técnicas de amortiguación, como la winsorización, que consiste en ajustar los valores extremos a percentiles límite (por ejemplo, 1% y 99%), reduciendo su impacto sin eliminar información relevante.

Adicionalmente, se plantea la aplicación de transformaciones robustas y escalamiento robusto (RobustScaler) en etapas posteriores, con el fin de mitigar la influencia de valores extremos en modelos analíticos.

Es importante resaltar que no todos los valores atípicos representan errores; algunos corresponden a comportamientos reales dentro de la población, como estudiantes con desempeño excepcional o muy bajo, por lo que su tratamiento debe considerar el contexto del análisis.

5.5 Implicaciones para el análisis

El principal desafío de calidad identificado se concentra en los valores faltantes del dataset ICFES, especialmente en variables de puntaje. Esto implica que no todos los registros podrán ser utilizados en todos los análisis, siendo necesario definir subconjuntos de datos según la disponibilidad de información.

Por otra parte, las variables socioeconómicas, aunque presentan faltantes moderados, siguen siendo utilizables mediante técnicas de imputación adecuadas. Finalmente, la presencia de valores atípicos y alta variabilidad refuerza la necesidad de aplicar técnicas robustas de análisis en la siguiente fase del proyecto.

En conjunto, a pesar de los desafíos identificados, los datasets presentan una calidad suficiente para el desarrollo del proyecto, siempre que se implementen estrategias adecuadas de limpieza, transformación y validación.

6. Planteamiento de Preguntas de Negocio

A continuación se presentan las preguntas de negocio que guiarán el análisis de la Entrega 2. Las respuestas serán desarrolladas mediante procesamiento de datos con Apache Spark y la aplicación de modelos de aprendizaje de máquina.

1. ¿Cómo influye el acceso a internet en el hogar en el puntaje global del ICFES en los municipios seleccionados?
2. ¿Qué tan significativa es la brecha en puntajes ICFES entre estudiantes con y sin acceso a internet?
3. ¿Cómo varía el desempeño académico (puntaje global y por áreas) entre Bogotá, Sogamoso y Bugalagrande a lo largo del tiempo?
4. ¿Cuál es la relación entre el estrato socioeconómico de la vivienda y el rendimiento en el examen Saber 11?
5. ¿Qué indicadores socioeconómicos derivados del Sisbén (h_5, i1, i2, i3, i4) presentan mayor asociación con el desempeño académico?
6. ¿Existe relación entre la conectividad institucional (sedes conectadas a internet) y los resultados académicos promedio por municipio?
7. ¿Cómo afectan variables del sistema educativo como cobertura, deserción y aprobación al desempeño en el ICFES?
8. ¿Qué área del examen (Matemáticas, Lectura Crítica o Inglés) es más sensible a las diferencias socioeconómicas y de conectividad entre municipios?

7. Filtros, Limpieza y Transformación Inicial

Como parte de la etapa de preparación inicial de los datos, se realizaron procesos de filtrado, selección, adecuación estructural y transformación sobre los datasets de ICFES, Sisbén y Educación. Estas acciones tuvieron como propósito construir una base de datos coherente, consistente y alineada con el objetivo del proyecto, facilitando el análisis exploratorio y sentando las bases para la siguiente fase.

En primer lugar, se aplicó un filtro territorial, restringiendo el análisis a los municipios de interés: Bogotá D.C. (11001), Bugalagrande (76113) y Sogamoso (15104). Este paso permitió enfocar el estudio en tres contextos con características contrastantes en términos de conectividad, condiciones socioeconómicas y desempeño académico.

Adicionalmente, en el dataset Sisbén se implementó un filtro por rango etario, seleccionando únicamente individuos entre 12 y 17 años. Esta decisión metodológica busca alinear la población analizada con el grupo de edad que típicamente presenta el examen Saber 11, evitando incluir registros que no aportan directamente al problema de estudio y mejorando la coherencia entre las fuentes de información.

En cuanto a la selección de variables, se realizó una reducción de columnas en los tres datasets, conservando únicamente aquellas relevantes para el análisis. En el caso del ICFES, se seleccionaron variables relacionadas con la ubicación del estudiante, características del hogar, acceso a tecnología y puntajes del examen. En el dataset Sisbén, se conservaron variables de identificación territorial y de caracterización socioeconómica. Por su parte, en el dataset de Educación se seleccionaron indicadores clave como matrícula, cobertura, conectividad institucional, deserción, aprobación, reprobación y repitencia.

Un aspecto relevante del proceso de transformación se presentó en el dataset de Educación, donde varias variables de tasas se encontraban almacenadas como texto con formato de porcentaje (por ejemplo, "85%"). Para su adecuado procesamiento, se realizó una transformación que consistió en eliminar el símbolo de porcentaje, convertir los valores a tipo numérico y normalizarlos a una escala entre 0 y 1. Esta transformación es fundamental para garantizar la compatibilidad con análisis estadísticos y modelos de aprendizaje de máquina.

Asimismo, se realizó una estandarización de nombres de columnas, eliminando tildes, espacios y caracteres especiales, y adoptando una nomenclatura homogénea en minúsculas con formato snake_case. Este proceso mejora la legibilidad del código y reduce errores en el procesamiento.

También se llevaron a cabo conversiones de tipos de datos en variables clave, como el código de municipio y el año, asegurando su formato numérico para facilitar la integración entre datasets. Este paso es especialmente importante en entornos de procesamiento de datos a gran escala, donde la consistencia de tipos impacta directamente la eficiencia de los procesos.

En términos de limpieza, se realizó una revisión inicial de valores faltantes y consistencia estructural, lo que permitió identificar las variables que requieren tratamiento en fases posteriores. Asimismo, se validó la existencia de las columnas esperadas en el dataset de Educación antes de su procesamiento, evitando errores derivados de supuestos incorrectos sobre la estructura de los datos.

En relación con los valores atípicos, el análisis exploratorio evidenció una presencia significativa de outliers en variables como el puntaje global y los puntajes por área. En esta fase, en lugar de eliminar estos valores, se optó por identificarlos y caracterizarlos, utilizando herramientas como boxplots y medidas de dispersión. Esta decisión responde a la necesidad de preservar información potencialmente relevante y dejar el tratamiento definitivo para etapas posteriores, donde se podrán aplicar técnicas como winsorización, transformación logarítmica o escalamiento robusto.

Finalmente, se realizaron transformaciones iniciales orientadas a la generación de variables agregadas, como promedios por municipio y por periodo, comparaciones entre áreas del conocimiento y análisis de distribución por estrato y acceso a internet. Estas transformaciones fueron fundamentales para la construcción de las visualizaciones exploratorias presentadas en el análisis de datos.

En conjunto, los procesos desarrollados en esta etapa permitieron estructurar los datos de manera coherente y alineada con el objetivo del proyecto. Si bien la preparación no se considera finalizada, esta fase establece una base sólida para la siguiente etapa, en la cual se profundizará en la integración de datasets, el tratamiento avanzado de datos y la aplicación de modelos analíticos.

8. Referencias:

Instituto Colombiano para la Evaluación de la Educación
(2025). *Resultados únicos Saber 11*. Datos Abiertos Colombia.
Disponible en: https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe/about_data

Departamento Nacional de Planeación
(2025). *Sisbén Personas*. Datos Abiertos Colombia.
Disponible en:
https://www.datos.gov.co/Estad-sticas-Nacionales/DNP-Sisb-n-Personas/hq2v-5umk/about_data
Departamento Nacional de Planeación
(s.f.). *Diccionario de datos Sisbén IV*.
Disponible en: https://anda.dnp.gov.co/index.php/catalog/150/datafile/F18
Departamento Nacional de Planeación
(2025). *Vista DNP Sisbén Personas*. Datos Abiertos Colombia.
Disponible en:
https://www.datos.gov.co/Estad-sticas-Nacionales/Vista-DNP-SISBEN-PERSONAS/dqyr-kxvd/about_data

Ministerio de Educación Nacional
(2025). *Estadísticas en educación preescolar, básica y media por municipio*. Datos Abiertos Colombia.
Disponible en:
https://www.datos.gov.co/Educaci-n/MEN_ESTADISTICAS_EN_EDUCACION_EN_PREESCOLAR-B-SICA/nudc-7mev/data_preview

Alkire, S., & Foster, J. (2011). *Counting and Multidimensional Poverty Measurement*. Journal of Public Economics.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.